

与统一嵌入空间的设计思路，让视觉与语言模块在特征层面深度对齐，支撑多模态的理解与推理任务。

ViT-3D：作为原生分辨率的视觉编码器，是架构中负责视觉特征提取的核心模块，集成了 NaViT 的 patch 打包策略，可直接处理不同分辨率的图像输入，无需进行复杂的子图像分割和拼接操作，同时针对视频理解设计了轻量级3D ViT 压缩机制，将连续四帧进行分组处理，通过共享编码器和补丁级的时间平均实现时空特征提取，还能在保持图像与视频编码器完全权重共享的前提下，让模型在相同上下文窗口内处理4倍时长的视频，且通过时间池化完成时空特征的有效聚合，输出适配后续融合的视觉特征表示。

MLP 投影器：作为连接视觉编码器与语言模型的桥梁模块，承接 ViT-3D 输出的视觉特征，通过多层感知机的映射转换，将视觉特征空间对齐到 MoE 语言模型的嵌入空间，实现视觉特征与语言特征的维度匹配和特征融合，为后续跨模态的理解与推理提供统一的特征表示基础，让视觉特征能够被语言模型有效解读和利用。

MoE 语言模型：作为架构的核心语言处理模块，是基于万亿参数的混合专家 Transformer 模型打造，整体包含1.04万亿总参数，其中激活参数为320亿，采用384个专家单元的设计，且每一个输入词元仅激活8个专家，形成48%的稀疏度，依托大尺度的预训练语言能力，承接经 MLP 投影器映射后的视觉-语言融合特征，完成多模态语境下的理解、推理与生成任务，同时与视觉模块形成双向增强，让语言能力为视觉推理提供逻辑支撑，视觉能力反过来优化语言的结构化推理表现。

6.1.4.2.2 多模态表征大模型

本项目将构建一款高性能多模态表征大模型，项目拟选择 VL 基

础模型作为骨干基座，核心拟采用双编码器为核心架构，依托因果注意力机制实现文本、图像、视觉文档、视频等多模态数据的独立编码与统一表征，本架构将遵循 VL 基础模型的指令感知式上下文结构进行设计，拟支持32K 超长序列输入、三十余种语言的多语言处理能力，同时将设置2B（28层网络）和8B（36层网络）两种参数规模版本，本模型核心将实现各类多模态输入到任务感知稠密向量表征的转化，各功能模块将严格按照多模态数据的处理流程依次衔接、层层发挥作用，形成从多模态输入接收、处理到嵌入向量输出的完整架构链路，保障多模态统一表征的高效实现。

模态适配处理模块是多模态数据进入模型的首个处理层，针对图像、视频、视觉文档不同视觉模态的输入特性开展专属的前置结构拆分与格式转换处理，为图像保留原始宽高比并转化为视觉编码器可处理的张量格式，为视频按固定帧率完成帧采样并设置最大采样帧数，再对单帧图像单独做格式转换且保留视频的时序特性，为视觉文档按版面结构拆分文字、图片、表格等子组件，分别完成格式转换后按原始版面顺序拼接为统一的视觉张量并保留文档版面语义，该模块所有处理仅做架构层面的格式适配，不改变视觉数据核心特征，同时对各视觉模态的令牌消耗设置上限约束，避免超长视觉输入导致的编码溢出，确保适配后的视觉输入能满足模型32K 序列长度的架构设计要求。

输入处理与模板解析模块是承接模态适配处理模块的核心衔接层，作为模型的指令感知核心入口，承担架构层面任务定制化的核心功能，对接经前置处理的视觉数据及原始文本数据，负责解析用户传入的各类任务指令和多模态实例，按照固定的上下文模板将各类输入封装为标准化的令牌序列，以系统消息段传入任务指令、用户消息段传入处理后的多模态实例，最后拼接起到锚点作用的 PAD 令牌，无

论输入为单一模态还是多模态组合，最终都会将其转化为包含系统、指令、用户、多模态、PAD 相关令牌的统一序列，实现全类型输入格式的归一化，确保不同任务、不同模态的输入能被后续模块统一处理。

基础支撑模块是多模态表征大模型的底层核心基座，具备 VL 视觉编码器和 LM 稠密解码器两大核心组件，承接输入处理与模板解析模块输出的标准化令牌序列，其中视觉编码器专门对序列中的视觉令牌做进一步特征提取与优化，LM 稠密解码器同时接收视觉令牌和文本令牌，依托因果注意力机制完成跨模态语义融合与特征深度编码，最终输出模型权重和最后隐藏状态，为后续的特征编码和向量生成提供高维语义特征基础，同时继承 VL 模型的多语言能力，支持32K 词元长度的超长序列的特征编码，能够适配长文本、长视频等复杂多模态输入的处理需求。

核心编码模块是多模态表征大模型双编码器架构的核心执行层，依托基础支撑模块提供的特征基础和组件能力，对标准化后的多模态令牌序列中的文本模态和视觉模态开展独立的特征编码处理，为文本模态由语言解码器直接对文本令牌完成深度编码，为视觉模态先经由视觉编码器完成特征转化后，再送入语言解码器进行编码，针对多模态组合输入，在完成各模态独立编码后，由语言解码器完成跨模态的轻量融合，该模块的设计能有效避免跨模态编码的相互干扰，同时依托因果注意力机制实现模态内的特征深度融合，最终输出与输入序列长度匹配、包含所有模态完整语义特征信息的高维特征序列，为嵌入向量生成提供核心且精准的特征源。

嵌入向量生成模块是多模态表征大模型的最终输出层，也是实现多模态统一表征的关键核心模块，承接核心编码模块输出的高维特征序列，以序列中 PAD 令牌为唯一锚点，精准提取该令牌位置对应的

模型最后隐藏状态，并将其作为整个多模态输入的最终嵌入向量表征，实现任意多模态输入到单一固定维度稠密向量的转化，为2B 版本设置2048维固定输出嵌入向量，为8B 版本设置4096维固定输出嵌入向量，向量维度与输入的模态类型、输入长度均无关联，该模块生成的高维稠密实值向量，可直接通过余弦相似度等常用度量方式实现多模态实例间的相关性判断，能够完美适配多模态检索的核心业务需求。

6.1.4.2.3 多模态生成大模型

本项目拟选择双分支 Diffusion Transformer (DIT) 作为核心基底，将构建基于 MMDiT 架构的统一多模态联合生成架构，拟在该架构中集成跨模态联合模块，打造端到端的音视频原生联合生成链路，整体架构将实现视觉与听觉分支的并行特征处理，依托跨模态交互实现音视频的深度融合，从输入特征解析到最终音视频内容生成形成标准化的架构链路，同时拟让该架构天然支持文本到音视频、图像到音视频、单模态视频生成等多类下游任务，保障视觉与听觉流的时间同步性和语义一致性。

文本编码器模块：该模块是架构的输入特征解析单元，负责对文本提示词进行语义编码，将自然语言指令转化为架构可识别的标准化特征向量，针对图像引导的生成任务，还会完成参考图像的视觉特征提取与编码，为后续双分支的特征处理提供统一的输入特征，是连接外部输入与架构内部生成逻辑的前置核心单元。

视觉分支处理模块：该模块是双分支 Diffusion Transformer 架构的视觉核心单元，基于 MMDiT 架构的设计逻辑实现视觉维度的特征学习与建模，专门处理画面主体、动作动态、镜头运动、场景过渡等视觉相关特征的构建与演化，按照输入特征的指引生成符合创作需求的视觉序列特征，同时模块内置与听觉分支的特征交互接口，为跨模

态融合提供视觉侧的特征基础。

听觉分支处理模块：该模块是双分支 **Diffusion Transformer** 架构的听觉核心单元，同基于 **MMDiT** 架构搭建，专注于人声、音效、背景音乐等听觉维度的特征构建与演化，能够根据输入特征生成匹配创作场景的音频序列特征，精准捕捉语言、方言的语音韵律特征，模块同样内置与视觉分支的特征交互接口，为跨模态融合提供听觉侧的特征基础，与视觉分支处理模块并行运作。

跨模态联合模块：该模块是基于 **MMDiT** 架构的统一多模态联合生成核心单元，承接视觉分支处理模块和听觉分支处理模块输出的特征信息，通过跨模态注意力机制实现视觉与听觉特征的深度交互、融合与协同校准，从时间维度和语义维度对双分支特征进行匹配优化，让视觉与听觉特征形成统一的跨模态特征表征，保障后续生成的音视频内容在口型、动作、音效等维度的精准同步，以及叙事、场景表达的语义一致。

音视频联合生成模块：该模块是架构的最终生成单元，基于跨模态联合模块输出的统一跨模态特征表征，依托 **Diffusion Transformer** 的生成能力，将特征向量转化为可直接输出的视频帧序列与音频波形数据，是架构实现音视频原生联合生成的收尾环节，能够按照架构的设计逻辑，将融合后的跨模态特征完整还原为音视频内容，且天然适配文本到音视频、图像到音视频等多种生成任务的输出需求。

语音生成大模型。本项目拟构建以离散语音表示为核心的端到端语音生成大模型，将采用双轨自回归语言模型设计实现实时流式语音合成，同时搭配两款专用语音分词器搭建多模块协同的处理链路，该架构将打通从文本输入到语音输出的全流程环节，可支撑多语言生成、语音克隆及语音细粒度控制等核心功能的落地实现。

文本分词器：对输入的自然语言文本开展标准化解析处理，将文本转换为模型可识别的文本令牌，是模型完成文本输入处理的首个环节，为后续文本特征与声学特征的融合构建基础条件。

说话人编码器：作为与模型骨干网络联合训练的可学习模块，从参考语音中提取说话人独有的音色、语调等身份特征并生成对应的说话人嵌入，以此实现对说话人身份的精准捕捉与保留，为语音克隆和特定说话人语音生成提供核心的身份特征支撑。

语音分词器：作为实现语音信号离散化表示的核心模块，包含两款适配不同场景需求的专用分词器。其中**25Hz** 版本为单码本编解码器，融合语义与声学双重线索，依托 **Audio** 编码器完成语音令牌提取，可通过块级扩散转换器实现流式波形重建；**12Hz** 版本为**12.5Hz** 多码本编解码器，采用语义-声学解纠缠量化策略，通过多层多码本设计与轻量级因果卷积网络，实现极低延迟的语音令牌编码与解码，可支持毫秒级的首包音频发射。

双轨表示融合模块：将文本分词器输出的文本令牌与语音分词器处理得到的声学令牌沿通道维度进行拼接，构建出融合文本语义与声学特征的双轨表示，实现两类特征的深度融合，为模型的实时语音合成提供融合后的核心特征数据。

语言模型：作为语音生成大模型的核心骨干模块，依托 **LM** 模型的高并发、低延迟推理能力，接收双轨表示融合模块输出的融合特征后，根据输入的文本令牌实时预测对应的声学令牌序列，其中适配 **12Hz** 语音分词器的版本会优先完成第**0**码本特征的预测，为后续残留码本的生成奠定基础。

多令牌预测模块：专为适配**12Hz** 语音分词器的模型版本设计，在语言模型完成第**0**码本特征预测后，基于该特征生成所有残留码本

的特征信息，能够精准捕捉语音中的各类声学细节，有效提升生成语音的表达一致性与丰富度，同时通过单帧即时生成的机制进一步降低语音合成的端到端延迟。

Code2Wav 模块：作为实现令牌到语音信号还原的关键模块，负责将模型各环节生成的声学令牌转换为可直接输出的实际语音波形。其中适配25Hz 语音分词器的版本通过块级扩散转换器与改进型 BigVGAN 声码器协同工作，基于流匹配技术完成语音波形的高保真重建；适配12Hz 语音分词器的版本则通过纯左上下文的流式编解码器，无需等待未来上下文信息即可实现音频的增量重建，在保障超低延迟的同时兼顾语音波形的还原质量。

流式解码器：适配语音生成大模型的流式处理核心需求，为流式语音合成提供专属的技术支撑。其中适配25Hz 语音分词器的版本采用滑动窗口块注意力机制，通过限制令牌的上下文参考范围，实现长序列语音的稳定流式生成；适配12Hz 语音分词器的版本采用全因果特征编解码器，按12.5Hz 的速率逐帧处理语音令牌并增量输出音频数据，能够充分满足实时在线语音服务的超低延迟需求。

6.1.4.3 安防行业后预训练

6.1.4.3.1 模型训练数据管道




图 124 模型训练数据管道及管理架构

6.1.4.3.1.1 数据源接入模块

数据源接入模块是训练过程的共性模块，负责实现多源异构数据的统一接入与融合，为后续的建模分析提供稳定可靠的数据基础支撑。

该模块通过统一数据模型抽象与数据组织规范，实现字段标准化、类型转换与元数据管理，消除多源数据之间的结构差异；同时支持多源数据融合。

6.1.4.3.1.2 数据清洗与标准化模块

数据清洗与标准化模块主要负责对接入数据进行质量治理与合规控制，提升数据可用性与一致性。在去重方面，模块支持基于 MinHash 与 SimHash 的近似相似度计算算法，实现大规模文本或多模态数据的高效相似检测与重复样本剔除，降低冗余数据对存储与模型

训练的影响；同时通过规则引擎与统计方法进行噪声过滤，识别异常值、乱码数据、格式错误及无效字段，确保数据结构与内容的规范性。

针对多模态数据，模块支持对图像分辨率、文件大小、清晰度，音频时长、采样率，以及文本长度、字符分布等指标进行阈值过滤与质量分级，避免低质量样本进入下游流程；同时构建内容安全与合规过滤机制，对不关注领域数据及违法违规内容进行自动识别与拦截，结合关键词规则与模型识别能力，保障数据集的合法性、相关性与可控性，为后续数据分析或模型训练提供高质量、可治理的数据基础。

6.1.4.3.1.3 数据质量评估模块

数据质量评估模块用于对数据集整体质量进行量化分析。模块首先基于去重算法与相似度计算结果，对数据样本进行重复率统计，区分完全重复与近似重复样本，形成重复率指标与分布报告，评估数据冗余程度及对存储与建模效率的影响。

同时，模块通过规则校验、异常检测与分类模型评估垃圾数据比例，包括无效样本、低质量内容、格式错误及噪声数据占比，并生成质量评分。在语义层面，模块结合向量化表示与聚类分析方法，对数据进行语义多样性评估，衡量主题分布广度、语义覆盖范围与样本分布均衡性，识别语义集中或数据偏置问题，从而为数据筛选、补充与结构优化提供定量支撑，提升数据集的代表性与泛化能力。

6.1.4.3.1.4 数据增强模块

数据增强模块旨在通过多策略扩展与变换原始数据，提高数据规模、语义覆盖度与模型泛化能力。在文本数据方面，模块支持基于规则与模型的语义改写，在保持语义一致的前提下生成多样化表达；支持多语种数据翻译与回译增强，扩展跨语言语料分布；同时构建对比样本生成机制，通过构造正负样本对、扰动样本或难例样本，增强模

型对语义差异与边界特征的判别能力。

在图像数据方面，模块支持多种图像增强策略，包括几何变换（旋转、裁剪、翻转）、色彩扰动、噪声注入、模糊处理及分辨率调整等。整体模块支持可配置化增强策略组合与强度控制，并提供增强数据标记与溯源能力，确保增强过程可追踪、可回滚，为模型训练提供更加丰富、均衡且具鲁棒性的数据基础。

6.1.4.3.1.5 数据版本与治理模块

模块对参与模型训练的数据集进行版本化管理，为每一次数据变更（如样本新增、删除、清洗规则调整、标注修订等）生成唯一版本标识，并记录元数据（数据规模、字段结构、质量指标、生成时间、责任人等），确保不同训练任务可精确定位所使用的数据版本，实现实验可复现与结果可审计。

同时，模块支持训练数据集快照机制，在关键节点（如模型发布前、重大数据更新后）生成完整数据状态镜像，用于归档与对比分析；当数据异常或模型效果退化时，可基于历史版本或快照执行一键回滚，快速恢复至指定稳定版本，避免不可控的数据漂移风险。通过版本血缘追踪与变更记录管理，模块实现数据全生命周期治理，强化数据合规性与风险控制能力，为模型稳定迭代提供可靠的数据基础。

6.1.4.3.1.6 数据存储与格式模块

模块基于分布式文件系统或对象存储架构，结合数据分片策略，将数据按照样本、时间、哈希或业务维度进行切分，实现并行读写与负载均衡，提升数据吞吐性能与扩展能力；同时支持冷热分层存储与压缩策略，优化存储成本与访问效率。

同时，支持预先词元化与延迟词元化两种设计决策。预先词元化方案通过离线分词与编码，将文本提前转换为模型输入格式，适用于

训练场景稳定、对吞吐要求高的环境；延迟词元化则在数据加载阶段动态完成分词与编码，适用于多模型共享数据或分词器频繁迭代的场景。模块支持统一数据格式抽象与元数据管理，确保不同存储策略与处理策略之间的兼容性与可追溯性，在性能、灵活性与存储成本之间实现可控平衡。

6.1.4.3.1.7 词元化与特征化模块

模块负责将原始多模态数据转换为模型可直接消费的结构化表示，是训练与推理流程中的核心前处理组件。模块支持自定义分词器训练，包括基于 BPE、WordPiece、Unigram 等算法构建子词词表，结合领域语料进行词表优化与 OOV 控制；同时支持与主流框架（如 Hugging Face Transformers）兼容的分词器格式输出。为提升性能，模块提供分词缓存机制，对高频样本或静态数据进行结果持久化存储，降低重复计算开销，提高数据加载吞吐效率。

在特殊词元管理方面，模块支持统一维护 BOS、EOS、PAD、UNK 及任务自定义控制词元（如指令起始标记、角色标记等），并提供版本化与冲突检测能力，确保不同模型与任务之间的一致性。在多模态场景下，模块集成图像编码与音频编码能力，例如基于视觉编码模型进行图像特征提取，或基于频谱转换与声学模型进行音频向量化表示，实现跨模态特征对齐与统一嵌入空间构建。

6.1.4.3.1.8 数据调度与采样策略模块

模块负责在模型训练过程中对数据加载、组织与分发进行高效控制，是保障训练吞吐与样本分布均衡性的关键组件。模块支持高性能批量加载机制，通过预取、内存映射与异步 I/O 等技术提升数据读取效率，并结合分布式数据管道框架（如 PyTorch 的 DataLoader 机制）实现可扩展的数据输入流水线。

在样本组织策略上，模块支持动态拼接技术，将不同长度样本在单批内进行高效拼接与填充优化，减少 padding 带来的算力浪费，提升 GPU 利用率；同时实现全局随机打乱，在跨分片、跨文件级别进行样本重排，避免局部数据顺序偏置，增强训练稳定性与泛化能力。在分布式训练场景下，模块支持多进程与多节点同步调度，结合数据并行或混合并行策略，确保各节点样本不重复且分布均衡，并通过统一的随机种子与采样状态管理机制实现可复现训练流程，从而在大规模集群环境中保障训练效率与统计一致性。

6.1.4.3.1.9 在线数据监控模块

在线数据监控模块用于在模型训练过程中对数据流进行实时调控与策略优化，实现数据分布、样本难度与训练阶段之间的动态匹配。模块支持多数据源比例控制，可对不同来源或不同任务类型的数据设置权重与采样占比，避免单一数据源过拟合或分布失衡问题；同时支持重加权采样，根据样本质量分数、类别频次或历史损失值动态调整采样概率，从而优化训练信号结构。

在样本难度管理方面，模块支持难度分级采样与课程学习策略，即根据样本复杂度、模型置信度或损失值对数据进行分层，在训练早期优先使用低难度样本，在模型收敛后逐步引入高难度或长尾样本；同时支持动态混合策略，例如在预热阶段提高通用数据比例、降低高噪声或高复杂度数据占比，以稳定梯度更新过程。此外，模块集成难例挖掘机制，基于实时 loss 统计或误判记录识别高价值样本并提升其采样频率，从而增强模型对边界样本与复杂模式的学习能力。整体模块强调可观测性与可调控性，通过实时指标监控与策略反馈闭环，实现训练数据分布的持续优化与精细化控制。

6.1.4.3.2 多模态对齐与融合训练

多模态对齐与融合训练是安防领域后预训练中的关键环节，其目标是让模型能够同时理解和关联来自不同数据模态的信息，例如监控视频、图像、文本描述以及传感器数据等。安防系统中的数据通常来源多样，例如摄像头画面记录“发生了什么”，报警日志记录“系统检测到了什么”，而人工报告或标签描述“事件含义是什么”。通过多模态对齐训练，模型学习建立这些信息之间的语义对应关系，例如让模型理解“视频中的翻越围栏行为”与文本标签“非法入侵”之间的关联，从而实现跨模态理解。

在训练过程中，通常需要构建成对或成组的跨模态数据样本，例如“视频片段—事件描述”、“图像—行为标签”、“视频—时间序列传感器数据”等。模型通过对比学习、跨模态编码器或共享语义空间等方法，使不同模态的特征能够映射到统一的语义表示空间。这样，当系统接收到新的监控视频时，模型不仅能识别画面内容，还能够自动关联对应的事件语义、风险等级或处置策略，从而提升安防系统的自动化分析能力。

在完成对齐之后，还需要进行多模态融合训练，即在统一语义表示的基础上综合利用多种数据源进行决策。例如，在复杂安防场景中，单一视频信息可能无法完全判断异常行为，而结合视频画面、时间序列轨迹数据以及报警文本信息，模型可以更准确地推断事件类型。通过融合训练，模型能够学习不同模态之间的互补关系，从而提升对复杂场景的理解能力和异常事件识别的准确性。

6.1.4.3.3 时空关系建模

时空关系建模是安防领域多模态智能分析中的重要环节，其核心目标是让模型能够同时理解事件在时间上的演化过程以及在空间上的分布和关联关系。在实际安防场景中，大多数安全事件并不是瞬时

发生的，而是具有明显的时间连续性和空间传播特征。例如，一名可疑人员可能先出现在某个入口摄像头，随后在不同区域摄像头中持续出现；或者某个异常行为（如聚集、追逐、打斗）通常会经历“出现—发展—结束”的时间过程。通过时空关系建模，模型可以学习这些行为变化模式与区域之间的关联路径，从而更准确地理解事件的发展过程。

在技术实现上，时空建模通常需要利用连续视频序列、多摄像头数据以及轨迹信息进行训练。模型可以通过时间序列建模方法（如时序特征编码、序列建模网络等）学习行为在不同时间节点上的变化，同时结合空间信息（如摄像头位置、区域划分或目标轨迹）建立跨区域关联。例如，当系统在一个摄像头中检测到异常行为时，通过学习到的时空关联模式，模型可以预测目标可能出现的下一个区域，并在相关摄像头中进行重点监测，从而实现更高效的联动监控。

在复杂安防环境中，单一摄像头往往只能提供局部信息，而时空关系建模可以将多个摄像头的观测信息整合成完整的事件轨迹。通过这种方式，系统不仅能够识别当前发生的异常行为，还能够进行事件追踪、行为预测和风险预警。例如，在人员密集场所，模型可以通过时空数据分析人员流动趋势，提前识别潜在的拥挤或安全风险，从而为安防决策提供更加全面和前瞻性的支持。

6.1.4.3.4 事件语义与知识注入

将安防领域的规则、事件类型和业务知识（如入侵、打架、遗留物、非法闯入等）融入训练数据或知识库，通过持续训练让模型掌握安防事件语义结构和业务逻辑，提高事件理解与风险识别能力。

6.1.4.3.5 长尾与异常场景强化

安防场景中很多关键事件（如突发事故、异常行为）属于低频长

尾事件。后预训练需要通过：数据增强、合成数据、异常样本扩展等技术强化模型对罕见事件和异常行为的识别能力。

6.1.4.3.6 安全与隐私约束训练

由于安防数据涉及个人隐私与敏感信息，后预训练阶段需要加入数据脱敏、隐私保护训练策略以及安全约束机制，确保模型在使用过程中符合数据安全和合规要求。

6.1.4.4 安防行业大模型

本项目在基础大模型之上，通过学习海量的安防知识、危险事件、地理信息、地理标识、人员图像、车辆图像、人员轨迹、车辆轨迹等数据，预训练安防行业 L1 大模型。该模型采用混合专家模型的方法，根据输入的不同动态地选择最合适的“专家”模型进行处理，具有**全要素解析、行为事件监测、情景理解、线索分析研判、图像重建**等能力，从而在公共安全、社会治理、行业融合等领域发挥重要作用。该模型将发布两种版本：**公安版和社会安防版**，其中公安版采用全量数据进行训练，主要服务于公安各警种；社会安防版使用去除公安敏感内容的数据进行训练，主要服务于社会安防。

6.1.4.4.1 安防行业大模型应具备的能力

从安防行业的应用需求出发，本项目根据目前已有的安防应用结合未来安防对智能的需求，将安防行业 L1 大模型的能力归纳融合。不同于 L0 大模型的基础能力，安防行业 L1 大模型在兼顾大模型的通用性的基础上，更注重安防行业的实际业务需求。具体能力描述如下：

1、全要素解析

全要素解析是安防行业大模型的基础能力之一，主要针对图像、视频、文本和音频等单模态数据进行深入解析。通过单模态判别式能力（例如视图模态的分类、检测、分割和跟踪等）对输入数据进行细

致的解析和理解。通过高效的图像分类算法，能够识别和分类监控摄像头捕获的不同对象（如车辆、行人等），实现海量监控图像的实时处理，快速识别关注目标。

2、行为事件监测

行为事件监测能力主要用于监测和识别图像、视频、文本和音频中的行为和事件。利用大模型的多模态判别式能力（如图文结合的分类、图音结合的分类等）实现对复杂行为和事件的精准监测，例如在公共安全监控中通过监控视频和现场描述文本的结合，更准确地识别出可疑行为。

3、情景理解

基于多模态的情景理解能力用于处理和理解图像、视频、文本等多种数据类型，利用大模型的多模态检索和图生文等能力，提供更深入的内容理解和关联。多模态检索是多模态情景理解的重要应用之一，通过输入图像或文本进行相关信息的搜索和匹配，例如在刑侦案件中，通过输入犯罪嫌疑人的照片，检索出监控系统中的相关图像和视频，帮助快速定位嫌疑人。

4、线索分析研判

线索分析研判能力通过整合表格数值、图像、文本和视频数据，利用多模态文本生成和多模态判别式能力进行综合分析和研判。在案件调查中，线索分析研判能力可以通过分析犯罪现场的图像、监控视频、相关文件和数据表格，生成详细的分析报告。例如，在一起盗窃案件中，通过分析监控视频中的嫌疑人行为、现场拍摄的图像和相关证据文件，综合推断出嫌疑人的行动轨迹和作案手段，帮助警方快速破案。

5、图像重建

图像重建能力通过处理图像和文本输入，利用多模态图文生成能力，实现图像的重建和生成。在监控图像不清晰或部分缺失时，图像重建技术可以恢复图像细节，提高图像的质量和可用性。例如，在交通事故中，通过对模糊的事故现场图像进行重建，可以清晰地还原事故发生的细节，帮助调查人员分析事故原因。

图生图技术可以根据输入图像生成新的图像，例如在失踪人员搜索中，通过分析失踪人员的旧照片，可以生成其当前的可能样貌，帮助搜索和定位。文生图技术还可以根据文本描述生成对应的图像，在安防应用中具有重要意义。

根据上述这些行业共性能力，项目组整理了各能力的任务类型及简单描述，详见表97。

表 102 行业大模型任务

安防行业大模型能力	输入类型	支撑的模型	任务描述
全要素解析	图像/视频/音频/文本单模态输入	安防多模态表征大模型	主要针对单模态的传统任务：图形模态的检测、分割、识别等任务，实现人、车、物目标细分类别或属性搜索；视频模态的跟踪任务；音频模态的检测、分类、识别等任务。
行为事件监测	图像/视频/音频	安防多模态理解大模型	图像、图像序列和音频序列是否存在关注的行为事件及类别。
情景理解	图像/视频/音频	安防多模态理解大模型	图像/音频模态向文本模态的转换；对音频/图像/视频等模型做摘要等。
线索分析研判	图像/视频/文本/音频	安防多模态理解大模型+安防多模态时空推理大模型	关键信息提取；人员/车辆轨迹分析；因果关系推理；关联分析等。
图像重建	文本/图像	安防多模态生成	根据文本和低质量图片复原人

		大模型	脸或关键目标的图片。
--	--	-----	------------

6.1.4.4.2 安防多模态表征大模型

训练融合安防行业数据模态，在统一或对齐的语义空间中，对图像、文本、语音、视频等多种模态进行编码，并输出可用于检索、匹配、分类、推理等任务的高质量特征的大规模模型。




图 125 行业多模态表征大模型

针对安防主要关注的对象（人、车）及通用要素，构建专有的视觉特征提取器，针对通用对象构建通用视觉识别模型，这些模型分别用于提取不同目标的视觉特征，用于安防场景中的检索行业应用中。

训练整体采用由粗到细、由通用到行业的三阶段策略，避免一次性端到端训练带来的不稳定与过拟合。

阶段一：多模态对齐预训练。行业数据往往存在模态分布不一致、语义表达不统一以及标注噪声较大的问题，如果直接进行多模态深度融合训练，模型容易在早期陷入局部最优甚至出现模态塌缩。通过对比学习的方式，可以在不引入复杂交互结构的前提下，先行建立不同

模态之间稳定、可度量的共享语义空间，使文本、图像等模态在向量层面具备统一的语义尺度。该阶段的核心优势在于训练稳定性高、对数据规模和标注质量要求相对可控，并且能够天然适配大规模负样本，有效提升检索场景下的全局召回能力。在具体方法上，通常采用双塔结构分别对不同模态进行编码，并通过对比损失函数（如 InfoNCE 或 CLIP Loss）拉近语义相关样本在向量空间中的距离，同时推远不相关样本。结合行业查询文本或查询图像对数据，并引入难负样本挖掘机制，可以在该阶段完成行业语义的初步对齐，为后续复杂融合训练奠定基础。

第二阶段：多模态融合训练。重点提升对复杂行业检索意图和细粒度语义关系的建模能力。仅依赖对比训练得到的独立编码向量，模型更擅长处理粗粒度相关性判断，但在面对包含多约束条件、隐含逻辑关系或细节判别要求的行业查询时，往往难以区分高相似但业务含义不同的候选结果。多模态融合训练通过引入跨模态交互结构，使模型能够在词元级或区域级层面建模不同模态之间的细粒度对齐关系，从而显著提升排序精度和业务可用性。该阶段的优势在于能够充分利用行业数据中的结构化信息和上下文关联，增强模型对复杂场景的理解能力，尤其适合用于 Top-K 精排或高价值检索场景。在训练方法上，通常在对比训练得到的编码器基础上，引入 Cross-Encoder 或多模态 Transformer 结构，对文本、图像（或其他模态）进行联合建模，并采用相关性分类或排序损失进行监督训练。该阶段训练规模相对可控，主要作用于候选集层面，从而在保证整体系统性能的同时，显著提升最终检索结果的精度与可信度。

6.1.4.4.3 安防多模态理解大模型

针对模型的风险识别能力，基于已训练完成的安防行业多模态检

索模型，进一步构建多模态理解模型，从“相关内容召回”向“可理解”的关键升级路径。该模型不再局限于静态相似度匹配，而是以多模态语义表示为基础，将用户查询视为一个需要被解析、推断和逐步收敛的理解任务，从而支持复杂业务场景下的多条件检索与事件理解。通过将检索模型产生语义相关的高质量候选结果作为推理输入，多模态理解模型能够在保持高召回效率的同时，引入更强的语义组合和逻辑建模能力，实现校园周边和车站等重点区域打架斗殴、未成年聚集等异常行为事件实时识别发现。

以已训练完成的多模态检索模型作为能力基座。检索模型在该阶段保持冻结或半冻结状态，仅负责为推理模型提供高质量、多样化的候选多模态内容及其向量表示。推理模型的核心目标并非学习“如何找到相关内容”，而是学习“如何在相关内容的基础上进行理解与推断”。为提升模型在真实搜索场景中的鲁棒性和泛化能力，训练过程中通常引入课程学习与难例驱动训练机制。同时，利用检索模型不断生成具有挑战性的候选集作为训练输入，使推理模型在“相似但不等价”的多模态内容中学习精细区分能力。这种逐步加深难度的训练模式，有助于模型形成稳定且可解释的推理行为。

在应用技术形态上，多模态理解模型采用“检索增强推理”的设计范式，将多模态检索模型作为前置能力模块，与具备推理能力的多模态大模型进行解耦式集成。这种架构一方面充分复用已有的向量检索和索引体系，避免端到端超大模型带来的高成本与不可控风险；另一方面通过理解模型对候选结果进行跨模态联合理解和上下文建模，实现对图像、文本及其关系的深层语义推断。该设计在当前多模态大模型体系中具有明显的先进性，同时在工程实现上具备良好的模块化特征，便于独立优化与迭代升级。

6.1.4.4.4 安防多模态时空推理大模型

针对城市安全治理的能力，在多模态搜索推理大模型的基础上，引入时间与空间维度信息，进一步构建多模态时空推理大模型，是实现复杂现实场景智能理解与决策的关键升级。该模型将时间序列、空间位置与多模态感知信息进行统一建模，使搜索与推理能力从静态语义匹配扩展至动态时空演化分析。通过将文本、图像、视频等多模态信息与时间戳、地理坐标等时空要素进行联合编码，模型能够理解事件在不同时间和空间尺度上的发生规律，为跨时段、跨区域的综合推理提供坚实基础。

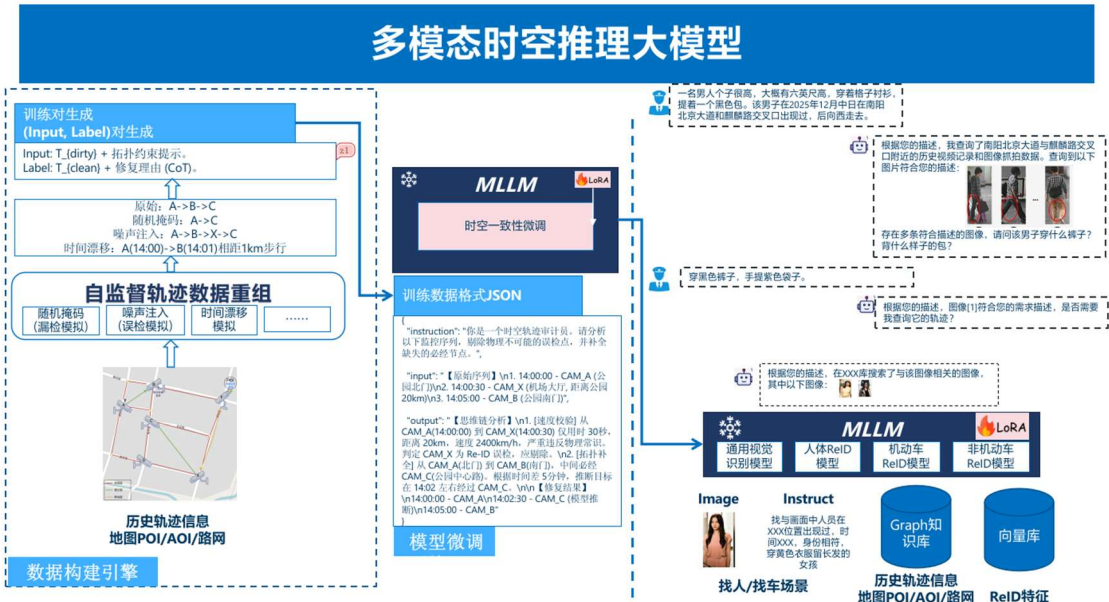


图 126 行业多模态时空推理大模型

多模态时空推理大模型以地图数据为核心空间载体，将 POI 和 ROI 作为高层语义锚点，构建结构化的时空语义表示体系。地图拓扑、道路网络、区域边界等信息被编码为空间约束，与多模态搜索推理模型输出的候选内容进行对齐，从而使模型能够在推理过程中显式感知“在哪里发生、与周边环境的关系以及空间可达性”等关键因素。同时，

通过对 POI 和 ROI 的行业属性、功能标签及历史行为特征进行建模，模型不仅能够理解单点位置的语义，还能够在区域尺度上进行聚合分析和关联推断，显著提升复杂场景下的推理准确性与可解释性。

6.1.4.4.5 安防多模态生成大模型

安防多模态生成大模型指能够在文本、图像、语音等多种模态之间进行条件生成与跨模态生成的统一大规模模型体系，面向安防行业场景构建端到端生成能力。该类模型通常以统一 Transformer 主干或多模态融合架构为核心，通过共享语义嵌入空间实现跨模态对齐，使模型既能够完成“文本生成图像”“文本生成语音”，也能够完成“图像生成语音描述”“语音生成图像内容”等跨模态生成任务，实现多模态输入与多模态输出的灵活组合。

在技术实现层面，可结合扩散模型与自回归生成框架，例如参考 Stable Diffusion 的条件扩散生成机制实现高质量图像生成，结合语音生成模型如 VALL-E 实现高保真语音合成，同时借鉴大语言模型架构进行跨模态条件建模与指令控制。针对行业应用，可通过领域数据微调与对齐训练，使模型具备行业术语理解、风格控制与专业内容生成能力。整体目标是构建一个统一参数空间、统一调度接口、统一训练范式的大规模多模态生成系统，降低系统复杂度，同时提升跨模态生成质量与可扩展性。

6.1.4.4.6 融合模型

通过多模态融合专家模块，将音频、视觉和语言等做特征融合，结合多个任务一起做模型预训练，通过不同专家的协作，完成下游任务学习，满足各种业务场景需求。

6.1.4.5 场景微调

6.1.4.5.1 低秩适配微调

当在通用安防场景任务中，当计算资源有限时，一般使用低秩微调技术可以显著降低内存和计算需求同时也可以提高微调效率。非常适合需要频繁更新参数或调整模型以适应不同任务的场景。




图 127 低秩适配微调示意图

大模型中包含大量的线性变换层，其中参数矩阵的维度通常很高。模型在针对特定任务进行适配时，参数矩阵往往是过参数化的，其存在一个较低的内在秩。为了解决这一问题，LoRA 提出在预训练模型的参数矩阵上添加低秩分解矩阵来近似每层的参数更新，从而减少适配下游任务所需要训练的参数。给定一个参数矩阵 W ，其更新过程可以一般性地表达为以下形式：

$$W = W_0 + \Delta W$$

其中， W_0 是原始参数矩阵， ΔW 是更新的梯度矩阵。LoRA 的基本思想是冻结原始矩阵 $W_0 \in \mathbb{R}^{H \times H}$ 通过低秩分解矩阵 $A \in \mathbb{R}^{H \times R}$ 和 $B \in \mathbb{R}^{H \times R}$ 来近似参数更新矩阵 $\Delta W = A \cdot B^T$ 。

$\Delta W = A \cdot B^T$ 其中 $R \ll H$ 是减小后的秩。在微调期间，原始的矩阵参数 W_0 不会被更新，低秩分解矩阵 A 和 B 则是可训练参数用于适配下游任务。在前向传播过程中，原始计算中间状态 $h = W_0 \cdot x$ 的公式修改

为：

$$h = W_0 \cdot x + A \cdot B^T \cdot x$$

在训练完成后，进一步将原始参数矩阵 W_0 和训练得到的权重 A 和 B 进行合并： $W = W_0 + A \cdot B^T$ ，得到更新后的参数矩阵。因此，LoRA微调得到的模型在解码过程中不会增加额外的开销。

6.1.4.5.2 适配器微调

适配器微调的目标是在特定场景任务中能够获得更好的性能，向模型添加部分额外的参数。这些附加参数被编码为简单的模块，以指导模型适应目标领域或场景任务。添加模块最佳位置的特点通常是参数数量较小且简单，可扩展到特定场景任务上进行连续训练时具有灵活性。在一些简单的检测识别场景下，根据人工标注的少样本图片，可以快速适应应用的需求。




图 128 适配器微调示意图

适配器微调在 Transformer 模型中引入了小型神经网络模块（称为适配器）。为了实现适配器模块，使用瓶颈网络架构：首先将原始的特征向量压缩到较低维度，然后使用激活函数进行非线性变换，最后再将其恢复到原始维度。上述过程，可以通过以下公式进行表达：

$$h = h + \sigma(h \cdot W^d) \cdot W^u$$

通常来说，适配器模块将会被集成到 Transformer 架构的每一层中，使用串行的方式分别插入在多头注意力层和前馈网络层之后、层归一化之前。在微调过程中，适配器模块将根据特定的任务目标进行优化，而原始的语言模型参数在这个过程中保持不变，从而在微调过程中有效减少需要训练参数的数量。图131展示了适配器微调算法的示意图。

6.1.4.5.3 前缀微调

前缀微调在数据量以及计算资源有限时更具有高效性以及灵活性，可以更好的适配特定场景。前缀微调在模型的每个多头注意力层中都添加了一组前缀参数。这些前缀参数组成了一个可训练连续矩阵，可以视为若干虚拟词元的嵌入向量。适合多任务的应用场景，例如各种行为事件分类任务，可以为不同任务训练不同的前缀，实现一个模型处理多个任务。进而可以为不同用户或场景训练特定的前缀，实现模型输出的个性化。




图 129 前缀微调示意图

在具体实现上，基于原始的注意力计算公式，一系列前缀词元被拼接到每个注意力的键向量与值向量之前，每个头的计算公式可以表示如下：

$$head = Attention(XW^Q, P^K \oplus XW^K, P^V \oplus XW^K)$$

其中 $Attention$ 代表原始的注意力操作， $\oplus$ 表示矩阵拼接， $P^K, P^V \in R^{L \times H}$ ， L 代表前缀向量的长度（一般在10到100之间），可以根据任务场景进行调整。为了更好地优化前缀向量，研究者提出了一种重参数化技巧，即引入一个多层感知机的映射函数 $P = MLP_{\theta}(P')$ 。重参数化技巧可以将较小的矩阵映射到前缀参数矩阵，而不是直接优化前缀，这对于稳定训练很有帮助。经过优化后，映射函数将被舍弃，只保留最终得到的前缀参数 P 来增强特定任务的性能。在前缀微调过程中，整个模型中只有前缀参数会被训练，因此可以实现参数高效的模型优化。

6.1.4.5.4 提示微调

与前缀微调不同，提示微调仅在输入嵌入层中加入可训练的提示向量。在需要同一模型处理多个不同任务的场景中，可以为每个任务设计不同的提示，从而在不改变模型结构的情况下，适应多种任务。在离散提示方法的基础上，提示微调首先在输入文本端插入一组连续嵌入数值的提示词元，这些提示词元可以以自由形式或前缀形式来增强输入文本，用于解决特定的下游任务。该技术在文本生成、摘要、翻译等 NLP 任务中表现出色。通过修改输入提示，可以快速适应不同的语言语音任务和场景。对于模型更新较频繁的场景，可以在不改变原始模型参数的情况下，通过更新提示来适应新的需求或修复问题。该技术还可以与 RAG 技术结合，提高模型在特定领域的表现。




图 130 提示调优示意图

在具体实现中，只需将可学习的特定任务提示向量与输入文本向量结合起来一起输入到语言模型中即可。在提示微调的训练过程中，只有提示的嵌入向量会根据特定任务进行监督学习，然而由于只在输入层中包含了极少量的可训练参数，该方法的性能高度依赖底层语言模型的能力。图133展示了提示微调算法的示意图。

6.1.4.6 专业场景模型

6.1.4.6.1 智慧图侦

6.1.4.6.1.1 图侦多模态表征模型

该模型承担高质量视觉特征生成的作用，为图侦应用中的关键要素识别与检索任务提供通用表征能力支撑。在功能层面，模型通过自监督或对比学习方式生成高判别性向量特征，支持目标检索、相似度匹配、零样本分类、跨域迁移等能力，可应用于人脸识别、人体识别、车辆识别及聚类分析等模块的底层特征支撑引擎。

6.1.4.6.1.2 图侦多模态理解模型

该模型定位于风险识别与异常预警核心，承担对非正常行为或异常模式进行自动识别与告警的作用，是安全管理与风险控制体系的重要组成部分。在功能层面，模型基于时序建模与行为表征分析能力，实现对异常行为、异常轨迹、异常状态变化等情况的自动检测，并输

出异常等级与事件类型，为图侦系统提供实时预警能力。

6.1.4.6.1.3 图侦多模态时空推理模型

该模型承担对多源数据进行融合分析与时空推理的作用，实现跨维度、跨时间尺度的综合判断能力。在功能层面，模型融合视频数据、结构化轨迹数据、摄像机数据、地图数据及文本规则信息等，进行时空关系建模，对关注的人车物等目标进行轨迹研判和预测，为图侦业务提供线索支撑和分析能力。

6.1.4.6.1.4 图侦多模态生成模型

该模型可通过模糊图像高清修复、证人描述合成画像、失踪人员跨龄样貌推演、案发现场与物证重建等方式，为公安图侦提供关键线索与技术支撑，大幅提升破案效率与精准度，同时可用于深度伪造检测防范风险，是公安智能化办案的重要辅助工具。

6.1.4.6.1.5 图侦模型融合

融合上述的多模态系列模型与图侦专业模型，如：人脸识别模型、人体识别模型、结构化模型等。实现人/车/物目标细分类别或属性搜索、语义搜点位、语义搜目标、视频自动巡检、关注人离开属地分析、关注人居住地变更分析、关注人长期不出现监测、关注人前往某地监测、落脚点分析、特定人员徘徊监测、目标轨迹融合分析、人群聚集监测、持刀持械监测、案件线索研判分析、关系人分析、团伙分析、骨干挖掘分析、打架斗殴监测、危险可疑物品监测、刻意躲避抓拍分析、套牌车分析、车辆徘徊监测、图像超分辨率重建等智能研判预警等智慧图侦服务能力，支撑公安大数据智能化平台建设。

6.1.4.6.2 智慧交管

6.1.4.6.2.1 交管多模态表征模型

多模态表征模型主要承担交通数据融合与统一特征表达的基础能力角色。通过将来自不同感知系统和业务系统的数据进行语义对齐和特征编码，模型能够建立统一的交通场景表示，为交通事件识别、行为分析和态势研判提供可靠的数据基础。多模态表征模型能够支持多种交管应用场景，包括交通目标检索、跨摄像头车辆关联、交通事件分析以及交通态势感知等。例如，在交通目标检索场景中，系统可以通过文本描述或车辆特征快速检索相关车辆；在交通态势分析中，模型可结合视频检测结果与交通流统计数据，对道路拥堵、异常交通行为或事故风险进行综合分析。

6.1.4.6.2.2 交管多模态理解模型

本模型定位于交通场景的语义理解与综合分析核心，承担将底层感知数据上升至场景级语义解释的作用，实现复杂交通场景的结构化理解。模型能够对交通场景进行整体语义建模，理解车辆与行人之间的关系、交通规则约束及场景动态变化，支持场景描述、行为解释、规则合规判断及多轮交互问答，为交通指挥调度与智能决策系统提供认知级能力支持。

6.1.4.6.2.3 交管多模态时空推理模型

本模型定位于交通系统的高级决策与趋势研判核心，承担对多源数据进行融合分析与时空推理的作用，实现跨维度、跨时间尺度的综合判断能力。模型融合视频数据、结构化轨迹数据、交通流量数据及文本规则信息，进行时空关系建模与趋势预测，可支持拥堵演化预测、风险扩散分析、交通态势研判及辅助决策生成，为智慧交通系统提供战略级智能分析能力。

6.1.4.6.2.4 交管多模态生成模型

该模型主要承担交通场景可视化表达与智能交互能力构建的角

色。通过对交通数据进行生成式建模，系统可以将复杂的交通监控数据、事件信息和运行状态以更加直观和可理解的方式呈现给管理人员或公众，同时为交通管理提供更丰富的仿真分析和辅助决策手段。

在图像生成方面，模型可以基于交通数据生成交通态势可视化图、事故场景模拟图以及交通流变化示意图，用于交通规划分析、事故复盘和应急演练；同时还可以通过数据增强生成多样化交通场景样本，用于提升交通检测与识别模型的训练效果。在音频生成方面，模型可以实现交通信息语音播报、智能语音提示以及应急广播生成，例如自动生成道路拥堵提示、交通管制信息播报和事故预警语音，提高交通信息发布的效率与覆盖范围。

6.1.4.6.2.5 交管模型融合

融合上述交管多模态系列模型与交管专业模型，如：车牌识别、车辆识别、车型识别、车辆跟踪、车辆检测等。实现重点车辆管控监测、交通态势感知、交通事件隐患监测、非法运营车监测、摩托车飙车监测、渣土车违规监测、大型货运车违规监测、机动车违法监测、机动车驾驶员异常行为监测、非机动车带人监测、摩电不戴头盔监测、非机动车逆行监测、非法停车监测、车辆超长期停放监测等场景应用，提升非现场执法能力、交通事故预警与处置能力，进一步加强交通管理的智能化、精细化升级，提高交通管理效率和公众出行体验，促进城市交通的智慧化发展。

6.1.4.6.3 平安城市

6.1.4.6.3.1 城市多模态表征模型

多模态表征模型主要承担城市多源数据融合与统一特征表达的基础能力角色。通过对来自视频监控系统、物联网设备及公共服务平台的数据进行统一编码与语义对齐，模型能够构建统一的城市安全信

息表达体系，实现不同系统之间的数据关联与信息互通。多模态表征模型可支持多种平安城市应用场景。例如，在目标检索与跨摄像头关联方面，模型能够通过图像、文本描述或行为特征实现人员与车辆的快速检索与匹配；在事件分析与风险识别方面，模型可以结合视频检测结果、轨迹数据及历史案件信息，对异常行为、可疑活动或潜在风险进行综合分析等。

6.1.4.6.3.2 城市多模态理解模型

多模态理解模型可支持多种平安城市应用场景。例如，在复杂事件理解与识别方面，模型能够结合视频画面、行为特征和警情文本信息，对异常行为、冲突事件、聚集事件等进行综合判定；在目标行为分析方面，模型可以通过融合视觉信息与轨迹数据，对人员或车辆的行为模式进行语义分析；在城市安全态势分析方面，模型可对多源信息进行综合理解，形成城市安全态势分析报告和风险提示，为指挥调度与应急处置提供智能辅助支持。

6.1.4.6.3.3 城市多模态时空推理模型

时空推理模型通过对时间维度与空间维度数据进行联合建模与关联分析，实现对城市事件演化过程、目标活动轨迹以及区域安全态势的综合推理能力。在平安城市建设中，该类模型能够将视频监控数据、人员车辆轨迹数据及地理信息数据进行统一时空关联分析，从而提升城市安全系统对复杂事件的研判能力和趋势预测能力。例如，在事件轨迹还原方面，模型能够结合多摄像头数据与轨迹信息，对人员或车辆的活动路径进行时空关联与完整还原；在重点目标追踪方面，模型可以通过时空关系分析实现跨区域目标关联与活动范围分析。

6.1.4.6.3.4 城市多模态生成模型

通过生成合成数据，可对监控图像和声音样本进行数据增强，弥

补真实异常事件（如事故、犯罪或枪声等）数据不足的问题，从而提高目标检测、行为识别和声音事件识别模型的训练效果。同时，生成模型还能用于城市监控视频的图像修复与超分辨率提升，改善低光或低清视频质量，并通过构建虚拟城市场景和数字孪生环境实现应急演练与安全风险仿真。

6.1.4.6.3.5 城市模型融合

融合上述多模态系列模型与平安城市已建设专业模型，实现城市治理各方面的工作中进行全方位、智能化的管理，一是实现对城市安全风险的监测预警，如烟火检测、路面积水、路面塌陷、井盖丢失、打架斗殴、持刀持械预警、盗抢行为、人员异常聚集、标语横幅、渣土车安全、广告牌掉落、人员溺水等风险；二是实现对城市管理市容市貌的智能监测预警，如破坏公共设施、违规占道经营、公共场所吸烟、垃圾管理、摆摊经营、广告牌破损等行为。通过智慧安防赋能，提升城市安全水平、综合管理水平，促进城市的智慧化建设，实现城市更高效、智能的安全管理和社会治理。

6.1.4.6.4 平安社区

6.1.4.6.4.1 社区多模态表征模型

多模态表征模型在平安社区中的核心价值在于通过跨模态信息融合构建更完整的场景语义表示，从而提升社区安全监控、异常检测和应急响应的智能化水平。与城市道路等开放场景不同，社区中的人员、车辆具有较高的重复出现率。例如同一住户每天出入小区、固定车辆停放在同一车位。因此检索系统需要更加关注长期身份关联与轨迹检索，通常依赖行人重识别。同时，社区场景通常是半封闭空间（小区入口、楼道、电梯、停车场等），空间范围较小，但包含大量细粒度语义关系。

6.1.4.6.4.2 社区多模态理解模型

本模块定位于社区风险识别与安全预警核心，实现对社区安全事件的实时感知、行为识别与智能预警。在功能层面，模型基于行为模式建模与场景规则匹配，实现对异常行为检测、人员身份识别、车辆管理、火灾烟雾识别、老人跌倒检测以及高空抛物、电动车进楼等安全事件监测，并输出事件类型、时间、位置及关联目标信息，为社区安防与物业管理提供及时处置依据。

6.1.4.6.4.3 社区多模态时空推理模型

多模态时空推理模型在平安社区治理中的应用，主要通过融合视频监控、物联网传感器、门禁记录、人员轨迹、警情文本及地理信息等多源数据，对社区内的人、车、事件和空间环境进行统一建模，并结合时间序列与空间关系进行智能推理，实现对社区安全态势的实时感知、异常行为识别和风险事件预测。例如，模型能够通过跨摄像头轨迹关联、行为时序分析和多模态信息融合，识别异常聚集、可疑徘徊或潜在安全隐患，并结合历史事件与环境因素对治安、火灾等风险进行提前预警，从而为社区管理部门提供智能化决策支持和快速应急响应能力。相比通用场景中的多模态应用侧重于内容理解、信息生成或通用推理，平安社区场景更加突出对强时空约束数据的分析能力，强调实时性、可靠性和可解释性，其核心作用在于提升基层社会治理的精细化与智能化水平，通过数据驱动实现对社区安全风险早发现、早研判和早处置，最终提高社区公共安全管理效率和居民生活环境的安全保障水平。

6.1.4.6.4.4 社区多模态生成模型

本模型可辅助提升应用性能。图像生成模型可用于模拟异常场景（如火灾、打架、入侵等），生成多样化训练数据，提升监控识别算

法对复杂环境的适应能力；同时还能对低清监控画面进行超分辨率重建或补全，提高取证与识别效率。音频生成模型则可模拟求救声、玻璃破碎声、异常喊叫等事件声音，用于训练声学异常检测系统，并在社区广播、智能客服中生成自然语音，实现应急提示与信息发布。

6.1.4.6.4.5 社区模型融合

平安社区中的多模态理解模型通常采用专用模型与规则系统相结合的方式，在保证识别准确率与系统可靠性的同时，实现对社区安全事件的高效感知与智能化管理。一是辅助开展社区人员、车辆安全管理工作，包括人员、车辆安全管理，支持实有人口管理、常口流口人员管理、关注人群管理等工作；二是实现危险预警能力，包括堵塞消防通道监测、烟雾火灾监测、电动车入楼监测、车辆盗抢等；三是加强对社区日常管理，包括工作人员睡岗脱岗监测、社区老幼守护、邻里纠纷监测、不文明养犬行为监测、垃圾异常堆放监测、垃圾桶溢满监测等。通过新智慧安防和社区的融合应用，为构建基层公共安全新格局提供有效支撑。

6.1.4.6.5 平安校园

6.1.4.6.5.1 校园多模态表征模型

多模态表征模型在校园场景中的差异性主要体现在：时间序列明显、实体关系固定、场景重复性高等。多模态表征模型是能够融合文本、图像、语音、视频等多种数据形式并进行统一语义表示与理解的人工智能模型。在校园场景中，这类模型主要用于提升教学管理、校园安全和学习分析等方面的智能化水平。例如，在智慧课堂中，通过融合课堂视频、教师语音和教学文本，可以分析课堂互动情况、学生注意力和教学效果；在校园安全管理中，结合监控视频、行为识别和门禁数据，可以实现异常行为检测和安全预警。

6.1.4.6.5.2 校园多模态理解模型

本模型定位于校园精细化行为感知与安全防护体系中的动作识别核心，承担对校园场景中个体及群体行为进行细粒度识别与动态分析的作用，是实现异常预警与行为研判的重要基础能力。在功能层面，模型基于人体关键点检测与时序动作建模技术，对奔跑、打闹、推搡、摔倒、攀爬、尾随、长时间滞留等动作进行识别与分类，并结合行为持续时间、频率及空间位置进行综合判定；同时支持异常动作模式分析与风险等级评估，可为校园安全管理、课间秩序维护及重点区域风险防控提供实时、结构化的行为数据支撑。

6.1.4.6.5.3 校园多模态时空推理模型

在校园场景中，这类模型的应用具有明显的环境和任务特征。首先，场景结构稳定且空间关系明确。校园由教学楼、宿舍、图书馆、操场等固定区域组成，人员活动路径和时间规律较为稳定。因此，多模态时空推理模型可以结合视频监控、门禁记录、位置数据等信息，对人员活动进行连续时空建模，例如识别学生在不同地点之间的行为轨迹或课堂出勤情况。其次，行为分析具有明显的时间序列特征。校园活动通常按照课程安排、作息时间等规律进行，模型在推理时需要考虑行为的连续性与顺序关系。例如在智慧课堂中，通过融合课堂视频、教师语音和学生动作数据，可以分析课堂互动过程、学习参与度以及教学节奏，从而实现对课堂行为的时序理解。

6.1.4.6.5.4 校园多模态生成模型

生成多样化训练数据，提升监控识别算法对复杂环境的适应能力；同时还能对低清监控画面进行超分辨率重建或补全，提高取证与识别效率。

6.1.4.6.5.5 校园模型融合

融合上述多模态系列模型与平安城市已建设专业模型，实现对校园周边可疑人员的识别和管理；对校园进行安全监测预警，如宿舍着火、实验室烟雾、食堂烟雾火灾监测、电瓶车安全风险等；对异常行为的预警，如打架斗殴、持刀持械、非法聚集、异常标语、校园霸凌行为、学生进入危险区域风险监测、踩踏事件预防和分析等；对校园日常管理起到辅助作用，如食堂的卫生和环境监测、保安脱岗/睡岗监测、设施设备损坏监测等。通过智慧安防赋能校园安全，完善校园安全防控体系，综合提升校园安全管理水平，构建安全、和谐稳定的校园环境。

6.1.4.6.6 平安园区

6.1.4.6.6.1 园区多模态表征模型

多模态表征模型在园区场景中的核心作用，是将来自视频监控、物联网传感器、门禁系统、设备日志、文本记录等多源异构数据进行统一语义建模，从而实现对园区人员、车辆、设备、环境与事件的综合理解与联动决策。与通用场景中的多模态表征应用相比，园区场景更强调场景结构化、实体关系稳定以及实时运行闭环：模型不仅需要融合多模态信息，还要结合园区空间拓扑、业务流程和设备状态形成可执行的事件理解与管理能力。

6.1.4.6.6.2 园区多模态理解模型

本模型定位于园区综合治理与安全保障体系中的风险识别核心，承担对园区场景中异常行为、违规操作及突发事件进行自动检测与分级预警的作用，是实现园区安全运行与高效管理的重要技术支撑。在功能层面，模型基于视频时序分析与行为模式建模能力，对异常聚集、非法闯入、越界入侵、危险作业行为、长时间滞留、设备异常操作及突发冲突等情况进行识别与分类，并输出事件类型、发生时间、空间

位置及关联目标信息；同时支持异常等级评估与联动响应机制，可与安防平台、门禁系统及应急处置流程对接，为园区安全管控与运营管理提供实时、精准、可追溯的智能预警能力。

6.1.4.6.6.3 园区多模态时空推理模型

多模态时空推理模型在园区场景中的作用，是对视频、物联网传感器、门禁记录、车辆轨迹、设备状态及文本事件等多源数据进行跨模态融合，并结合时间序列与空间拓扑关系进行持续推理，从而实现园区内人员活动、车辆流动、设备运行及异常事件的动态理解、预测与联动处置。与通用场景中的多模态推理（如开放环境的视频理解或跨模态问答）相比，园区应用更强调强约束的物理空间结构、持续的时间演化以及明确的运营目标：模型需要基于园区的区域划分、路径网络和业务规则进行因果与轨迹推断，重点解决事件演化判断、跨系统关联分析和实时决策支持问题，因此其核心区别在于从“内容理解型推理”转向面向实体关系与时空行为演化的业务驱动型推理。

6.1.4.6.6.4 园区多模态生成模型

生成多样化训练数据，提升监控识别算法对复杂环境的适应能力；同时还能对低清监控画面进行超分辨率重建或补全，提高取证与识别效率。

6.1.4.6.6.5 园区模型融合

融合多模态系列模型与园区已建专业模型，一是实现园区人员车辆管控，包括员工考勤、访客管理、陌生人员徘徊、车辆违停、危化品车辆监管等；二是构建安全风险预警体系，覆盖消防通道堵塞、烟雾火灾、危险区域闯入、未佩戴安全装备等监测；三是提升日常管理水平，包括安保脱岗睡岗监测、周界入侵、物资防盗、设备故障监测等。通过智慧安防赋能园区数字化管理，全面提升安全防范能力与运

营效率，构建安全、高效的现代化园区环境。

6.1.4.6.7 平安乡村

6.1.4.6.7.1 乡村多模态表征模型

本模型定位于乡村数字化治理体系中的基础感知核心，承担对乡村场景图像与视频数据进行全要素结构化解析的作用，是后续行为分析、事件识别与资源管理应用的底层数据支撑。在功能层面，模型支持对人员、车辆、农机设备、牲畜、道路、农田、水体、房屋建筑及公共设施等要素进行检测与分类，并输出目标类别、空间位置及基础属性信息；同时可适应乡村环境中复杂光照、开放场景与多样化目标形态，实现乡村视图的全面数字化表达，为乡村安全治理、农业生产监管及公共资源管理提供标准化视觉数据基础。

6.1.4.6.7.2 乡村多模态理解模型

本模型定位于乡村安全治理与风险防控体系中的智能预警核心，承担对乡村场景中异常行为与突发事件进行自动识别、实时研判与分级告警的作用，是提升基层治理数字化与精细化水平的重要技术支撑。在功能层面，模型基于视频时序建模与场景规则匹配能力，对非法闯入、盗窃行为、夜间异常活动、异常聚集、秸秆违规焚烧、牲畜异常集散、河道异常作业等情况进行识别与分类，并输出事件类型、发生时间、空间位置及关联目标信息；同时支持异常等级评估与联动处置机制，可与村级综治平台及应急响应流程对接，为乡村公共安全、生态保护及社会治理提供及时、精准、可追溯的智能预警能力。

6.1.4.6.7.3 乡村多模态时空推理模型

模型需对乡村区域中的人员活动、车辆流动、异常事件与环境变化进行持续理解与预测，从而提升安防预警与事件处置能力。与通用

场景中的多模态推理主要侧重跨模态语义理解或通用事件判断不同，乡村安防更强调稀疏监控条件下的时空关联推断、地理空间约束以及长时间尺度的行为模式识别，模型需要在监控覆盖不均、数据模态不完整和事件发生低频但影响较大的环境中进行综合推理，因此更加依赖时空上下文整合与区域治理知识来支撑实际安防决策。

6.1.4.6.7.4 乡村多模态生成模型

生成多样化训练数据，提升监控识别算法对复杂环境的适应能力；同时还能对低清监控画面进行超分辨率重建或补全，提高取证与识别效率。

6.1.4.6.7.5 乡村模型融合

融合上述多模态系列模型与平安乡村已建设专业模型，实现村庄出入口异常人员、车辆监测和关注人群管理监测，实现乡村地区的鱼塘水库守护、果园农场守护、养殖场守护等，保障村民人身财产安全，自动开展治安巡逻监测、河沟治理监测、危险区域落水监测，对非法电鱼、摩电违规驾乘、公路晒场等行为事件进行实时监测预警，通过智慧安防技术手段，为构建更高水平的平安乡村注入更强的技术动力，助力打造打防管控一体的乡村治安防控及公共服务体系，提升乡村安全防范能力，促进乡村智慧化进程。

6.1.4.6.8 平安机场

6.1.4.6.8.1 机场多模态表征模型

在机场场景中应用的多模态表征模型在训练时通常具有强场景约束、结构化业务语义以及跨模态时空信息融合等特性：模型需要同时对接视频监控图像、安检图像、文本信息（航班信息、告示牌、广播文本）、传感器或行为日志等多源数据，因此训练过程中更强调视觉-文本-行为数据的语义对齐。模型通常需要具备对复杂光照、遮挡、

人群密集环境的鲁棒性，以及对细粒度目标与长尾事件的表征能力，以适应机场真实运行环境中高动态、多主体和安全敏感的特点。

6.1.4.6.8.2 机场多模态理解模型

机场场景中的行为事件相比通用安防场景具有安全等级高、人员规模大、管控区域分级严格和风险类型更具安全敏感性等特点。机场属于重要交通枢纽和重点防护单位，人员流量大且来源复杂，安防不仅需要关注一般异常行为，还需重点识别遗留物品、异常徘徊、人员聚集、闯入限制区域、尾随通行等事件。同时机场通常划分为公共区、控制区和隔离区等多级管控区域，不同区域对人员行为和通行权限要求严格，因此行为事件识别需要结合旅客流程与区域权限管理进行分析，并具备高准确度和实时响应能力，以保障航空运行安全和旅客秩序。

6.1.4.6.8.3 机场多模态时空推理模型

本模型定位于机场全域态势感知与智能研判核心，通过整合视频监控、航班动态、旅客行李轨迹、安检过检及门禁通行等多维数据，构建覆盖航站楼、空侧陆侧的立体化时空关系模型。实现对旅客、工作人员、行李货物及保障车辆的全轨迹追踪与行为预测，支撑安防管控、运行调度优化及应急处置决策。

6.1.4.6.8.4 机场多模态生成模型

生成多样化训练数据以覆盖不同光照、角度、遮挡和天气等复杂场景，从而提升监控识别算法在真实环境中的泛化能力；同时，通过对低清监控画面进行超分辨率重建与细节补全，可有效提升图像清晰度与关键信息可辨性，进而提高识别的准确性和效率。

6.1.4.6.8.5 机场模型融合

融合上述多模态系列模型与平安机场已建设专业模型，实现对机

场内部及周边的全面监控和管理，人员、车辆与物品的全流程监测与管控，包括周界入侵防护、重点区域访问控制及异常行为识别等能力。对关键区域、重点设备、危险品运输及重点关注人员进行动态管控，实现身份核验、行为分析和轨迹追踪等能力。

6.1.4.6.9 平安医院

6.1.4.6.9.1 医院多模态表征模型

医院环境具有人员类型复杂（医护、患者、访客、医闹）、活动模式差异明显、关键区域安全等级不同等特点，因此模型通常需要强化细粒度行为识别、区域语义理解和异常模式的表征能力。需重点学习人员行为、空间区域，以实现对异常行为（如闯入限制区域、长时间徘徊、医患冲突、患者跌倒等）的有效表征。

6.1.4.6.9.2 医院多模态理解模型

医院安防场景中的行为事件相比通用安防场景具有人员构成复杂、行为类型特殊、风险事件多样和安全敏感度高等特点。医院属于半开放环境，人员流动频繁，既包含医护人员、患者和家属等多类角色，又存在推送病人、陪护聚集等特殊医疗行为，因此在行为识别上需要区分正常医疗活动与异常事件。同时，医院更容易出现医疗纠纷、情绪冲突、跌倒走失等风险事件，并且药房、ICU、手术室等重点区域对非法进入和异常行为的管控要求较高。因此，医院安防行为事件识别需要结合医疗业务场景，实现更精准的判别和应急处置。

6.1.4.6.9.3 医院多模态时空推理模型

本模型定位于医院智慧运营管理中枢，通过关联视频监控、患者就诊轨迹、医护定位、医疗设备状态及药品流转等异构数据，建立跨院区、跨科室的精细化时空映射。实现对患者、医护人员、物资设备的全流程动线分析，赋能安防预警、医疗质量监管及服务效率提升。

6.1.4.6.9.4 医院多模态生成模型

生成多样化训练数据，提升监控识别算法对复杂环境的适应能力；同时还能对低清监控画面进行超分辨率重建或补全，提高识别效率。

6.1.4.6.9.5 医院模型融合

融合上述多模态系列模型与平安医院已建设专业模型，实现未戴脱岗离岗、医疗纠纷、安全事件、紧急救治通道保障等进行监测和智能预警，提升监管效率，增强透明度，促进行业自律，提升医疗过程安全监管的效率和水平。

6.1.4.6.10 环保安防

6.1.4.6.10.1 环保多模态表征模型

本模型定位于生态环境监测与治理体系中的基础感知核心，承担对环境监控视频及图像数据进行全要素结构化解析的作用，为污染识别、风险研判与执法监管提供标准化数据支撑。在功能层面，模型支持对河道水体、烟囱排放、扬尘区域、垃圾堆放、渣土车辆、裸土覆盖情况、植被状态及相关作业设备等要素进行检测与分类，并输出目标类别、空间位置及状态属性信息；同时具备适应复杂光照、远距离观测及气候变化条件的鲁棒性，实现环境要素的数字化表达与动态监测，为环保巡查、污染溯源及治理评估提供可靠的视觉数据基础。

6.1.4.6.10.2 环保多模态理解模型

本模型定位于生态环境监管与污染防治体系中的智能预警核心，承担对环境监控场景中异常排放与违规行为进行自动识别、快速研判与分级告警的作用，是提升环保执法效率与精准监管能力的重要技术支撑。在功能层面，模型基于视频时序分析与环境要素建模能力，对异常烟气排放、黑烟超标、扬尘异常升高、露天焚烧、非法倾倒垃圾、渣土车违规覆盖不严及水体异常颜色变化等情况进行识别与分类，并

输出事件类型、发生时间、空间位置及关联主体信息；同时支持风险等级评估与联动处置机制，可对接环保监管平台与执法流程，实现实时预警、证据留存与事后溯源分析，为环境治理与污染防控提供精准、可追溯的智能化支撑能力。

6.1.4.6.10.3 环保多模态生成模型

生成多样化训练数据，提升监控识别算法对复杂环境的适应能力；同时还能对低清监控画面进行超分辨率重建或补全，提高取证与识别效率。

6.1.4.6.10.4 环保模型融合

融合上述多模态系列模型与环保安防已建设专业模型，实现对涉及环境保护的安防智能化监控、管理和优化。通过实现烧桔杆检测、河道漂浮监测、垃圾乱堆放监测、工厂废气排放监测、工厂扬尘监测、违规排污识别、裸土未覆盖、车辆冒黑烟等智能场景的应用，可以有效提升管理效率，降低环境污染，促进节能减排，为环保过程提供了全面、高效、便捷的安全保障。

6.1.4.6.11 平安工地

6.1.4.6.11.1 工地多模态表征模型

本模型定位于施工现场智能监管体系中的基础感知核心，承担对工地场景进行全要素结构化解析的作用，为安全管理、作业监督与风险识别提供标准化视觉数据支撑。在功能层面，模型支持对施工人员、工程车辆、塔吊设备、脚手架、物料堆放区、安全防护设施及作业区域边界等要素进行检测与分类，并输出目标类别、空间位置、数量统计及基础属性信息；同时可适应粉尘、强光、遮挡及复杂动态环境，实现对施工现场运行状态的全面数字化表达，为安全生产管理与精细化施工监管提供可靠的数据基础。

6.1.4.6.11.2 工地多模态理解模型

本模型定位于施工现场安全生产与风险防控体系中的智能预警核心，承担对工地场景中异常行为、违规作业及突发安全事件进行自动识别与分级告警的作用，是实现安全生产闭环管理的重要技术支撑。在功能层面，模型基于视频时序分析与作业规范规则建模能力，对未佩戴安全帽或反光衣、危险区域违规进入、高空抛物、人员跌落、机械设备异常运行、明火作业异常及异常聚集等情况进行识别与分类，并输出事件类型、发生时间、空间位置及关联目标信息；同时支持风险等级评估与联动响应机制，可与现场管理平台、广播系统及应急处置流程对接，实现实时预警、过程留痕与事后溯源分析，为施工现场安全监管与生产管理提供精准、可靠的智能保障能力。

6.1.4.6.11.3 工地多模态生成模型

生成多样化训练数据以覆盖不同光照、角度、遮挡和天气等复杂场景，从而提升监控识别算法在真实环境中的泛化能力；同时，通过对低清监控画面进行超分辨率重建与细节补全，可有效提升图像清晰度与关键信息可辨性，进而提高目标识别与取证分析的准确性和效率。

6.1.4.6.11.4 工地模型融合

融合上述多模态系列模型与平安工地已建设专业模型，实现未系安全带、未戴安全帽、违反安全流程、工服合规性、未穿反光衣、吸烟、化学品泄漏监测、火情、安全风险、危险动作、机械臂下站人、区域禁入等异常行为事件的智能监测，提升安全生产领域对工地风险的感知能力、预警能力和处置效率，可有效降低安全事故的发生率，提升工地安全生产水平。

6.1.4.6.12 平安铁路

6.1.4.6.12.1 铁路多模态表征模型

对火车站、铁路沿线的人员及物品进行建模，支持目标检索、相似度匹配、零样本分类、跨域迁移等能力，可应用于人脸识别、人体识别、车辆识别及聚类分析等模块的底层特征支撑引擎。

6.1.4.6.12.2 铁路多模态理解模型

本模型定位于铁路运营安全保障体系中的智能风险识别核心，承担对铁路沿线及站场场景中的异常行为与突发事件进行自动检测、快速研判与分级预警的作用，是保障行车安全与运营稳定的重要技术支撑。在功能层面，模型基于视频时序分析与场景规则建模能力，对人员侵入轨道、翻越围栏、滞留线路、抛掷异物、设备异常状态、烟火异常及可疑聚集等情况进行识别与分类，并输出事件类型、发生时间、空间位置及关联目标信息；同时支持风险等级评估与联动处置机制，可与调度系统、报警系统及应急响应流程对接，实现实时告警、闭环处置与事后溯源分析，为铁路运行安全与综合管控提供高可靠性的智能预警能力。

6.1.4.6.12.3 铁路多模态时空推理模型

本模型定位于铁路网络安全运营与运力调度决策引擎，通过融合视频监控、列车运行图、旅客出行链、票务信息及线路设备状态等数据，搭建跨车站、跨线路的网络化时空分析框架。实现对旅客、作业人员、列车车辆及关键设施的全链条轨迹还原与风险预判，保障客运安全与运输秩序。

6.1.4.6.12.4 铁路多模态生成模型

生成多样化训练数据，提升监控识别算法对复杂环境的适应能力；同时还能对低清监控画面进行超分辨率重建或补全，提高取证与识别效率。

6.1.4.6.12.5 铁路模型融合

融合上述多模态系列模型与平安铁路已建设专业模型，实现对火车站、铁路沿线的异常事件识别、特殊人员发现、人员行为识别、人员物品识别查找、目标轨迹生成等更实时、准确的监测和预测能力，给出处理建议或工单触达到责任人。

6.1.4.7 模型推理优化

6.1.4.7.1 模型量化压缩与蒸馏算法

6.1.4.7.1.1 模型可压缩性分析

模型可压缩性分析模块用于系统评估大模型在量化、剪枝与蒸馏等压缩路径下的性能损失风险与收益空间，为部署优化与成本控制提供决策依据。

在量化分析方面，模块对不同层类型（**Embedding**、**Attention**、**MLP**、**LayerNorm** 等）进行敏感度评估，给出推荐量化比特范围。例如，**Embedding** 与 **Attention** 权重通常对精度较敏感，建议优先采用 **8-bit** 或混合精度量化；**MLP** 层在部分场景下可尝试 **4-bit** 量化；对激活值可结合对称/非对称量化策略进行动态校准。通过逐层误差传播分析与校准数据集测试，评估量化后对困惑度、下游任务指标与推理稳定性的影响，形成分层量化建议与混合精度方案。

在结构压缩层面，模块提供剪枝比例建议，包括结构化剪枝（如按通道、按头剪枝）与非结构化剪枝的可行性分析。通常建议从 **10%–30%** 的保守剪枝比例开始，结合稀疏度—性能曲线评估可接受区间，并分析不同模块（**Attention** 与 **FFN**）对剪枝的敏感度差异。在知识蒸馏方面，模块评估教师模型与学生模型之间的容量差距、任务复杂度与对齐难度，判断蒸馏可行性与预期性能上限，包括是否需要中间层对齐或仅输出层蒸馏。整体模块通过量化敏感度分析、结构冗余评估与蒸馏可达性判断，形成系统化压缩路径建议，在模型性能、推理延

迟与部署成本之间实现可控平衡。

6.1.4.7.1.2 量化算法研究

量化算法研究模块聚焦于在尽可能降低模型存储与推理成本的前提下，维持模型精度与稳定性，是大模型部署优化的核心技术方向之一。模块围绕不同阶段与不同精度目标，系统研究多种量化路径与算法实现机制。

在 PTQ (Post-Training Quantization) 方面，重点研究在不重新训练或仅少量校准数据参与的情况下，对已训练模型进行权重与激活值量化的方法。包括对称/非对称量化、逐通道量化、逐张量量化、误差补偿与校准数据选择策略等。PTQ 具有工程成本低、部署速度快的优势，适用于大规模模型快速压缩场景，但对高压缩率场景下的精度保持能力存在一定挑战。

在 QAT (Quantization Aware Training) 方面，模块研究在训练阶段引入量化模拟算子，使模型在前向与反向传播过程中感知量化误差，从而主动学习对量化噪声的鲁棒表示。QAT 通常能够在 8-bit 或更低精度下取得优于 PTQ 的性能表现，但训练成本更高，工程复杂度也更大，适用于对精度要求较高的生产级部署场景。

在超低比特量化方向（如 4-bit、3-bit 甚至 2-bit 量化），模块重点研究分组量化、混合精度策略、离群值处理、以及结合缩放因子与零点优化的非均匀量化方法。此类方法在显著降低显存占用与推理带宽需求的同时，对数值稳定性与精度保持提出更高挑战，通常需要配合蒸馏、再训练或混合精度设计。整体模块通过算法对比实验与误差传播分析，形成不同模型规模与部署场景下的最优量化策略建议。

6.1.4.7.1.3 模型剪枝研究

模型剪枝研究模块聚焦于通过移除冗余参数或结构单元，降低模

型计算复杂度与存储开销，在尽量保持性能的前提下提升推理效率与部署适配性。根据剪枝粒度与硬件友好程度，主要分为非结构化剪枝与结构化剪枝两大方向。

在非结构化剪枝方面，剪枝对象通常为单个权重参数，通过基于权重幅值、梯度敏感度或重要性评分进行稀疏化处理，使权重矩阵呈现高比例稀疏分布。该方法能够在理论上获得较高压缩率（如50%–90%稀疏度），并在一定程度上保持模型精度，但由于生成的是不规则稀疏结构，对通用硬件加速支持有限，通常需要专用稀疏计算库或定制推理引擎才能充分释放性能收益。

在结构化剪枝（Structured Pruning）方面，剪枝粒度提升至通道（Channel）、注意力头（Attention Head）、隐藏维度或整层结构，直接移除完整结构单元，从而生成规则、紧凑的新模型结构。该方法对 GPU、CPU 等通用硬件更加友好，能够直接减少 FLOPs 与实际推理延迟，适合工业部署场景。常见策略包括基于通道重要性评分的通道裁剪、基于注意力权重分布的头剪枝，以及对前馈网络宽度的压缩。整体研究强调在“压缩率—性能损失—硬件加速收益”三者之间建立量化评估体系，为不同规模模型与部署环境提供最优剪枝路径建议。

6.1.4.7.1.4 低秩分解

低秩分解研究模块聚焦于利用矩阵的低秩结构对大规模模型参数进行近似表示，以实现参数压缩与计算加速，同时在微调场景中降低训练成本与显存占用，是当前超大模型优化的重要技术路径之一。

在超大模型压缩方面，低秩分解通过将权重矩阵 $W \in \mathbb{R}^{m \times n}$ 解为两个低秩矩阵 $A \in \mathbb{R}^{m \times r}$ 与 $B \in \mathbb{R}^{r \times n}$ （其中 $r \ll \min(m, n)$ ），显著减少参数量与计算量。该方法可应用于 Attention 投影矩阵、前馈网络层以及嵌入层，通过秩选择策略与误差控制机制，在保证模型性能可接

受的前提下实现有效压缩。结合 SVD 分解、分块低秩近似或动态秩选择策略，可在不同层设置不同压缩强度，形成分层压缩方案。在微调场景中，低秩思想通常以参数高效微调（PEFT）的形式出现，例如通过在冻结原模型权重的基础上引入可训练的低秩增量矩阵，实现小规模参数更新而保持主模型不变。

6.1.4.7.1.5 知识蒸馏

知识蒸馏模块旨在通过“教师模型—学生模型”范式，将大模型的知识迁移至更小规模或更高效率的模型，在降低参数规模与推理成本的同时尽量保持性能表现，是模型压缩与能力迁移的重要技术路径。

在 Logits 蒸馏方面，学生模型通过拟合教师模型输出的软标签进行训练，通常采用温度参数对输出分布进行平滑处理，使学生学习到类别之间的相对关系信息，而不仅仅是硬标签。该方法实现简单、工程成本低，适用于分类或生成任务的基础能力迁移，是最常见的蒸馏形式。

在中间层蒸馏方面，学生模型不仅学习最终输出，还对齐教师模型的中间隐藏层表示、注意力分布或特征图，从而在表征空间层面进行知识迁移。该方法通常用于结构差异较大的模型之间，或在需要更高性能保留率的场景下使用，但对结构与映射方式要求更高。

在多任务蒸馏方面，学生模型同时学习教师在多个任务上的输出行为，通过联合损失函数整合不同任务信号，实现跨任务能力压缩与统一建模。这种方法适用于构建轻量级通用模型或行业专用模型，在保持多任务泛化能力的同时降低模型规模。整体蒸馏策略需要综合考虑教师—学生容量差距、任务复杂度与训练稳定性，通过温度调节、损失权重设计与阶段式训练策略实现最佳迁移效果。

6.1.4.7.1.6 混合压缩策略

混合压缩策略模块旨在综合利用量化、剪枝、低秩分解与知识蒸馏等多种压缩技术，在性能、模型规模与推理效率之间实现系统级最优平衡。该模块强调策略自动化与搜索优化能力，而非单一压缩方法的局部改进。

在自动组合策略方面，模块支持根据模型结构特征与部署约束（显存、延迟、功耗等）自动选择压缩路径，例如“结构化剪枝+8-bit 量化”或“低秩分解+蒸馏+4-bit 混合量化”等组合方案。通过分层策略配置，对不同模块采用不同压缩方式，以适配其敏感度差异。在压缩超参数搜索方面，引入自动化搜索机制（如基于网格搜索、贝叶斯优化或进化算法），对剪枝比例、量化 bit 数、低秩秩值、蒸馏温度等关键参数进行联合优化，构建多维压缩配置空间并评估性能变化趋势。

在精度-延迟帕累托优化方面，模块构建多目标优化框架，将模型精度（Accuracy、Perplexity 等指标）与实际推理延迟、吞吐量、模型大小纳入统一评估体系，通过 Pareto Front 分析筛选非劣解集合，辅助决策最优部署方案。整体模块强调系统级协同优化，通过自动搜索与多目标评估机制，实现压缩效果的可量化与可解释，在资源受限场景下提供高性价比模型版本。

6.1.4.7.1.7 精度对齐优化

精度对齐优化模块用于在模型压缩或结构调整后恢复性能，并在能力层面重新对齐目标任务与人类期望，是模型工程化落地中的关键收敛保障机制。该模块通常作为量化、剪枝或蒸馏之后的“恢复阶段”，以较低成本弥补精度损失与行为偏移。

在小规模再训练方面，模块通过少量高质量数据进行短周期再训练，对压缩后模型进行权重微调或局部解冻训练，修正因数值近似或结构裁剪带来的分布偏移。可采用低学习率、分层解冻或仅微调关键

模块（如输出层、**Attention** 投影层）等策略，在控制计算成本的同时最大化精度恢复效果。

在对齐再优化方面，模块重点关注模型输出行为与目标标准之间的一致性，包括任务目标对齐、风格一致性与安全合规约束。可结合 **SFT**（**Supervised Fine-Tuning**，即监督微调）、偏好优化或轻量级对齐数据进行再训练，强化模型在关键场景下的稳定性与可靠性。整体机制强调“压缩—恢复—对齐”的闭环优化流程，在保持高压缩率的同时确保性能指标与行为表现达到可上线标准。

6.1.4.7.1.8 性能评估与基准测试

性能评估与基准测试模块用于对模型在压缩、优化或迭代后的综合表现进行系统验证，从精度、效率与稳定性三个维度构建多指标评估体系，为上线决策与版本对比提供量化依据。

在精度指标方面，根据任务类型选取对应评价标准，例如分类任务的 **Accuracy**、**F1-score**，生成任务的 **BLEU**、**ROUGE** 或 **Perplexity**，多模态任务的 **Recall@K**、**mAP** 等；同时可结合行业自定义指标与场景测试集进行专项评估，分析不同任务子集或难度区间的性能分布，确保模型能力提升具有统计显著性与业务相关性。

在效率指标方面，重点衡量模型在真实部署环境下的资源消耗与响应能力，包括推理延迟、吞吐量、显存占用、参数规模、**FLOPs** 等；在多机多卡或边缘部署场景下，还需评估扩展效率与带宽利用率，确保优化策略带来实际系统收益。

在稳定性指标方面，评估模型在长时间运行与复杂输入场景下的鲁棒性与一致性，包括输出波动性、数值稳定性（是否出现 **NaN/Inf**）、异常输入容错能力以及多轮对话一致性等。可结合压力测试与对抗样本测试进行验证。整体模块通过标准化评测流程与自动化基准对比工

具,构建可重复、可追踪的评估体系,支撑模型版本迭代与工程决策。

6.1.4.7.2 模型国产化推理适配与加速

行业模型国产化适配与加速模块聚焦于行业大模型在国产算力平台上的高效运行与性能优化,目标是在保证模型精度与稳定性的前提下,充分释放国产硬件架构的计算潜力,实现可控、安全、低成本的部署能力。

6.1.4.7.2.1 硬件适配与抽象模块

硬件适配与抽象模块旨在构建模型框架与底层算力之间的统一抽象层,实现跨硬件平台的可移植性与性能可控性,是模型工程体系中的关键基础设施。

在统一算子接口方面,模块对矩阵乘法、Attention、LayerNorm、卷积、激活函数等核心算子进行标准化封装,屏蔽不同硬件后端(GPU、NPU、CPU 等)之间的实现差异,通过统一 API 进行调度与调用;同时支持算子自动选择与融合优化,根据设备特性选择最优内核实现或执行图优化。在统一内存接口方面,模块抽象显存与主存管理机制,统一管理张量分配、释放、缓存复用与数据拷贝策略,支持异步数据传输与计算重叠,减少内存碎片与数据搬移开销。

在精度格式适配方面,模块支持多种数值格式,包括 FP32、BF16、FP16、INT8、INT4等,能够根据设备能力与部署需求自动选择或混合精度执行策略,并处理不同精度间的数据转换与缩放问题,确保数值稳定性与性能平衡。在设备能力探测方面,模块在运行时自动检测设备算力、显存容量、内存带宽与并行单元规模等关键指标,据此动态调整并行策略、批大小、量化级别与缓存配置,实现资源感知型调度与自适应优化。整体模块通过“算子抽象+内存抽象+精度适配+能力感知”机制,构建软硬件解耦且高效协同的运行基础架构。

6.1.4.7.2.2 算子级优化模块

算子级优化模块聚焦于底层计算内核的性能提升，通过对关键算子执行路径进行细粒度优化，最大化硬件利用率与吞吐能力，是高性能推理与训练系统的重要加速手段。

在 **Kernel Fusion** 方面，通过将多个连续算子（如 **MatMul+Bias+Activation+LayerNorm**）进行融合，减少中间张量写回与显存访问次数，降低内存带宽压力与 **kernel launch** 开销，从而提升整体执行效率。在 **Tensor Core** 利用方面，针对支持矩阵加速单元的硬件平台，优化矩阵维度对齐与数据排布格式，使计算路径能够调用专用矩阵乘法单元，实现高吞吐混合精度计算。

在 **Warp-level** 优化层面，通过线程束级协同与共享内存优化，减少线程分支与同步开销，提升并行执行效率；在 **Tile** 优化方面，通过分块计算策略优化数据复用与缓存命中率，合理规划寄存器与共享内存占用，避免访存瓶颈。最后，在内存对齐优化方面，通过对齐数据结构、优化张量布局（如行主序/列主序或特定块布局）与向量化加载方式，降低非对齐访问带来的性能损耗。整体模块强调“计算-访存-调度”协同优化，在算子级别实现高效、稳定且可扩展的性能提升。

6.1.4.7.2.3 高效 Attention 优化模块

高效 **Attention** 优化模块聚焦于降低自注意力机制在长序列与大规模推理场景下的计算与显存开销，是提升大模型吞吐能力与推理效率的核心优化方向。

在 **FlashAttention** 方面，通过块状计算与在线 **softmax** 归一化策略，将 **Attention** 计算重构为 **IO-aware** 算法，显著减少显存读写次数，实现接近理论带宽上限的执行效率，尤其适用于长序列训练与推理场景。

在 Paged Attention 方面（如 vLLM 中的实现），通过将 KV 缓存分页管理并映射至非连续显存区域，提高显存利用率与批量推理吞吐能力，特别适用于多请求并发场景。

在结构层面，Multi-Query Attention (MQA) 通过共享键值对投影，仅保留多头 Query，显著降低 KV 缓存存储规模与内存带宽需求，在推理阶段能够有效减少显存占用与访问开销。进一步地，模块支持 KV 缓存压缩策略，包括低比特量化、分组压缩、滑动窗口裁剪或基于重要性评分的历史词元剪枝，以控制长上下文场景下的显存增长。整体模块围绕“计算重构+存储优化+结构简化”三条主线，系统提升 Attention 机制在高并发与长序列条件下的性能与可扩展性。

6.1.4.7.2.4 并行与分布式执行模块

并行与分布式执行模块用于提升大模型在不同规模算力环境下的执行效率与扩展能力，覆盖单卡、多卡及多机场景，是实现高吞吐与低延迟部署的关键基础模块。

在单卡优化方面，模块通过批量合并与动态分批技术，将多个小请求在运行时自动聚合为统一批次执行，提高算力利用率与吞吐效率；同时结合算子融合、显存复用与 KV 缓存管理优化，减少碎片化计算与频繁调度带来的性能损耗，提升单卡资源使用率与响应稳定性。

在多卡优化方面，模块支持主流并行策略，包括张量并行（将单层计算拆分到多卡执行）、流水线并行（将不同层分布到不同设备）、以及数据并行（通过多副本同步梯度更新）。可根据模型规模与网络拓扑设计混合并行策略，在计算负载、通信成本与显存占用之间取得平衡，提升整体扩展效率。

在多机优化方面，模块支持跨节点分布式调度与异步执行机制，通过梯度异步更新、通信压缩与计算通信重叠等方式降低网络瓶颈影

响；同时结合任务调度与资源感知分配策略，实现大规模集群环境下的高效运行与弹性扩展。整体模块构建“单卡优化—多卡并行—多机协同”三级并行体系，实现从边缘部署到数据中心级推理的全场景覆盖。

6.1.4.7.2.5 精度与量化适配模块

精度与量化适配模块用于在不同硬件能力与部署场景下，实现模型数值精度的动态调度与稳定运行，在性能、显存占用与精度损失之间取得工程化平衡。

在动态精度切换方面，模块支持根据运行负载、设备能力或任务类型，在 FP32、BF16、FP16与低比特整型之间进行运行时切换，实现资源感知型精度调度；例如在高并发场景下降低精度以提升吞吐，在关键任务阶段切换至高精度保障输出质量。在 INT8/INT4推理支持方面，模块集成低比特量化算子与校准机制，支持对权重与激活值进行整型推理，并结合缩放因子管理与误差补偿策略，确保数值稳定性与性能提升效果。

在 BF16自动适配方面，模块根据设备是否支持 BF16原生指令集自动选择执行路径，在支持的平台上优先启用 BF16计算以获得更好的数值范围与计算效率；若设备不支持，则自动回退至 FP16或 FP32。通过混合精度 **fallback** 机制，当检测到数值异常（如溢出、NaN、梯度不稳定）或性能异常时，系统可对特定层或算子自动回退至更高精度执行，实现分层精度控制与局部容错。整体模块强调“精度自适应+稳定性保障+性能最大化”的协同设计，支撑多平台、多场景下的高效部署。

6.1.4.7.2.6 推理调度与负载均衡模块

推理调度与负载均衡模块用于在高并发、多租户或多业务场景下，

实现推理资源的高效分配与稳定运行，保障系统吞吐能力、响应时延与服务质量。

在动态批处理方面，模块在运行时对短时间窗口内到达的请求进行自动聚合，形成最优批大小执行，从而提升硬件利用率与整体吞吐；同时结合最大等待时间阈值控制，避免过度聚合导致尾延迟上升。在请求排队策略方面，支持 **FIFO**、基于最短剩余时间或自定义权重队列等策略，平衡吞吐与延迟需求，避免热点请求导致系统拥塞。

在优先级调度方面，模块支持按用户等级、业务类型或任务紧急程度分配优先级，实现关键业务优先保障；结合限流机制，可对单位时间请求数或并发数进行控制，防止流量突发对系统稳定性造成冲击。同时支持异步执行与事件驱动架构，使请求处理与结果返回解耦，提升资源利用率并减少阻塞等待时间。整体模块通过“调度策略+批处理优化+流量控制+异步架构”构建弹性推理服务体系，在高负载环境下实现稳定、可扩展的模型服务能力。

6.1.4.7.2.7 性能监控与分析模块

性能监控与分析模块用于对模型训练与推理过程中的关键系统指标进行实时采集、分析与诊断，是保障高性能运行与持续优化的重要支撑模块。

在资源利用率监控方面，模块实时采集 **GPU** 利用率与显存使用率，分析计算单元占用情况、显存峰值与碎片化程度，识别算力空闲或显存瓶颈问题；同时可结合批大小、并行策略与 **KV** 缓存使用情况进行关联分析，评估资源利用效率。

在执行路径分析方面，模块支持内核级时间分析，统计各算子执行耗时、调用频率与占比，识别热点算子与低效路径；同时监控多卡或多机场景下的通信耗时，包括梯度同步时间、参数广播时间与带宽

利用率，评估通信与计算是否有效重叠。基于上述指标，模块提供瓶颈定位机制，通过时间分解与阶段占比分析（如前向、反向、优化器更新、数据加载等），快速判断性能瓶颈来源是计算受限、内存受限还是通信受限，从而为算子优化、并行策略调整或系统调度改进提供明确依据。整体模块强调可观测性与可量化分析能力，支撑模型系统的持续性能优化与容量规划。

6.1.4.7.3 大小模型协同

大模型与小模型的协同进化是人工智能领域的一个重要发展趋势，它旨在结合大模型的强大计算能力和小模型的灵活性，以实现更高效、更适应性强的智能系统。项目将通过以下手段/步骤实现大小模型协同：通过轻量级预处理模块结合预设任务分配规则，根据任务的复杂度、数据特征和响应时间需求，决定任务是由大模型处理还是小模型处理；通过共享存储以及消息队列经由数据格式转换模块保证在大小模型之间高效传输数据，确保大小模型协同工作；在任务完成后，对大模型和小模型的结果进行验证和比对，确保结果的准确性和一致性；实时监控大模型和小模型的性能（包括响应时间、准确率和资源使用情况）发现问题及时调整；基于反馈数据，持续改进模型。

6.1.4.7.4 端边云结合




图 131 端边云协同示意图

构建“集中式大规模训练”和“边缘分布式协同推理”新范式，实现端边云协同。

云算力中心负责训练和推理；边缘设备上的大模型平台负责对经过剪枝、量化、蒸馏等操作的压缩模型进行微调 and 推理；端侧设备则通过调用云算力中心实现数据回流以及小模型推理。

6.1.4.7.5 主要设备配置清单

基础大模型购置清单如表103错误!未找到引用源。所示。

表 103 基础大模型购置清单

序号	设备名称	主要性能指标	国别	数量 (套)
1	基础大模型			
1.1	多模态基础大模型及技术服务	多模态基础大模型能够将来自不同模态的数据（如文本描述、图像内容、音频信号等）进行有效整合，形成一个统一的表示空间。这种整合不仅限于简单的数据拼接，而是通过复杂的算法和模型架构，实现不同模态信息之间的深度理解和交互。模型能够自动从各种模	国产	1

		态的数据中提取关键特征，并将这些特征转换为统一的、可比较的表示形式。这有助于模型在后续的处理和推理过程中，更好地理解 and 利用这些多模态信息。多模态大模型应具备强大的自然语言理解能力，能够准确识别和理解用户输入的文本信息（语音），包括语义、语境和上下文等。这有助于模型在人机交互过程中，更准确地捕捉用户的意图和需求。支持生成流畅、自然的文本输出。这包括回答用户问题、生成文本摘要、进行文本创作等多种任务。多模态大模型能够根据用户的输入（如文本描述、图像、语音信息等），生成相应的其他模态的输出。例如，根据文本描述生成图像、根据图像生成文本描述（语音信息）等。支持同时处理多种模态的输入，并生成多种模态（文本、图像、语音）的输出。多模态大模型能够结合不同模态（文本、图像、视频、语音）的信息进行推理和判断。例如，在安防应用中，模型可以结合场景的现状以及规范指导要求，进行更准确的现状分析和预警诊断。基于多模态信息的整合和分析，模型能够做出更加智能和合理的决策。提供多模态交互式大模型，参数量不低于400 亿，基于自然语言能够处理统一多视觉任务的 L0 大模型，接受图像和自然语言、语音等信息作为输入，将对齐的视觉和文本特征	
--	--	---	--

		输入到大语言模型中，进行自回归输出。 相关指标要求如下： 1、模型参数：提供百亿级、千亿级模型，可满足对不同场景参数的多样性选择； 2、输入输出长度：提供 8K、128K 上下文输入输出长度，可满足对不同长度的需求； 3、模型调优：提供 post-pretrain、SFT、RL 等调优方式，支持进行行业模型训练和调优； 4、具备模型配套的精简能力（量化、剪枝、蒸馏），支持在多种国产卡上的推理，如：华为、登临等不少于 6 种国产化设备； 5、支持并维护模型性能需求至少 3 年。		
--	--	---	--	--

自研算法清单如错误!未找到引用源。表104所示。

表 104 自研算法清单

序号	系统及模块名称	主要研发内容
1	安防行业后预训练方法研究	
1.1	模型训练数据管道	
1.1.1	数据源接入模块	(1) 对接多种数据源（本地文件、对象存储、数据库、API 等） (2) 支持批量导入与流式导入 (3) 统一格式抽象及融合
1.1.2	数据清洗与标准化模块	(1) 去重（MinHash / SimHash） (2) 噪声过滤 (3) 图像、声音、文本长度及大小过滤 (4) 不关注或非法内容过滤
1.1.3	数据质量评估模块	(1) 重复率统计 (2) 垃圾数据比例评估 (3) 语义多样性评估

1.1.4	数据增强模块	(1) 数据改写 (2) 数据翻译 (3) 数据对比样本生成 (4) 图像增强
1.1.5	数据版本与治理模块	(1) 参与训练的数据集版本管理 (2) 训练数据集快照 (3) 训练数据集回滚
1.1.6	数据存储与格式模块	(1) 支持 TB~PB 级数据 (2) 数据分片 (Sharding) (3) 支持预先 Tokenize 或 Lazy Tokenize 设计决策
1.1.7	Tokenization 与特征化模块	(1) Tokenizer 训练 (2) 分词缓存 (3) 特殊 token 管理 (4) 多模态特征抽取 (图像编码、音频编码)
1.1.8	数据调度与采样策略模块	(1) 批量加载 (2) 动态拼接 (packing) (3) 随机打乱 (global shuffle) (4) 多进程 / 多节点同步
1.1.9	在线数据监控模块	(1) 多数据源比例控制 (2) 难度分级采样 (3) 重加权采样 (4) 动态混合 (例如 warmup 阶段比例不同) (5) curriculum learning (6) 难例挖掘
1.2	多模态对齐与融合训练	通过多模态对齐训练, 模型学习建立这些信息之间的语义对应关系
1.3	时空关系建模	通过多模态对齐训练, 模型学习建立这些信息之间的语义对应关系
1.4	事件语义与知识注入	通过多模态对齐训练, 模型学习建立这些信息之间的语义对应关系
1.5	长尾与异常场景强化	安防场景中很多关键事件 (如突发事件、异常行为) 属于低频长尾事件。后预训练需要通过: 数据增强、合成数据、异常样本扩展等技术强化模型对罕见事件和异常行为的识别能力
1.6	安全与隐私约束训练	加入数据脱敏、隐私保护训练策略以及安全约束机制, 确保模型在使用过程中符合数据安全和合规要求
2	安防行业大模型	

2.1	安防多模态表征大模型	训练融合安防行业数据模态，在统一或对齐的语义空间中，对图像、文本、语音、视频等多种模态进行编码，并输出可用于检索、匹配、分类、推理等任务的高质量 embedding 的大规模模型
2.2	安防多模态理解大模型	针对模型的风险识别能力，基于已训练完成的安防行业多模态检索模型，进一步构建多模态搜索推理模型，从“相关内容召回”向“可理解、可推理搜索”的关键升级路径。
2.3	安防多模态时空推理大模型	实现复杂现实场景智能理解与决策的关键升级。该模型将时间序列、空间位置与多模态感知信息进行统一建模，使搜索与推理能力从静态语义匹配扩展至动态时空演化分析。
2.4	安防多模态生成大模型	能够在文本、图像、语音等多种模态之间进行条件生成与跨模态生成的统一大规模模型体系，面向安防行业场景构建端到端生成能力
2.5	融合模型	通过多模态融合专家模块，将音频、视觉和语言等做特征融合，结合多个任务一起做模型预训练，通过不同专家的协作，完成下游任务学习，满足各种业务场景需求
3	专业场景微调	
3.1	低秩适配微调	当计算资源有限时，一般使用低秩微调技术可以显著降低内存和计算需求同时也可以提高微调效率
3.2	适配器微调	在特定场景任务中能够获得更好的性能，向模型添加部分额外的参数
3.3	前缀微调	在数据量以及计算资源有限时更具有高效性以及灵活性，可以更好的适配特定场景
3.4	提示微调	在需要同一模型处理多个不同任务的场景中，可以为每个任务设计不同的提示，从而在不改变模型结构的情况下，适应多种任务
4	专业场景模型	
4.1	智慧图侦	
4.1.1	图侦多模态表征模型	该模型承担高质量视觉特征生成的作用，为图侦应用中的关键要素识别与检索任务提供通用表征能力支撑。在功能

		层面，模型通过自监督或对比学习方式生成高判别性向量特征，支持目标检索、相似度匹配、零样本分类、跨域迁移等能力，可应用于人脸识别、人体识别、车辆识别及聚类分析等模块的底层特征支撑引擎。
4.1.2	图侦多模态理解大模型	该模型定位于风险识别与异常预警核心，承担对非正常行为或异常模式进行自动识别与告警的作用，是安全管理与风险控制体系的重要组成部分。在功能层面，模型基于时序建模与行为表征分析能力，实现对异常行为、异常轨迹、异常状态变化等情况的自动检测，并输出异常等级与事件类型，为图侦系统提供实时预警能力。
4.1.3	图侦多模态时空推理大模型	该模型承担对多源数据进行融合分析与时空推理的作用，实现跨维度、跨时间尺度的综合判断能力。在功能层面，模型融合视频数据、结构化轨迹数据、摄像机数据、地图数据及文本规则信息等，进行时空关系建模，对关注的人车物等目标进行轨迹研判和预测，为图侦业务提供线索支撑和分析能力。
4.1.4	图侦多模态生成大模型	该模型可通过模糊图像高清修复、证人描述合成画像、失踪人员跨龄样貌推演、案发现场与物证重建等方式，为公安图侦提供关键线索与技术支撑，大幅提升破案效率与精准度，同时可用于深度伪造检测防范风险，是公安智能化办案的重要辅助工具
4.1.5	图侦模型融合	融合上述的多模态系列模型与图侦专业模型，如：人脸识别模型、人体识别模型、结构化模型等。实现人/车/物目标细分类别或属性搜索、语义搜点位、语义搜目标、视频自动巡检、关注人离开属地分析、关注人居住地变更分析、关注人长期不出现监测、关注人前往某地监测、落脚点分析、特定人员徘徊监测、目标轨迹融合分析、人群聚集监测、持刀持械监测、案件线索研判分析、关系人分析、团伙分析、骨干挖掘分析、打架斗殴监测、危险可疑物品监测、刻意躲避抓拍分析、套牌车分析、车辆徘徊

		监测、图像超分辨率重建等智能研判预警等智慧图侦服务能力，支撑公安大数据智能化平台建设
4.2	智慧交管	
4.2.1	交管多模态表征模型	通过将来自不同感知系统和业务系统的数据进行语义对齐和特征编码，模型能够建立统一的交通场景表示，为交通事件识别、行为分析和态势研判提供可靠的数据基础
4.2.2	交管多模态理解大模型	将底层感知数据上升至场景级语义解释的作用，实现复杂交通场景的结构化理解。模型能够对交通场景进行整体语义建模，理解车辆与行人之间的关系、交通规则约束及场景动态变化，支持场景描述、行为解释、规则合规判断及多轮交互问答，为交通指挥调度与智能决策系统提供认知级能力支持
4.2.3	交管多模态时空推理大模型	模型融合视频数据、结构化轨迹数据、交通流量数据及文本规则信息，进行时空关系建模与趋势预测，可支持拥堵演化预测、风险扩散分析、交通态势研判及辅助决策生成，为智慧交通系统提供战略级智能分析能力
4.2.4	交管多模态生成大模型	通过对交通数据进行生成式建模，系统可以将复杂的交通监控数据、事件信息和运行状态以更加直观和可理解的方式呈现给管理人员或公众，同时为交通管理提供更丰富的仿真分析和辅助决策手段
4.2.5	交管模型融合	融合上述交管多模态系列模型与交管专业模型，如：车牌识别、车辆识别、车型识别、车辆跟踪、车辆检测等。实现重点车辆管控监测、交通态势感知、交通事件隐患监测、非法运营车监测、摩托车飙车监测、渣土车违规监测、大型货运车违规监测、机动车违法监测、机动车驾驶员异常行为监测、非机动车带人监测、摩电不戴头盔监测、非机动车逆行监测、非法停车监测、车辆超长期停放监测等场景应用，提升非现场执法能力、交通事故预警与处置能力，进一步加强交通管理的智能化、精细化升级，提高交通管理效率和公众出行体验，促

		进城市交通的智慧化发展
4.3	平安城市	
4.3.1	城市多模态表征模型	模型能够构建统一的城市安全信息表达体系，实现不同系统之间的数据关联与信息互通。多模态表征模型可支持多种平安城市应用场景。例如，在目标检索与跨摄像头关联方面，模型能够通过图像、文本描述或行为特征实现人员与车辆的快速检索与匹配；在事件分析与风险识别方面，模型可以结合视频检测结果、轨迹数据及历史案件信息，对异常行为、可疑活动或潜在风险进行综合分析等
4.3.2	城市多模态理解大模型	多模态理解模型可支持多种平安城市应用场景。例如，在复杂事件理解与识别方面，模型能够结合视频画面、行为特征和警情文本信息，对异常行为、冲突事件、聚集事件等进行综合判定；在目标行为分析方面，模型可以通过融合视觉信息与轨迹数据，对人员或车辆的行为模式进行语义分析；在城市安全态势分析方面，模型可对多源信息进行综合理解，形成城市安全态势分析报告和风险提示，为指挥调度与应急处置提供智能辅助支持
4.3.3	城市多模态时空推理大模型	时空推理模型通过对时间维度与空间维度数据进行联合建模与关联分析，实现对城市事件演化过程、目标活动轨迹以及区域安全态势的综合推理能力。在平安城市建设中，该类模型能够将视频监控数据、人员车辆轨迹数据及地理信息数据进行统一时空关联分析，从而提升城市安全系统对复杂事件的研判能力和趋势预测能力。例如，在事件轨迹还原方面，模型能够结合多摄像头数据与轨迹信息，对人员或车辆的活动路径进行时空关联与完整还原；在重点目标追踪方面，模型可以通过时空关系分析实现跨区域目标关联与活动范围分析
4.3.4	城市多模态生成大模型	通过生成合成数据，可对监控图像和声音样本进行数据增强，弥补真实异常事件（如事故、犯罪或枪声等）数据不足的问题，从而提高目标检测、行为识别

		和声音事件识别模型的训练效果。同时，生成模型还能用于城市监控视频的图像修复与超分辨率提升，改善低光或低清视频质量，并通过构建虚拟城市场景和数字孪生环境实现应急演练与安全风险仿真
4.3.5	城市模型融合	融合上述多模态系列模型与平安城市已建设专业模型，实现城市治理各方面的工作中进行全方位、智能化的管理，一是实现对城市安全风险的监测预警，如烟火检测、路面积水、路面塌陷、井盖丢失、打架斗殴、持刀持械预警、盗抢行为、人员异常聚集、标语横幅、渣土车安全、广告牌掉落、人员溺水等风险；二是实现对城市管理市容市貌的智能监测预警，如破坏公共设施、违规占道经营、公共场所吸烟、垃圾管理、摆摊经营、广告牌破损等行为。通过智慧安防赋能，提升城市安全水平、综合管理水平，促进城市的智慧化建设，实现城市更高效、智能的安全管理和社会治理
4.4	平安社区	
4.4.1	社区多模态表征模型	多模态表征模型在平安社区中的核心价值在于通过跨模态信息融合构建更完整的场景语义表示，从而提升社区安全监控、异常检测和应急响应的智能化水平。与城市道路等开放场景不同，社区中的人员、车辆具有较高的重复出现率。例如同住户每天出入小区、固定车辆停放在同一车位。因此检索系统需要更加关注长期身份关联与轨迹检索，通常依赖行人重识别。同时，社区场景通常是半封闭空间（小区入口、楼道、电梯、停车场等），空间范围较小，但包含大量细粒度语义关系
4.4.2	社区多模态理解大模型	本模块定位于社区风险识别与安全预警核心，实现对社区安全事件的实时感知、行为识别与智能预警。在功能层面，模型基于行为模式建模与场景规则匹配，实现对异常行为检测、人员身份识别、车辆管理、火灾烟雾识别、老人跌倒检测以及高空抛物、电动车进楼等安全事件监测，并输出事件类型、时间、位置

		及关联目标信息，为社区安防与物业管理提供及时处置依据
4.4.3	社区多模态时空推理大模型	多模态时空推理模型在平安社区治理中的应用，主要通过融合视频监控、物联网传感器、门禁记录、人员轨迹、警情文本及地理信息等多源数据，对社区内的人、车、事件和空间环境进行统一建模，并结合时间序列与空间关系进行智能推理，实现对社区安全态势的实时感知、异常行为识别和风险事件预测
4.4.4	社区多模态生成大模型	本模型可辅助提升应用性能。图像生成模型可用于模拟异常场景（如火灾、打架、入侵等），生成多样化训练数据，提升监控识别算法对复杂环境的适应能力；同时还能对低清监控画面进行超分辨率重建或补全，提高取证与识别效率
4.4.5	社区模型融合	平安社区中的多模态理解模型通常采用专用模型与规则系统相结合的方式，在保证识别准确率与系统可靠性的同时，实现对社区安全事件的高效感知与智能化管理。一是辅助开展社区人员、车辆安全管理工作，包括人员、车辆安全管理，支持实有人口管理、常口流口人员管理、关注人群管理等工作；二是实现危险预警能力，包括堵塞消防通道监测、烟雾火灾监测、电动车入楼监测、车辆盗抢等；三是加强对社区日常管理，包括工作人员睡岗脱岗监测、社区老幼守护、邻里纠纷监测、不文明养犬行为监测、垃圾异常堆放监测、垃圾桶溢满监测等。通过新智慧安防和社区的融合应用，为构建基层公共安全新格局提供有效支撑
4.5	平安校园	
4.5.1	校园多模态表征模型	在校园场景中，这类模型主要用于提升教学管理、校园安全和学习分析等方面的智能化水平。例如，在智慧课堂中，通过融合课堂视频、教师语音和教学文本，可以分析课堂互动情况、学生注意力和教学效果；在校园安全管理中，结合监控视频、行为识别和门禁数据，可以实现异常行为检测和安全预警
4.5.2	校园多模态理解大模型	本模型定位于校园精细化行为感知与安

		全防控体系中的动作识别核心，承担对校园场景中个体及群体行为进行细粒度识别与动态分析的作用，是实现异常预警与行为研判的重要基础能力。在功能层面，模型基于人体关键点检测与时序动作建模技术，对奔跑、打闹、推搡、摔倒、攀爬、尾随、长时间滞留等动作进行识别与分类，并结合行为持续时间、频率及空间位置进行综合判定；同时支持异常动作模式分析与风险等级评估，可为校园安全管理、课间秩序维护及重点区域风险防控提供实时、结构化的行为数据支撑
4.5.3	校园多模态时空推理大模型	在校园场景中，这类模型的应用具有明显的环境和任务特征。首先，场景结构稳定且空间关系明确。校园由教学楼、宿舍、图书馆、操场等固定区域组成，人员活动路径和时间规律较为稳定。因此，多模态时空推理模型可以结合视频监控、门禁记录、位置数据等信息，对人员活动进行连续时空建模，例如识别学生在不同地点之间的行为轨迹或课堂出勤情况。其次，行为分析具有明显的时间序列特征。校园活动通常按照课程安排、作息时间等规律进行，模型在推理时需要考虑行为的连续性与顺序关系。例如在智慧课堂中，通过融合课堂视频、教师语音和学生动作数据，可以分析课堂互动过程、学习参与度以及教学节奏，从而实现对课堂行为的时序理解
4.5.4	校园多模态生成大模型	生成多样化训练数据，提升监控识别算法对复杂环境的适应能力；同时还能对低清监控画面进行超分辨率重建或补全，提高取证与识别效率
4.5.5	校园模型融合	融合上述多模态系列模型与平安城市已建设专业模型，实现对校园周边可疑人员的识别和管理；对校园进行安全监测预警，如宿舍着火、实验室烟雾、食堂烟雾火灾监测、电瓶车安全风险等；对异常行为的预警，如打架斗殴、持刀持械、非法聚集、异常标语、校园霸凌行为、学生进入危险区域风险监测、踩踏

		事件预防和分析等；对校园日常管理起到辅助作用，如食堂的卫生和环境监测、保安脱岗/睡岗监测、设施设备损坏监测等。通过智慧安防赋能校园安全，完善校园安全防控体系，综合提升校园安全管理水平，构建安全、和谐稳定的校园环境
4.6	平安园区	
4.6.1	园区多模态表征模型	多模态表征模型在园区场景中的核心作用，是将来自视频监控、物联网传感器、门禁系统、设备日志、文本记录等多源异构数据进行统一语义建模，从而实现对园区人员、车辆、设备、环境与事件的综理解与联动决策。与通用场景中的多模态表征应用相比，园区场景更强调场景结构化、实体关系稳定以及实时运行闭环：模型不仅需要融合多模态信息，还要结合园区空间拓扑、业务流程和设备状态形成可执行的事件理解与管理能力
4.6.2	园区多模态理解大模型	本模型定位于园区综合治理与安全保障体系中的风险识别核心，承担对园区场景中异常行为、违规操作及突发事件进行自动检测与分级预警的作用，是实现园区安全运行与高效管理的重要技术支撑。在功能层面，模型基于视频时序分析与行为模式建模能力，对异常聚集、非法闯入、越界入侵、危险作业行为、长时间滞留、设备异常操作及突发冲突等情况进行识别与分类，并输出事件类型、发生时间、空间位置及关联目标信息；同时支持异常等级评估与联动响应机制，可与安防平台、门禁系统及应急处置流程对接，为园区安全管控与运营管理提供实时、精准、可追溯的智能预警能力
4.6.3	园区多模态时空推理大模型	多模态时空推理模型在园区场景中的作用，是对视频、物联网传感器、门禁记录、车辆轨迹、设备状态及文本事件等多源数据进行跨模态融合，并结合时间序列与空间拓扑关系进行持续推理，从而实现对园区内人员活动、车辆流动、设备运行及异常事件的动态理解、预测

		与联动处置。与通用场景中的多模态推理（如开放环境的视频理解或跨模态问答）相比，园区应用更强调强约束的物理空间结构、持续的时间演化以及明确的运营目标：模型需要基于园区的区域划分、路径网络和业务规则进行因果与轨迹推断，重点解决事件演化判断、跨系统关联分析和实时决策支持问题，因此其核心区别在于从“内容理解型推理”转向面向实体关系与时空行为演化的业务驱动型推理
4.6.4	园区多模态生成大模型	生成多样化训练数据，提升监控识别算法对复杂环境的适应能力；同时还能对低清监控画面进行超分辨率重建或补全，提高取证与识别效率
4.6.5	园区模型融合	融合多模态系列模型与园区已建专业模型，一是实现园区人员车辆管控，包括员工考勤、访客管理、陌生人员徘徊、车辆违停、危化品车辆监管等；二是构建安全风险预警体系，覆盖消防通道堵塞、烟雾火灾、危险区域闯入、未佩戴安全装备等监测；三是提升日常管理水平，包括安保脱岗睡岗监测、周界入侵、物资防盗、设备故障监测等。通过智慧安防赋能园区数字化管理，全面提升安全防范能力与运营效率，构建安全、高效的现代化园区环境
4.7	平安乡村	
4.7.1	乡村多模态表征模型	本模型定位于乡村数字化治理体系中的基础感知核心，承担对乡村场景图像与视频数据进行全要素结构化解析的作用，是后续行为分析、事件识别与资源管理应用的底层数据支撑。在功能层面，模型支持对人员、车辆、农机设备、牲畜、道路、农田、水体、房屋建筑及公共设施等要素进行检测与分类，并输出目标类别、空间位置及基础属性信息；同时可适应乡村环境中复杂光照、开放场景与多样化目标形态，实现乡村视图的全面数字化表达，为乡村安全治理、农业生产监管及公共资源管理提供标准化视觉数据基础
4.7.2	乡村多模态理解大模型	本模型定位于乡村安全治理与风险防控

		体系中的智能预警核心，承担对乡村场景中异常行为与突发事件进行自动识别、实时研判与分级告警的作用，是提升基层治理数字化与精细化水平的重要技术支撑。在功能层面，模型基于视频时序建模与场景规则匹配能力，对非法闯入、盗窃行为、夜间异常活动、异常聚集、秸秆违规焚烧、牲畜异常集散、河道异常作业等情况进行识别与分类，并输出事件类型、发生时间、空间位置及关联目标信息；同时支持异常等级评估与联动处置机制，可与村级综治平台及应急响应流程对接，为乡村公共安全、生态保护及社会治理提供及时、精准、可追溯的智能预警能力
4.7.3	乡村多模态时空推理大模型	模型需对乡村区域中的人员活动、车辆流动、异常事件与环境变化进行持续理解与预测，从而提升安防预警与事件处置能力。与通用场景中的多模态推理主要侧重跨模态语义理解或通用事件判断不同，乡村安防更强调稀疏监控条件下的时空关联推断、地理空间约束以及长时间尺度的行为模式识别，模型需要在监控覆盖不均、数据模态不完整和事件发生低频但影响较大的环境中进行综合推理，因此更加依赖时空上下文整合与区域治理知识来支撑实际安防决策
4.7.4	乡村多模态生成大模型	生成多样化训练数据，提升监控识别算法对复杂环境的适应能力；同时还能对低清监控画面进行超分辨率重建或补全，提高取证与识别效率
4.7.5	乡村模型融合	融合上述多模态系列模型与平安乡村已建设专业模型，实现村庄出入口异常人员、车辆监测和关注人群管理监测，实现乡村地区的鱼塘水库守护、果园农场守护、养殖场守护等，保障村民人身财产安全，自动开展治安巡逻监测、河沟治理监测、危险区域落水监测，对非法电鱼、摩电违规驾乘、公路晒场等行为事件进行实时监测预警，通过智慧安防技术手段，为构建更高水平的平安乡村注入更强的技术动力，助力打造打防管控一体的乡村治安防控及公共服务体

		系，提升乡村安全防范能力，促进乡村智慧化进程
4.8	平安机场	
4.8.1	机场多模态表征模型	在机场场景中应用的多模态表征模型在训练时通常具有强场景约束、结构化业务语义以及跨模态时空信息融合等特性：模型需要同时对接视频监控图像、安检图像、文本信息（航班信息、告示牌、广播文本）、传感器或行为日志等多源数据，因此训练过程中更强调视觉-文本-行为数据的语义对齐。模型通常需要具备对复杂光照、遮挡、人群密集环境的鲁棒性，以及对细粒度目标与长尾事件的表征能力，以适应机场真实运行环境中高动态、多主体和安全敏感的特点
4.8.2	机场多模态理解大模型	机场场景中的行为事件相比通用安防场景具有安全等级高、人员规模大、管控区域分级严格和风险类型更具安全敏感性等特点。机场属于重要交通枢纽和重点防护单位，人员流量大且来源复杂，安防不仅需要关注一般异常行为，还需重点识别遗留物品、异常徘徊、人员聚集、闯入限制区域、尾随通行等事件。同时机场通常划分为公共区、控制区和隔离区等多级管控区域，不同区域对人员行为和通行权限要求严格，因此行为事件识别需要结合旅客流程与区域权限管理进行分析，并具备高准确度和实时响应能力，以保障航空运行安全和旅客秩序。
4.8.3	机场多模态时空推理大模型	本模型定位于机场全域态势感知与智能研判核心，通过整合视频监控、航班动态、旅客行李轨迹、安检过检及门禁通行等多维数据，构建覆盖航站楼、空侧陆侧的立体化时空关系模型。实现对旅客、工作人员、行李货物及保障车辆的全轨迹追踪与行为预测，支撑安防管控、运行调度优化及应急处置决策
4.8.4	机场多模态生成大模型	生成多样化训练数据以覆盖不同光照、角度、遮挡和天气等复杂场景，从而提升监控识别算法在真实环境中的泛化能力；同时，通过对低清监控画面进行超

		分辨率重建与细节补全，可有效提升图像清晰度与关键信息可辨性，进而提高识别的准确性和效率
4.8.5	机场模型融合	融合上述多模态系列模型与平安机场已建设专业模型，实现对机场内部及周边的全面监控和管理，人员、车辆与物品的全流程监测与管控，包括周界入侵防护、重点区域访问控制及异常行为识别等能力。对关键区域、重点设备、危险品运输及重点关注人员进行动态管控，实现身份核验、行为分析和轨迹追踪等能力
4.9	平安医院	
4.9.1	医院多模态表征模型	医院环境具有人员类型复杂（医护、患者、访客、医闹）、活动模式差异明显、关键区域安全等级不同等特点，因此模型通常需要强化细粒度行为识别、区域语义理解和异常模式的表征能力。需重点学习人员行为、空间区域，以实现对异常行为（如闯入限制区域、长时间徘徊、医患冲突、患者跌倒等）的有效表征
4.9.2	医院多模态理解大模型	医院安防场景中的行为事件相比通用安防场景具有人员构成复杂、行为类型特殊、风险事件多样和安全敏感度高等特点。医院属于半开放环境，人员流动频繁，既包含医护人员、患者和家属等多类角色，又存在推送病人、陪护聚集等特殊医疗行为，因此在行为识别上需要区分正常医疗活动与异常事件。同时，医院更容易出现医疗纠纷、情绪冲突、跌倒走失等风险事件，并且药房、ICU、手术室等重点区域对非法进入和异常行为的管控要求较高。因此，医院安防行为事件识别需要结合医疗业务场景，实现更精准的判别和应急处置
4.9.3	医院多模态时空推理大模型	本模型定位于医院智慧运营管理中枢，通过关联视频监控、患者就诊轨迹、医护定位、医疗设备状态及药品流转等异构数据，建立跨院区、跨科室的精细化时空映射。实现对患者、医护人员、物资设备的全流程动线分析，赋能安防预警、医疗质量监管及服务效率提升

4.9.4	医院多模态生成大模型	生成多样化训练数据，提升监控识别算法对复杂环境的适应能力；同时还能对低清监控画面进行超分辨率重建或补全，提高识别效率
4.9.5	医院模型融合	融合上述多模态系列模型与平安医院已建设专业模型，实现未戴脱岗离岗、医疗纠纷、安全事件、紧急救治通道保障等进行监测和智能预警，提升监管效率，增强透明度，促进行业自律，提升医疗过程安全监管的效率和水平
4.10	环保安防	
4.10.1	环保多模态表征模型	本模型定位于生态环境监测与治理体系中的基础感知核心，承担对环境监控视频及图像数据进行全要素结构化解析的作用，为污染识别、风险研判与执法监管提供标准化数据支撑。在功能层面，模型支持对河道水体、烟囱排放、扬尘区域、垃圾堆放、渣土车辆、裸土覆盖情况、植被状态及相关作业设备等要素进行检测与分类，并输出目标类别、空间位置及状态属性信息；同时具备适应复杂光照、远距离观测及气候变化条件的鲁棒性，实现环境要素的数字化表达与动态监测，为环保巡查、污染溯源及治理评估提供可靠的视觉数据基础
4.10.2	环保多模态理解大模型	本模型定位于生态环境监管与污染防控体系中的智能预警核心，承担对环境监控场景中异常排放与违规行为进行自动识别、快速研判与分级告警的作用，是提升环保执法效率与精准监管能力的重要技术支撑。在功能层面，模型基于视频时序分析与环境要素建模能力，对异常烟气排放、黑烟超标、扬尘异常升高、露天焚烧、非法倾倒垃圾、渣土车违规覆盖不严及水体异常颜色变化等情况进行识别与分类，并输出事件类型、发生时间、空间位置及关联主体信息；同时支持风险等级评估与联动处置机制，可对接环保监管平台与执法流程，实现实时预警、证据留存与事后溯源分析，为环境治理与污染防控提供精准、可追溯的智能化支撑能力
4.10.3	环保多模态生成大模型	生成多样化训练数据，提升监控识别算

		法对复杂环境的适应能力；同时还能对低清监控画面进行超分辨率重建或补全，提高取证与识别效率
4.10.4	环保模型融合	融合上述多模态系列模型与环保安防已建设专业模型，实现对涉及环境保护的安防智能化监控、管理和优化。通过实现烧桔杆检测、河道漂浮监测、垃圾乱堆放监测、工厂废气排放监测、工厂扬尘监测、违规排污识别、裸土未覆盖、车辆冒黑烟等智能场景的应用，可以有效提升管理效率，降低环境污染，促进节能减排，为环保过程提供了全面、高效、便捷的安全保障
4.11	平安工地	
4.11.1	工地多模态表征模型	本模型定位于施工现场智能监管体系中的基础感知核心，承担对工地场景进行全要素结构化解析的作用，为安全管理、作业监督与风险识别提供标准化视觉数据支撑。在功能层面，模型支持对施工人员、工程车辆、塔吊设备、脚手架、物料堆放区、安全防护设施及作业区域边界等要素进行检测与分类，并输出目标类别、空间位置、数量统计及基础属性信息；同时可适应粉尘、强光、遮挡及复杂动态环境，实现对施工现场运行状态的全面数字化表达，为安全生产管理与精细化施工监管提供可靠的数据基础
4.11.2	工地多模态理解大模型	本模型定位于施工现场安全生产与风险防控体系中的智能预警核心，承担对工地场景中异常行为、违规作业及突发安全事件进行自动识别与分级告警的作用，是实现安全生产闭环管理的重要技术支撑。在功能层面，模型基于视频时序分析与作业规范规则建模能力，对未佩戴安全帽或反光衣、危险区域违规进入、高空抛物、人员跌落、机械设备异常运行、明火作业异常及异常聚集等情况进行识别与分类，并输出事件类型、发生时间、空间位置及关联目标信息；同时支持风险等级评估与联动响应机制，可与现场管理平台、广播系统及应急处置流程对接，实现实时预警、过程

		留痕与事后溯源分析，为施工现场安全监管与生产管理提供精准、可靠的智能保障能力
4.11.3	工地多模态生成大模型	生成多样化训练数据以覆盖不同光照、角度、遮挡和天气等复杂场景，从而提升监控识别算法在真实环境中的泛化能力；同时，通过对低清监控画面进行超分辨率重建与细节补全，可有效提升图像清晰度与关键信息可辨性，进而提高目标识别与取证分析的准确性和效率
4.11.4	工地模型融合	融合上述多模态系列模型与平安工地已建设专业模型，实现未系安全带、未戴安全帽、违反安全流程、工服合规性、未穿反光衣、吸烟、化学品泄漏监测、火情、安全风险、危险动作、机械臂下站人、区域禁入等异常行为事件的智能监测，提升安全生产领域对工地风险的感知能力、预警能力和处置效率，可有效降低安全事故的发生率，提升工地安全生产水平
4.12	平安铁路	
4.12.1	铁路多模态表征模型	对火车站、铁路沿线的人员及物品进行建模，支持目标检索、相似度匹配、零样本分类、跨域迁移等能力，可应用于人脸识别、人体识别、车辆识别及聚类分析等模块的底层特征支撑引擎
4.12.2	铁路多模态理解大模型	本模型定位于铁路运营安全保障体系中的智能风险识别核心，承担对铁路沿线及站场场景中的异常行为与突发事件进行自动检测、快速研判与分级预警的作用，是保障行车安全与运营稳定的重要技术支撑。在功能层面，模型基于视频时序分析与场景规则建模能力，对人员侵入轨道、翻越围栏、滞留线路、抛掷异物、设备异常状态、烟火异常及可疑聚集等情况进行识别与分类，并输出事件类型、发生时间、空间位置及关联目标信息；同时支持风险等级评估与联动处置机制，可与调度系统、报警系统及应急响应流程对接，实现实时告警、闭环处置与事后溯源分析，为铁路运行安全与综合管控提供高可靠性的智能预警能力

4.12.3	铁路多模态时空推理大模型	本模型定位于铁路网络安全运营与运力调度决策引擎，通过融合视频监控、列车运行图、旅客出行链、票务信息及线路设备状态等数据，搭建跨车站、跨线路的网络化时空分析框架。实现对旅客、作业人员、列车车辆及关键设施的全链条轨迹还原与风险预判，保障客运安全与运输秩序
4.12.4	铁路多模态生成大模型	生成多样化训练数据，提升监控识别算法对复杂环境的适应能力；同时还能对低清监控画面进行超分辨率重建或补全，提高取证与识别效率
4.12.5	铁路模型融合	融合上述多模态系列模型与平安铁路已建设专业模型，实现对火车站、铁路沿线的异常事件识别、特殊人员发现、人员行为识别、人员物品识别查找、目标轨迹生成等更实时、准确的监测和预测能力，给出处理建议或工单触达到责任人
5	模型推理优化	
5.1	安防行业大模型量化压缩与蒸馏算法研究	
5.1.1	模型可压缩性分析	(1) 各层量化 bit 推荐范围 (2) 剪枝比例建议 (3) 蒸馏难度评估
5.1.2	量化算法研究	(1) PTQ (Post-Training Quantization) (2) QAT (Quantization Aware Training) (3) 超低比特量化
5.1.3	模型剪枝研究	(1) 非结构化剪枝 (2) 结构化剪枝
5.1.4	低秩分解	(1) 超大模型压缩 (2) 微调场景
5.1.5	知识蒸馏	(1) Logits 蒸馏 (2) 中间层蒸馏 (3) 多任务蒸馏
5.1.6	混合压缩策略	(1) 自动组合策略 (2) 搜索压缩超参数 (3) 精度-延迟 Pareto 优化
5.1.7	精度对齐优化	(1) 小规模再训练 (2) LoRA 微调恢复 (3) 对齐再优化
5.1.8	性能评估与基准测试	(1) 精度指标

		(2) 效率指标 (3) 稳定性指标
5.2	模型国产化适配与加速	
5.2.1	硬件适配与抽象模块	(1) 统一算子接口 (2) 统一内存接口 (3) 精度格式适配 (FP32 / BF16 / FP16 / INT8 / INT4) (4) 设备能力探测 (算力、显存、带宽)
5.2.2	算子级优化模块	(1) Kernel Fusion (2) Tensor Core 利用 (3) Warp-level 优化 (4) Tile 优化 (5) 内存对齐优化
5.2.3	高效 Attention 优化模块	(1) FlashAttention (2) PagedAttention (3) Multi-Query Attention (4) KV Cache 压缩
5.2.4	并行与分布式执行模块	(1) 单卡优化 (批量合并、动态 batching) (2) 多卡优化 (Tensor Parallel、Pipeline Parallel、Data Parallel) (3) 多机优化 (异步调度)
5.2.5	精度与量化适配模块	(1) 动态精度切换 (2) INT8 / INT4 推理支持 (3) BF16 自动适配 (4) 混合精度 fallback 机制
5.2.6	推理调度与负载均衡模块	(1) 动态批处理 (2) 请求排队策略 (3) 优先级调度 (4) 限流机制 (5) 异步执行
5.2.7	性能监控与分析模块	(1) GPU 利用率 (2) 显存使用率 (3) Kernel 时间分析 (4) 通信耗时 (5) 瓶颈定位
5.3	大小模型协同	结合大模型的强大计算能力和小模型的灵活性，以实现更高效、更适应性强的智能系统
5.4	端边云结合	云算力中心负责训练和推理；边缘设备上的大模型平台负责对经过剪枝、量化、蒸馏等操作的压缩模型进行微调和推

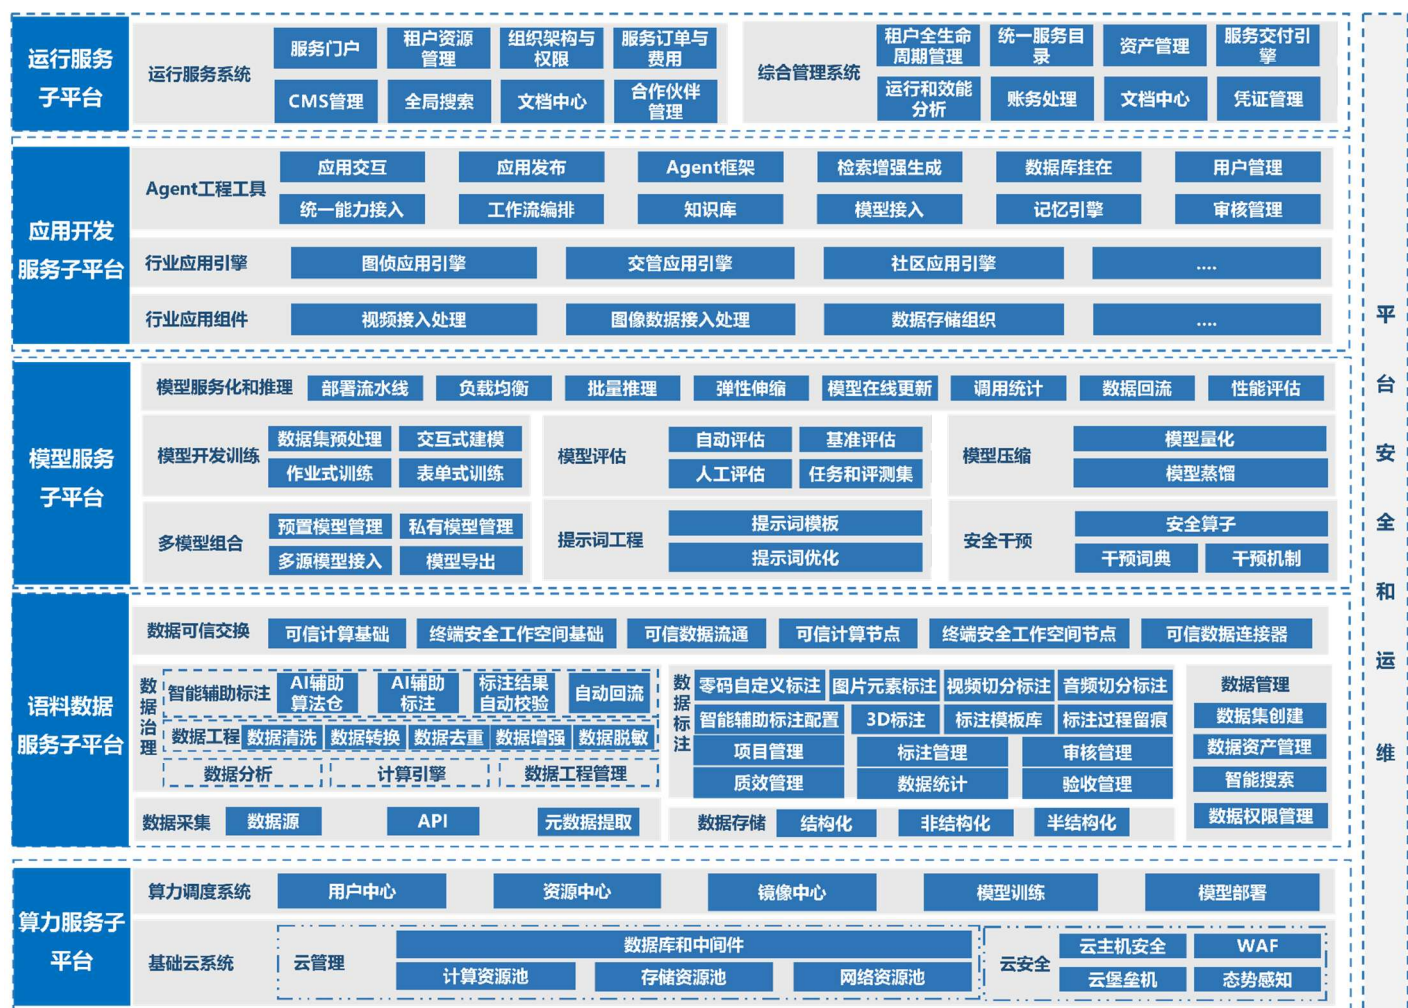
		理；端侧设备则通过调用云算力中心实现数据回流以及小模型推理。
--	--	--------------------------------

6.1.5 安防行业人工智能共性服务平台建设方案

基于安防行业生态伙伴对人工智能研发应用的共性需求，项目拟集约建设人工智能共性服务平台，形成覆盖算力调度、数据集管理、模型训练、高效微调、模型管理、模型评测、应用开发、推理应用的全流程 AI 服务能力，形成安防人工智能研发工具链，为行业内企事业单位和人工智能企业、高校、科研院所参与基地共建共创提供标准化、组件化、模块化的工具支撑，为行业用户提供安防行业大模型通用能力推理服务，从而有序引导数据、算法、人才在基地形成汇聚，一体化推进研发攻关、应用迭代和生态培育。

6.1.5.1 总体框架

安防行业人工智能共性服务平台整体架构分为算力资源服务、数据服务、模型服务、应用开发和运行服务共5个子平台，平台整体架构如图132所示。



平台安全和运维

图 132 技术架构

算力服务子平台：作为基础设施支撑，提供丰富的算力资源，以虚拟化、服务化的方式动态分配和高效管理算力资源，为用户提供引擎更灵活、可扩展的计算能力支持，包括：

- （1）可实现对 CPU、GPU 的智能算力调度与精准分配。
- （2）支持异构计算容器，能良好兼容各类 GPU。
- （3）支持分布式块存储、并行文件存储和海量云存储多种方式。
- （4）提供多种算力调度系统。
- （5）兼容百度飞桨、华为昇思等多种深度学习框架。

语料数据服务子平台：作为数据处理的核心枢纽，主要负责数据全生命周期管理。主要功能包括：

- （1）遵循视频联网标准，通过视频联网平台接口进行数据采集。通过 API 接口、数据源进行数据接入。
- （2）通过数据看板对数据分布、任务分布、质量指标等关键指标数据动态展示，实现对平台数据使用情况实时监测与多维分析。
- （3）支持结构化、非结构化、半结构化等多种数据存储形式。提供数据清洗、数据增强、数据标注、数据同步等多种数据工程工具。
- （4）支持数据可信交换、融合共享，配置安全策略与空间管理规则，确保数据安全。
- （5）实现数据集的创建、发布、加密封装及权限管理。

模型服务子平台：作为一站式大模型服务平台，为模型开发者提供模型全生命周期管理能力，包括：

- （1）多模型组合工具支持对模型进行统一纳管和展示，支持模型类型、分类、框架等多维度筛选，方便用户快速了解平台已有模型，并进行便捷的训练和部署。
- （2）模型工程工具提供语言、视觉、语音、多模态等模型的训

练和调优功能，包括 SFT 训练、post-pretrain 训练、强化学习训练、模型蒸馏等功能。同时也具备模型推理功能，支持直接将模型发布为模型服务，对外提供标准化服务。整体对训练任务、推理任务、模型、提示词进行管理。

应用开发服务子平台：专注于行业应用的开发与发布，构建安防行业的 AI 应用，包括：

（1）行业应用组件针对各类场景应用，提供行业通用的组件库，为应用开发提供便捷可快速直接调用的组件库。

（2）行业应用引擎提供针对如图侦、交管、社区等应用场景的特有服务能力集合。

（3）Agent 工程工具聚焦于应用开发与发布，包括应用交互、调试、发布及 Agent 框架搭建、知识库调用等操作，支持检索增强生成等。

（4）行业应用场景图谱覆盖智慧图侦、智慧交管、平安城市、平安社区等众多领域，助力实现行业融合应用开发，将模型与数据能力转化为服务实战的行业应用。

运行服务子平台：以“需求对接+全链路服务+生态协同”为核心，面向租户与生态伙伴的统一服务入口，对外提供 AI 能力和产品，同时对内具备能力管理、资源管理、租户管理、AI 资产管理等功能，包括：

（1）运行服务系统提供 AI 能力和产品的展示、资源申请、能力开发、订单结算、生态对接等全场景租户需求，实现从需求发现、资源获取到服务使用、问题反馈的全链路闭环。

（2）综合管理系统提供租户管理、订单管控、效能分析、资产交付、身份认证等全场景需求，为前台运行服务系统提供全链路、一

体化的底层支撑能力。

6.1.5.2 算力服务子平台

算力资源服务子平台采用先进的人工智能计算架构，提供人工智能应用所需算力服务、数据服务、算法服务和算力调度服务的公共算力新型基础设施。通过算力的生产、聚合、调度和释放，高效支撑数据开放共享、智能生态建设、产业创新聚集。算力资源服务为整个共性服务平台提供底层资源支撑，包括计算资源（CPU、GPU 资源）、存储资源、网络资源和安全资源，底层高性能 AI 计算能力提供芯片、服务器、高性能网络等服务。同时，算力资源服务支持使用国产 AI 芯片，来完成部分推理或训练任务。

具体建设模块包括：基础云系统、算力调度系统。

6.1.5.2.1 算力服务子平台架构




图 133 算力资源服务子平台逻辑架构

算力资源服务子平台，兼容适配业界广泛使用的主流硬件、操作系统，对算力资源进行统一管理、调度和监控，同时进行细粒度的资源实时分配，实现海量任务的智能自动调度、任务管理、数据加载和预处理，支撑大模型从数据处理到预训练、微调到多模型管理的整个

研发流程。

算力资源服务设计遵照“分层解耦，异构兼容，统一管理，统一服务”的目标，整合硬件资源，实现硬件资源的共享，通过算力资源服务对基础设施资源进行统一的管理，屏蔽底层硬件的异构性和组网的复杂性。通过计算、存储、网络等虚拟化技术将传统物理设备进行池化处理，构建统一的计算、存储、网络和安全资源池。为上层应用提供运行稳定、安全隔离、按需获取的基础资源服务，以细粒度管理方式充分利用基础设施资源，大幅提高云计算平台基础设施的资源利用率。

基础云系统：是对基础设施的云化管理，通过云管理模块将基础设施层提供的硬件设备按照逻辑功能的不同划分为计算、存储、网络等不同功能的资源池，其中，计算资源池包括云服务器、裸金属服务器、GPU 服务器、容器服务、弹性伸缩服务；存储资源池包括块存储、对象存储、文件存储；网络资源池包括私有网络、弹性公网 IP、专线服务、云解析服务、负载均衡服务；数据库与中间件包括关系型数据库、内存数据库、全文数据库。同时，提供云安全模块，对云内安全进行统一保障。

算力调度系统：算力调度系统是基于基础云系统构建，聚焦智算设备，提供算力资源管理、任务调度、模型优化、故障诊断及性能优化于一体的综合性平台。为用户提供个性化、高效能的算力服务，适配人工智能相关需求，助力构建稳定可靠的高性能计算环境。包括用户中心、资源中心、镜像中心、模型训练、模型部署。

6.1.5.2.2 算力服务子平台技术方案

6.1.5.2.2.1 基础云系统

基础云系统是核心基础设施，提供云管理模块和云安全模块，其

中云管理模块包含计算资源池、存储资源池、网络资源池、数据库与中间件等服务能力。

基础云系统提供领先的虚拟化技术，通过虚拟机和软件定义网络，实现了多租户隔离及组网，对于计算/虚拟机隔离，租户的虚机被创建在指定的计算节点上或将它的虚机部署在指定的专有的服务器上，主要是通过 **Host aggregate** 技术来支持这种需求的实现。存储卷物理隔离，不同租户的卷创建在不同的后端存储上，即支持租户在指定的后端上创建卷 **Volume**。在网络的逻辑隔离，采用 **VxLAN** 等技术模式，不同租户或应用相互隔离，即便在同一个机房内也不可见，有效保证数据的安全性。同时在单地域内可以将部署在多个机房的服务纳入同一个虚拟网络，即可实现多机房冗余。

基础云系统拥有多种存储技术，可针对用户不同应用场景提供量身定制的解决方案。包括块存储、文件存储、对象存储等，支持海量数据的大规模压力考验，能够确保用户的数据安全可靠。

基础云系统提供多种数据库和中间件服务，包括关系型数据库，对性能要求高的 **NoSQL** 存储系统，支持全文检索的弹性搜索服务。

6.1.5.2.2.1.1 云管理模块

6.1.5.2.2.1.1.1 计算资源池

6.1.5.2.2.1.1.2 云服务器




图 134 云服务器架构

云服务器是基于虚拟化技术构建的虚拟服务器，通过整合物理服务器资源，为用户提供一种处理能力可弹性伸缩的计算服务，管理方式比物理服务器更简单高效。根据业务需要，用户可按需配置资源，随时创建或释放任意多台云服务器实例，提升运维效率。

云服务器为用户快速部署应用构建提供稳定可靠的基础，可以降低网络规模计算的难度，使用户更专注于核心业务创新。另外，用户无需再购买及维护托管虚拟机的硬件，使用云服务器能有效降低 IT 成本。

6.1.5.2.2.1.1.3 裸金属服务器




图 135 裸金属服务器产品架构

裸金属服务器是用户可以在云环境中独享的高性能物理裸机，用户拥有完全的物理设备管理权限，同时可以结合弹性公网 IP、负载均衡灵活组网，并与云服务器在内网互通，灵活应对用户多种复杂场景的业务需求，轻松构建内网混合云。

基于智算云提供的裸金属服务器，用户可以在管理控制台便捷的创建和管理云环境中的物理裸机，包括配置裸金属服务器名称、网络 IP，查看硬件配置和创建时间等。

6.1.5.2.2.1.1.4 GPU 服务器




图 136 基地运行组织架构

GPU 服务器是配备独享 GPU 卡的高性能云计算服务，可以帮助用户快速、便捷的获得高质量的 GPU 计算资源，能够大幅提高机器学习及科学计算等大规模计算框架的运行速度，为搭建人工智能及高性能计算平台提供基础架构支持。

GPU 服务器提供两种形态计算资源，虚拟机形态的 GPU 云服务器和物理机形态的 GPU 物理服务器：

（1）GPU 云服务器：提供与标准云服务器一致的管理方式，用户可以快速灵活地申请并管理 GPU 云服务器，结合私有网络 VPC、

负载均衡负载均衡，共同构建云环境中高可用的 GPU 集群。

(2) GPU 物理服务器：当普通 GPU 云服务器无法满足用户的业务要求时，智算云还可以提供租用独享 GPU 物理服务器的服务。并在用户计划搭建超高性能的 GPU 集群时，提供配置更多 GPU 卡(8 卡以上)和高速互联带宽的超高性能的 GPU 物理服务器集群的服务。

6.1.5.2.2.1.1.5 容器服务




图 137 容器服务架构

容器服务基于轻量级虚拟化技术，提供接近物理服务器的高性能容器环境，支持容器全生命周期管理，实现业务快速部署与弹性调整；依托 Kubernetes 与 Docker 构建容器引擎，提供集群动态创建、自动扩缩容、监控运维、镜像及工作负载管理等能力，降低搭建维护成本并提升可观测性与可用性，覆盖计算、网络、存储、权限、日志监控等完整功能模块；支持服务模块拆分与独立部署升级，容器具备独立环境镜像与网络 IP，通过灵活方式实现服务发现，可整合各类云服务构建服务集群，且集群环境迁移、复制便捷，通过镜像选择与访问地址配置即可快速搭建一致新集群。

6.1.5.2.2.1.1.6 弹性伸缩




图 138 弹性伸缩服务架构

弹性伸缩是自动化扩缩容用户云资源的管理服务，当用户业务所需的云资源用量经常性变化时，弹性伸缩会是用户使用云资源的理想方式。

目前弹性伸缩能够帮用户的管理的云资源包括云服务器，以及和云服务器相关的云磁盘和弹性公网 IP 等。支持对这些资源进行自动化的横向扩缩容。

6.1.5.2.2.1.1.7 存储资源池

6.1.5.2.2.1.1.8 云磁盘




图 139 云磁盘架构

云磁盘是一种安全可靠的高弹性存储服务，作为云服务器的扩展块存储部件，为云服务器数据存储提供高可用和高容量支持。有独立于云服务器的生命周期，支持快速扩容、在线备份和回滚。

云磁盘支持数据的随机读写，在吞吐量，IOPS 以及异常恢复时间等方面，都有不错的性能，能够满足大部分客户在各类场景下的使用需求。

云磁盘具有独立于云服务器的生命周期，并支持在线扩容，在线转换云磁盘类型，通过自动快照进行容灾备份和磁盘回滚等众多弹性管理功能。

相比本地盘，云磁盘采用三副本或纠删码技术对磁盘数据进行存储。若部分存储节点，存储介质或网络交换机发生意外故障，数据会立即迁移到其它节点，用户对数据的访问不会受到任何影响，更不会

感知到组件故障的发生。

6.1.5.2.2.1.1.9 对象存储




图 140 对象存储架构

对象存储，是一种以对象为单位，将数据、元数据和唯一标识符组合存储的分布式存储架构，具有高扩展性、高持久性和高可用性特点，对外提供统一的存储接口服务。

支持常见的访问接口统一访问，通过标准的 RESTful API 接口提供服务，支撑多种业务需求。对象存储支持多数据中心多活。

支持不同类别数据存放到不同存储类型，以降低总存储成本，同时满足服务要求。

6.1.5.2.2.1.1.10 网络资源池

6.1.5.2.2.1.1.11 私有网络