

模块（如输出层、**Attention** 投影层）等策略，在控制计算成本的同时最大化精度恢复效果。

在对齐再优化方面，模块重点关注模型输出行为与目标标准之间的一致性，包括任务目标对齐、风格一致性与安全合规约束。可结合 **SFT**（**Supervised Fine-Tuning**，即监督微调）、偏好优化或轻量级对齐数据进行再训练，强化模型在关键场景下的稳定性与可靠性。整体机制强调“压缩—恢复—对齐”的闭环优化流程，在保持高压缩率的同时确保性能指标与行为表现达到可上线标准。

6.1.4.7.1.8 性能评估与基准测试

性能评估与基准测试模块用于对模型在压缩、优化或迭代后的综合表现进行系统验证，从精度、效率与稳定性三个维度构建多指标评估体系，为上线决策与版本对比提供量化依据。

在精度指标方面，根据任务类型选取对应评价标准，例如分类任务的 **Accuracy**、**F1-score**，生成任务的 **BLEU**、**ROUGE** 或 **Perplexity**，多模态任务的 **Recall@K**、**mAP** 等；同时可结合行业自定义指标与场景测试集进行专项评估，分析不同任务子集或难度区间的性能分布，确保模型能力提升具有统计显著性与业务相关性。

在效率指标方面，重点衡量模型在真实部署环境下的资源消耗与响应能力，包括推理延迟、吞吐量、显存占用、参数规模、**FLOPs** 等；在多机多卡或边缘部署场景下，还需评估扩展效率与带宽利用率，确保优化策略带来实际系统收益。

在稳定性指标方面，评估模型在长时间运行与复杂输入场景下的鲁棒性与一致性，包括输出波动性、数值稳定性（是否出现 **NaN/Inf**）、异常输入容错能力以及多轮对话一致性等。可结合压力测试与对抗样本测试进行验证。整体模块通过标准化评测流程与自动化基准对比工

具,构建可重复、可追踪的评估体系,支撑模型版本迭代与工程决策。

6.1.4.7.2 模型国产化推理适配与加速

行业模型国产化适配与加速模块聚焦于行业大模型在国产算力平台上的高效运行与性能优化,目标是在保证模型精度与稳定性的前提下,充分释放国产硬件架构的计算潜力,实现可控、安全、低成本的部署能力。

6.1.4.7.2.1 硬件适配与抽象模块

硬件适配与抽象模块旨在构建模型框架与底层算力之间的统一抽象层,实现跨硬件平台的可移植性与性能可控性,是模型工程体系中的关键基础设施。

在统一算子接口方面,模块对矩阵乘法、Attention、LayerNorm、卷积、激活函数等核心算子进行标准化封装,屏蔽不同硬件后端(GPU、NPU、CPU等)之间的实现差异,通过统一API进行调度与调用;同时支持算子自动选择与融合优化,根据设备特性选择最优内核实现或执行图优化。在统一内存接口方面,模块抽象显存与主存管理机制,统一管理张量分配、释放、缓存复用与数据拷贝策略,支持异步数据传输与计算重叠,减少内存碎片与数据搬移开销。

在精度格式适配方面,模块支持多种数值格式,包括FP32、BF16、FP16、INT8、INT4等,能够根据设备能力与部署需求自动选择或混合精度执行策略,并处理不同精度间的数据转换与缩放问题,确保数值稳定性与性能平衡。在设备能力探测方面,模块在运行时自动检测设备算力、显存容量、内存带宽与并行单元规模等关键指标,据此动态调整并行策略、批大小、量化级别与缓存配置,实现资源感知型调度与自适应优化。整体模块通过“算子抽象+内存抽象+精度适配+能力感知”机制,构建软硬件解耦且高效协同的运行基础架构。

6.1.4.7.2.2 算子级优化模块

算子级优化模块聚焦于底层计算内核的性能提升，通过对关键算子执行路径进行细粒度优化，最大化硬件利用率与吞吐能力，是高性能推理与训练系统的重要加速手段。

在 **Kernel Fusion** 方面，通过将多个连续算子（如 **MatMul+Bias+Activation+LayerNorm**）进行融合，减少中间张量写回与显存访问次数，降低内存带宽压力与 **kernel launch** 开销，从而提升整体执行效率。在 **Tensor Core** 利用方面，针对支持矩阵加速单元的硬件平台，优化矩阵维度对齐与数据排布格式，使计算路径能够调用专用矩阵乘法单元，实现高吞吐混合精度计算。

在 **Warp-level** 优化层面，通过线程束级协同与共享内存优化，减少线程分支与同步开销，提升并行执行效率；在 **Tile** 优化方面，通过分块计算策略优化数据复用与缓存命中率，合理规划寄存器与共享内存占用，避免访存瓶颈。最后，在内存对齐优化方面，通过对齐数据结构、优化张量布局（如行主序/列主序或特定块布局）与向量化加载方式，降低非对齐访问带来的性能损耗。整体模块强调“计算-访存-调度”协同优化，在算子级别实现高效、稳定且可扩展的性能提升。

6.1.4.7.2.3 高效 Attention 优化模块

高效 **Attention** 优化模块聚焦于降低自注意力机制在长序列与大规模推理场景下的计算与显存开销，是提升大模型吞吐能力与推理效率的核心优化方向。

在 **FlashAttention** 方面，通过块状计算与在线 **softmax** 归一化策略，将 **Attention** 计算重构为 **IO-aware** 算法，显著减少显存读写次数，实现接近理论带宽上限的执行效率，尤其适用于长序列训练与推理场景。

在 Paged Attention 方面（如 vLLM 中的实现），通过将 KV 缓存分页管理并映射至非连续显存区域，提高显存利用率与批量推理吞吐能力，特别适用于多请求并发场景。

在结构层面，Multi-Query Attention (MQA) 通过共享键值对投影，仅保留多头 Query，显著降低 KV 缓存存储规模与内存带宽需求，在推理阶段能够有效减少显存占用与访问开销。进一步地，模块支持 KV 缓存压缩策略，包括低比特量化、分组压缩、滑动窗口裁剪或基于重要性评分的历史词元剪枝，以控制长上下文场景下的显存增长。整体模块围绕“计算重构+存储优化+结构简化”三条主线，系统提升 Attention 机制在高并发与长序列条件下的性能与可扩展性。

6.1.4.7.2.4 并行与分布式执行模块

并行与分布式执行模块用于提升大模型在不同规模算力环境下的执行效率与扩展能力，覆盖单卡、多卡及多机场景，是实现高吞吐与低延迟部署的关键基础模块。

在单卡优化方面，模块通过批量合并与动态分批技术，将多个小请求在运行时自动聚合为统一批次执行，提高算力利用率与吞吐效率；同时结合算子融合、显存复用与 KV 缓存管理优化，减少碎片化计算与频繁调度带来的性能损耗，提升单卡资源使用率与响应稳定性。

在多卡优化方面，模块支持主流并行策略，包括张量并行（将单层计算拆分到多卡执行）、流水线并行（将不同层分布到不同设备）、以及数据并行（通过多副本同步梯度更新）。可根据模型规模与网络拓扑设计混合并行策略，在计算负载、通信成本与显存占用之间取得平衡，提升整体扩展效率。

在多机优化方面，模块支持跨节点分布式调度与异步执行机制，通过梯度异步更新、通信压缩与计算通信重叠等方式降低网络瓶颈影

响；同时结合任务调度与资源感知分配策略，实现大规模集群环境下的高效运行与弹性扩展。整体模块构建“单卡优化—多卡并行—多机协同”三级并行体系，实现从边缘部署到数据中心级推理的全场景覆盖。

6.1.4.7.2.5 精度与量化适配模块

精度与量化适配模块用于在不同硬件能力与部署场景下，实现模型数值精度的动态调度与稳定运行，在性能、显存占用与精度损失之间取得工程化平衡。

在动态精度切换方面，模块支持根据运行负载、设备能力或任务类型，在 FP32、BF16、FP16与低比特整型之间进行运行时切换，实现资源感知型精度调度；例如在高并发场景下降低精度以提升吞吐，在关键任务阶段切换至高精度保障输出质量。在 INT8/INT4推理支持方面，模块集成低比特量化算子与校准机制，支持对权重与激活值进行整型推理，并结合缩放因子管理与误差补偿策略，确保数值稳定性与性能提升效果。

在 BF16自动适配方面，模块根据设备是否支持 BF16原生指令集自动选择执行路径，在支持的平台上优先启用 BF16计算以获得更好的数值范围与计算效率；若设备不支持，则自动回退至 FP16或 FP32。通过混合精度 **fallback** 机制，当检测到数值异常（如溢出、NaN、梯度不稳定）或性能异常时，系统可对特定层或算子自动回退至更高精度执行，实现分层精度控制与局部容错。整体模块强调“精度自适应+稳定性保障+性能最大化”的协同设计，支撑多平台、多场景下的高效部署。

6.1.4.7.2.6 推理调度与负载均衡模块

推理调度与负载均衡模块用于在高并发、多租户或多业务场景下，

实现推理资源的高效分配与稳定运行，保障系统吞吐能力、响应时延与服务质量。

在动态批处理方面，模块在运行时对短时间窗口内到达的请求进行自动聚合，形成最优批大小执行，从而提升硬件利用率与整体吞吐；同时结合最大等待时间阈值控制，避免过度聚合导致尾延迟上升。在请求排队策略方面，支持 **FIFO**、基于最短剩余时间或自定义权重队列等策略，平衡吞吐与延迟需求，避免热点请求导致系统拥塞。

在优先级调度方面，模块支持按用户等级、业务类型或任务紧急程度分配优先级，实现关键业务优先保障；结合限流机制，可对单位时间请求数或并发数进行控制，防止流量突发对系统稳定性造成冲击。同时支持异步执行与事件驱动架构，使请求处理与结果返回解耦，提升资源利用率并减少阻塞等待时间。整体模块通过“调度策略+批处理优化+流量控制+异步架构”构建弹性推理服务体系，在高负载环境下实现稳定、可扩展的模型服务能力。

6.1.4.7.2.7 性能监控与分析模块

性能监控与分析模块用于对模型训练与推理过程中的关键系统指标进行实时采集、分析与诊断，是保障高性能运行与持续优化的重要支撑模块。

在资源利用率监控方面，模块实时采集 **GPU** 利用率与显存使用率，分析计算单元占用情况、显存峰值与碎片化程度，识别算力空闲或显存瓶颈问题；同时可结合批大小、并行策略与 **KV** 缓存使用情况进行关联分析，评估资源利用效率。

在执行路径分析方面，模块支持内核级时间分析，统计各算子执行耗时、调用频率与占比，识别热点算子与低效路径；同时监控多卡或多机场景下的通信耗时，包括梯度同步时间、参数广播时间与带宽

利用率，评估通信与计算是否有效重叠。基于上述指标，模块提供瓶颈定位机制，通过时间分解与阶段占比分析（如前向、反向、优化器更新、数据加载等），快速判断性能瓶颈来源是计算受限、内存受限还是通信受限，从而为算子优化、并行策略调整或系统调度改进提供明确依据。整体模块强调可观测性与可量化分析能力，支撑模型系统的持续性能优化与容量规划。

6.1.4.7.3 大小模型协同

大模型与小模型的协同进化是人工智能领域的一个重要发展趋势，它旨在结合大模型的强大计算能力和小模型的灵活性，以实现更高效、更适应性强的智能系统。项目将通过以下手段/步骤实现大小模型协同：通过轻量级预处理模块结合预设任务分配规则，根据任务的复杂度、数据特征和响应时间需求，决定任务是由大模型处理还是小模型处理；通过共享存储以及消息队列经由数据格式转换模块保证在大小模型之间高效传输数据，确保大小模型协同工作；在任务完成后，对大模型和小模型的结果进行验证和比对，确保结果的准确性和一致性；实时监控大模型和小模型的性能（包括响应时间、准确率和资源使用情况）发现问题及时调整；基于反馈数据，持续改进模型。

6.1.4.7.4 端边云结合




图 131 端边云协同示意图

构建“集中式大规模训练”和“边缘分布式协同推理”新范式，实现端边云协同。

云算力中心负责训练和推理；边缘设备上的大模型平台负责对经过剪枝、量化、蒸馏等操作的压缩模型进行微调 and 推理；端侧设备则通过调用云算力中心实现数据回流以及小模型推理。

6.1.4.7.1 主要设备配置清单

基础大模型购置清单如表103错误!未找到引用源。所示。

表 103 基础大模型购置清单

序号	设备名称	主要性能指标	国别	数量 (套)
1	基础大模型			
1.1	多模态基础大模型及技术服务	多模态基础大模型能够将来自不同模态的数据（如文本描述、图像内容、音频信号等）进行有效整合，形成一个统一的表示空间。这种整合不仅限于简单的数据拼接，而是通过复杂的算法和模型架构，实现不同模态信息之间的深度理解和交互。模型能够自动从各种模	国产	1

		态的数据中提取关键特征，并将这些特征转换为统一的、可比较的表示形式。这有助于模型在后续的处理和推理过程中，更好地理解 and 利用这些多模态信息。多模态大模型应具备强大的自然语言理解能力，能够准确识别和理解用户输入的文本信息（语音），包括语义、语境和上下文等。这有助于模型在人机交互过程中，更准确地捕捉用户的意图和需求。支持生成流畅、自然的文本输出。这包括回答用户问题、生成文本摘要、进行文本创作等多种任务。多模态大模型能够根据用户的输入（如文本描述、图像、语音信息等），生成相应的其他模态的输出。例如，根据文本描述生成图像、根据图像生成文本描述（语音信息）等。支持同时处理多种模态的输入，并生成多种模态（文本、图像、语音）的输出。多模态大模型能够结合不同模态（文本、图像、视频、语音）的信息进行推理和判断。例如，在安防应用中，模型可以结合场景的现状以及规范指导要求，进行更准确的现状分析和预警诊断。基于多模态信息的整合和分析，模型能够做出更加智能和合理的决策。提供多模态交互式大模型，参数量不低于400 亿，基于自然语言能够处理统一多视觉任务的 L0 大模型，接受图像和自然语言、语音等信息作为输入，将对齐的视觉和文本特征	
--	--	---	--

		输入到大语言模型中，进行自回归输出。 相关指标要求如下： 1、模型参数：提供百亿级、千亿级模型，可满足对不同场景参数的多样性选择； 2、输入输出长度：提供 8K、128K 上下文输入输出长度，可满足对不同长度的需求； 3、模型调优：提供 post-pretrain、SFT、RL 等调优方式，支持进行行业模型训练和调优； 4、具备模型配套的精简能力（量化、剪枝、蒸馏），支持在多种国产卡上的推理，如：华为、登临等不少于 6 种国产化设备； 5、支持并维护模型性能需求至少 3 年。		
--	--	---	--	--

自研算法清单如错误!未找到引用源。表104所示。

表 104 自研算法清单

序号	系统及模块名称	主要研发内容
1	安防行业后预训练方法研究	
1.1	模型训练数据管道	
1.1.1	数据源接入模块	(1) 对接多种数据源（本地文件、对象存储、数据库、API 等） (2) 支持批量导入与流式导入 (3) 统一格式抽象及融合
1.1.2	数据清洗与标准化模块	(1) 去重（MinHash / SimHash） (2) 噪声过滤 (3) 图像、声音、文本长度及大小过滤 (4) 不关注或非法内容过滤
1.1.3	数据质量评估模块	(1) 重复率统计 (2) 垃圾数据比例评估 (3) 语义多样性评估

1.1.4	数据增强模块	(1) 数据改写 (2) 数据翻译 (3) 数据对比样本生成 (4) 图像增强
1.1.5	数据版本与治理模块	(1) 参与训练的数据集版本管理 (2) 训练数据集快照 (3) 训练数据集回滚
1.1.6	数据存储与格式模块	(1) 支持 TB~PB 级数据 (2) 数据分片 (Sharding) (3) 支持预先 Tokenize 或 Lazy Tokenize 设计决策
1.1.7	Tokenization 与特征化模块	(1) Tokenizer 训练 (2) 分词缓存 (3) 特殊 token 管理 (4) 多模态特征抽取 (图像编码、音频编码)
1.1.8	数据调度与采样策略模块	(1) 批量加载 (2) 动态拼接 (packing) (3) 随机打乱 (global shuffle) (4) 多进程 / 多节点同步
1.1.9	在线数据监控模块	(1) 多数据源比例控制 (2) 难度分级采样 (3) 重加权采样 (4) 动态混合 (例如 warmup 阶段比例不同) (5) curriculum learning (6) 难例挖掘
1.2	多模态对齐与融合训练	通过多模态对齐训练, 模型学习建立这些信息之间的语义对应关系
1.3	时空关系建模	通过多模态对齐训练, 模型学习建立这些信息之间的语义对应关系
1.4	事件语义与知识注入	通过多模态对齐训练, 模型学习建立这些信息之间的语义对应关系
1.5	长尾与异常场景强化	安防场景中很多关键事件 (如突发事件、异常行为) 属于低频长尾事件。后预训练需要通过: 数据增强、合成数据、异常样本扩展等技术强化模型对罕见事件和异常行为的识别能力
1.6	安全与隐私约束训练	加入数据脱敏、隐私保护训练策略以及安全约束机制, 确保模型在使用过程中符合数据安全和合规要求
2	安防行业大模型	

2.1	安防多模态表征大模型	训练融合安防行业数据模态，在统一或对齐的语义空间中，对图像、文本、语音、视频等多种模态进行编码，并输出可用于检索、匹配、分类、推理等任务的高质量 embedding 的大规模模型
2.2	安防多模态理解大模型	针对模型的风险识别能力，基于已训练完成的安防行业多模态检索模型，进一步构建多模态搜索推理模型，从“相关内容召回”向“可理解、可推理搜索”的关键升级路径。
2.3	安防多模态时空推理大模型	实现复杂现实场景智能理解与决策的关键升级。该模型将时间序列、空间位置与多模态感知信息进行统一建模，使搜索与推理能力从静态语义匹配扩展至动态时空演化分析。
2.4	安防多模态生成大模型	能够在文本、图像、语音等多种模态之间进行条件生成与跨模态生成的统一大规模模型体系，面向安防行业场景构建端到端生成能力
2.5	融合模型	通过多模态融合专家模块，将音频、视觉和语言等做特征融合，结合多个任务一起做模型预训练，通过不同专家的协作，完成下游任务学习，满足各种业务场景需求
3	专业场景微调	
3.1	低秩适配微调	当计算资源有限时，一般使用低秩微调技术可以显著降低内存和计算需求同时也可以提高微调效率
3.2	适配器微调	在特定场景任务中能够获得更好的性能，向模型添加部分额外的参数
3.3	前缀微调	在数据量以及计算资源有限时更具有高效性以及灵活性，可以更好的适配特定场景
3.4	提示微调	在需要同一模型处理多个不同任务的场景中，可以为每个任务设计不同的提示，从而在不改变模型结构的情况下，适应多种任务
4	专业场景模型	
4.1	智慧图侦	
4.1.1	图侦多模态表征模型	该模型承担高质量视觉特征生成的作用，为图侦应用中的关键要素识别与检索任务提供通用表征能力支撑。在功能

		层面，模型通过自监督或对比学习方式生成高判别性向量特征，支持目标检索、相似度匹配、零样本分类、跨域迁移等能力，可应用于人脸识别、人体识别、车辆识别及聚类分析等模块的底层特征支撑引擎。
4.1.2	图侦多模态理解大模型	该模型定位于风险识别与异常预警核心，承担对非正常行为或异常模式进行自动识别与告警的作用，是安全管理与风险控制体系的重要组成部分。在功能层面，模型基于时序建模与行为表征分析能力，实现对异常行为、异常轨迹、异常状态变化等情况的自动检测，并输出异常等级与事件类型，为图侦系统提供实时预警能力。
4.1.3	图侦多模态时空推理大模型	该模型承担对多源数据进行融合分析与时空推理的作用，实现跨维度、跨时间尺度的综合判断能力。在功能层面，模型融合视频数据、结构化轨迹数据、摄像机数据、地图数据及文本规则信息等，进行时空关系建模，对关注的人车物等目标进行轨迹研判和预测，为图侦业务提供线索支撑和分析能力。
4.1.4	图侦多模态生成大模型	该模型可通过模糊图像高清修复、证人描述合成画像、失踪人员跨龄样貌推演、案发现场与物证重建等方式，为公安图侦提供关键线索与技术支撑，大幅提升破案效率与精准度，同时可用于深度伪造检测防范风险，是公安智能化办案的重要辅助工具
4.1.5	图侦模型融合	融合上述的多模态系列模型与图侦专业模型，如：人脸识别模型、人体识别模型、结构化模型等。实现人/车/物目标细分类别或属性搜索、语义搜点位、语义搜目标、视频自动巡检、关注人离开属地分析、关注人居住地变更分析、关注人长期不出现监测、关注人前往某地监测、落脚点分析、特定人员徘徊监测、目标轨迹融合分析、人群聚集监测、持刀持械监测、案件线索研判分析、关系人分析、团伙分析、骨干挖掘分析、打架斗殴监测、危险可疑物品监测、刻意躲避抓拍分析、套牌车分析、车辆徘徊

		监测、图像超分辨率重建等智能研判预警等智慧图侦服务能力，支撑公安大数据智能化平台建设
4.2	智慧交管	
4.2.1	交管多模态表征模型	通过将来自不同感知系统和业务系统的数据进行语义对齐和特征编码，模型能够建立统一的交通场景表示，为交通事件识别、行为分析和态势研判提供可靠的数据基础
4.2.2	交管多模态理解大模型	将底层感知数据上升至场景级语义解释的作用，实现复杂交通场景的结构化理解。模型能够对交通场景进行整体语义建模，理解车辆与行人之间的关系、交通规则约束及场景动态变化，支持场景描述、行为解释、规则合规判断及多轮交互问答，为交通指挥调度与智能决策系统提供认知级能力支持
4.2.3	交管多模态时空推理大模型	模型融合视频数据、结构化轨迹数据、交通流量数据及文本规则信息，进行时空关系建模与趋势预测，可支持拥堵演化预测、风险扩散分析、交通态势研判及辅助决策生成，为智慧交通系统提供战略级智能分析能力
4.2.4	交管多模态生成大模型	通过对交通数据进行生成式建模，系统可以将复杂的交通监控数据、事件信息和运行状态以更加直观和可理解的方式呈现给管理人员或公众，同时为交通管理提供更丰富的仿真分析和辅助决策手段
4.2.5	交管模型融合	融合上述交管多模态系列模型与交管专业模型，如：车牌识别、车辆识别、车型识别、车辆跟踪、车辆检测等。实现重点车辆管控监测、交通态势感知、交通事件隐患监测、非法运营车监测、摩托车飙车监测、渣土车违规监测、大型货运车违规监测、机动车违法监测、机动车驾驶员异常行为监测、非机动车带人监测、摩电不戴头盔监测、非机动车逆行监测、非法停车监测、车辆超长期停放监测等场景应用，提升非现场执法能力、交通事故预警与处置能力，进一步加强交通管理的智能化、精细化升级，提高交通管理效率和公众出行体验，促

		进城市交通的智慧化发展
4.3	平安城市	
4.3.1	城市多模态表征模型	模型能够构建统一的城市安全信息表达体系，实现不同系统之间的数据关联与信息互通。多模态表征模型可支持多种平安城市应用场景。例如，在目标检索与跨摄像头关联方面，模型能够通过图像、文本描述或行为特征实现人员与车辆的快速检索与匹配；在事件分析与风险识别方面，模型可以结合视频检测结果、轨迹数据及历史案件信息，对异常行为、可疑活动或潜在风险进行综合分析等
4.3.2	城市多模态理解大模型	多模态理解模型可支持多种平安城市应用场景。例如，在复杂事件理解与识别方面，模型能够结合视频画面、行为特征和警情文本信息，对异常行为、冲突事件、聚集事件等进行综合判定；在目标行为分析方面，模型可以通过融合视觉信息与轨迹数据，对人员或车辆的行为模式进行语义分析；在城市安全态势分析方面，模型可对多源信息进行综合理解，形成城市安全态势分析报告和风险提示，为指挥调度与应急处置提供智能辅助支持
4.3.3	城市多模态时空推理大模型	时空推理模型通过对时间维度与空间维度数据进行联合建模与关联分析，实现对城市事件演化过程、目标活动轨迹以及区域安全态势的综合推理能力。在平安城市建设中，该类模型能够将视频监控数据、人员车辆轨迹数据及地理信息数据进行统一时空关联分析，从而提升城市安全系统对复杂事件的研判能力和趋势预测能力。例如，在事件轨迹还原方面，模型能够结合多摄像头数据与轨迹信息，对人员或车辆的活动路径进行时空关联与完整还原；在重点目标追踪方面，模型可以通过时空关系分析实现跨区域目标关联与活动范围分析
4.3.4	城市多模态生成大模型	通过生成合成数据，可对监控图像和声音样本进行数据增强，弥补真实异常事件（如事故、犯罪或枪声等）数据不足的问题，从而提高目标检测、行为识别

		和声音事件识别模型的训练效果。同时，生成模型还能用于城市监控视频的图像修复与超分辨率提升，改善低光或低清视频质量，并通过构建虚拟城市场景和数字孪生环境实现应急演练与安全风险仿真
4.3.5	城市模型融合	融合上述多模态系列模型与平安城市已建设专业模型，实现城市治理各方面的工作中进行全方位、智能化的管理，一是实现对城市安全风险的监测预警，如烟火检测、路面积水、路面塌陷、井盖丢失、打架斗殴、持刀持械预警、盗抢行为、人员异常聚集、标语横幅、渣土车安全、广告牌掉落、人员溺水等风险；二是实现对城市管理市容市貌的智能监测预警，如破坏公共设施、违规占道经营、公共场所吸烟、垃圾管理、摆摊经营、广告牌破损等行为。通过智慧安防赋能，提升城市安全水平、综合管理水平，促进城市的智慧化建设，实现城市更高效、智能的安全管理和社会治理
4.4	平安社区	
4.4.1	社区多模态表征模型	多模态表征模型在平安社区中的核心价值在于通过跨模态信息融合构建更完整的场景语义表示，从而提升社区安全监控、异常检测和应急响应的智能化水平。与城市道路等开放场景不同，社区中的人员、车辆具有较高的重复出现率。例如同住户每天出入小区、固定车辆停放在同一车位。因此检索系统需要更加关注长期身份关联与轨迹检索，通常依赖行人重识别。同时，社区场景通常是半封闭空间（小区入口、楼道、电梯、停车场等），空间范围较小，但包含大量细粒度语义关系
4.4.2	社区多模态理解大模型	本模块定位于社区风险识别与安全预警核心，实现对社区安全事件的实时感知、行为识别与智能预警。在功能层面，模型基于行为模式建模与场景规则匹配，实现对异常行为检测、人员身份识别、车辆管理、火灾烟雾识别、老人跌倒检测以及高空抛物、电动车进楼等安全事件监测，并输出事件类型、时间、位置

		及关联目标信息，为社区安防与物业管理提供及时处置依据
4.4.3	社区多模态时空推理大模型	多模态时空推理模型在平安社区治理中的应用，主要通过融合视频监控、物联网传感器、门禁记录、人员轨迹、警情文本及地理信息等多源数据，对社区内的人、车、事件和空间环境进行统一建模，并结合时间序列与空间关系进行智能推理，实现对社区安全态势的实时感知、异常行为识别和风险事件预测
4.4.4	社区多模态生成大模型	本模型可辅助提升应用性能。图像生成模型可用于模拟异常场景（如火灾、打架、入侵等），生成多样化训练数据，提升监控识别算法对复杂环境的适应能力；同时还能对低清监控画面进行超分辨率重建或补全，提高取证与识别效率
4.4.5	社区模型融合	平安社区中的多模态理解模型通常采用专用模型与规则系统相结合的方式，在保证识别准确率与系统可靠性的同时，实现对社区安全事件的高效感知与智能化管理。一是辅助开展社区人员、车辆安全管理工作，包括人员、车辆安全管理，支持实有人口管理、常口流口人员管理、关注人群管理等工作；二是实现危险预警能力，包括堵塞消防通道监测、烟雾火灾监测、电动车入楼监测、车辆盗抢等；三是加强对社区日常管理，包括工作人员睡岗脱岗监测、社区老幼守护、邻里纠纷监测、不文明养犬行为监测、垃圾异常堆放监测、垃圾桶溢满监测等。通过新智慧安防和社区的融合应用，为构建基层公共安全新格局提供有效支撑
4.5	平安校园	
4.5.1	校园多模态表征模型	在校园场景中，这类模型主要用于提升教学管理、校园安全和学习分析等方面的智能化水平。例如，在智慧课堂中，通过融合课堂视频、教师语音和教学文本，可以分析课堂互动情况、学生注意力和教学效果；在校园安全管理中，结合监控视频、行为识别和门禁数据，可以实现异常行为检测和安全预警
4.5.2	校园多模态理解大模型	本模型定位于校园精细化行为感知与安

		全防控体系中的动作识别核心，承担对校园场景中个体及群体行为进行细粒度识别与动态分析的作用，是实现异常预警与行为研判的重要基础能力。在功能层面，模型基于人体关键点检测与时序动作建模技术，对奔跑、打闹、推搡、摔倒、攀爬、尾随、长时间滞留等动作进行识别与分类，并结合行为持续时间、频率及空间位置进行综合判定；同时支持异常动作模式分析与风险等级评估，可为校园安全管理、课间秩序维护及重点区域风险防控提供实时、结构化的行为数据支撑
4.5.3	校园多模态时空推理大模型	在校园场景中，这类模型的应用具有明显的环境和任务特征。首先，场景结构稳定且空间关系明确。校园由教学楼、宿舍、图书馆、操场等固定区域组成，人员活动路径和时间规律较为稳定。因此，多模态时空推理模型可以结合视频监控、门禁记录、位置数据等信息，对人员活动进行连续时空建模，例如识别学生在不同地点之间的行为轨迹或课堂出勤情况。其次，行为分析具有明显的时间序列特征。校园活动通常按照课程安排、作息时间等规律进行，模型在推理时需要考虑行为的连续性与顺序关系。例如在智慧课堂中，通过融合课堂视频、教师语音和学生动作数据，可以分析课堂互动过程、学习参与度以及教学节奏，从而实现对课堂行为的时序理解
4.5.4	校园多模态生成大模型	生成多样化训练数据，提升监控识别算法对复杂环境的适应能力；同时还能对低清监控画面进行超分辨率重建或补全，提高取证与识别效率
4.5.5	校园模型融合	融合上述多模态系列模型与平安城市已建设专业模型，实现对校园周边可疑人员的识别和管理；对校园进行安全监测预警，如宿舍着火、实验室烟雾、食堂烟雾火灾监测、电瓶车安全风险等；对异常行为的预警，如打架斗殴、持刀持械、非法聚集、异常标语、校园霸凌行为、学生进入危险区域风险监测、踩踏

		事件预防和分析等；对校园日常管理起到辅助作用，如食堂的卫生和环境监测、保安脱岗/睡岗监测、设施设备损坏监测等。通过智慧安防赋能校园安全，完善校园安全防控体系，综合提升校园安全管理水平，构建安全、和谐稳定的校园环境
4.6	平安园区	
4.6.1	园区多模态表征模型	多模态表征模型在园区场景中的核心作用，是将来自视频监控、物联网传感器、门禁系统、设备日志、文本记录等多源异构数据进行统一语义建模，从而实现对园区人员、车辆、设备、环境与事件的综理解与联动决策。与通用场景中的多模态表征应用相比，园区场景更强调场景结构化、实体关系稳定以及实时运行闭环：模型不仅需要融合多模态信息，还要结合园区空间拓扑、业务流程和设备状态形成可执行的事件理解与管理能力
4.6.2	园区多模态理解大模型	本模型定位于园区综合治理与安全保障体系中的风险识别核心，承担对园区场景中异常行为、违规操作及突发事件进行自动检测与分级预警的作用，是实现园区安全运行与高效管理的重要技术支撑。在功能层面，模型基于视频时序分析与行为模式建模能力，对异常聚集、非法闯入、越界入侵、危险作业行为、长时间滞留、设备异常操作及突发冲突等情况进行识别与分类，并输出事件类型、发生时间、空间位置及关联目标信息；同时支持异常等级评估与联动响应机制，可与安防平台、门禁系统及应急处置流程对接，为园区安全管控与运营管理提供实时、精准、可追溯的智能预警能力
4.6.3	园区多模态时空推理大模型	多模态时空推理模型在园区场景中的作用，是对视频、物联网传感器、门禁记录、车辆轨迹、设备状态及文本事件等多源数据进行跨模态融合，并结合时间序列与空间拓扑关系进行持续推理，从而实现对园区内人员活动、车辆流动、设备运行及异常事件的动态理解、预测

		与联动处置。与通用场景中的多模态推理（如开放环境的视频理解或跨模态问答）相比，园区应用更强调强约束的物理空间结构、持续的时间演化以及明确的运营目标：模型需要基于园区的区域划分、路径网络和业务规则进行因果与轨迹推断，重点解决事件演化判断、跨系统关联分析和实时决策支持问题，因此其核心区别在于从“内容理解型推理”转向面向实体关系与时空行为演化的业务驱动型推理
4.6.4	园区多模态生成大模型	生成多样化训练数据，提升监控识别算法对复杂环境的适应能力；同时还能对低清监控画面进行超分辨率重建或补全，提高取证与识别效率
4.6.5	园区模型融合	融合多模态系列模型与园区已建专业模型，一是实现园区人员车辆管控，包括员工考勤、访客管理、陌生人员徘徊、车辆违停、危化品车辆监管等；二是构建安全风险预警体系，覆盖消防通道堵塞、烟雾火灾、危险区域闯入、未佩戴安全装备等监测；三是提升日常管理水平，包括安保脱岗睡岗监测、周界入侵、物资防盗、设备故障监测等。通过智慧安防赋能园区数字化管理，全面提升安全防范能力与运营效率，构建安全、高效的现代化园区环境
4.7	平安乡村	
4.7.1	乡村多模态表征模型	本模型定位于乡村数字化治理体系中的基础感知核心，承担对乡村场景图像与视频数据进行全要素结构化解析的作用，是后续行为分析、事件识别与资源管理应用的底层数据支撑。在功能层面，模型支持对人员、车辆、农机设备、牲畜、道路、农田、水体、房屋建筑及公共设施等要素进行检测与分类，并输出目标类别、空间位置及基础属性信息；同时可适应乡村环境中复杂光照、开放场景与多样化目标形态，实现乡村视图的全面数字化表达，为乡村安全治理、农业生产监管及公共资源管理提供标准化视觉数据基础
4.7.2	乡村多模态理解大模型	本模型定位于乡村安全治理与风险防控

		体系中的智能预警核心，承担对乡村场景中异常行为与突发事件进行自动识别、实时研判与分级告警的作用，是提升基层治理数字化与精细化水平的重要技术支撑。在功能层面，模型基于视频时序建模与场景规则匹配能力，对非法闯入、盗窃行为、夜间异常活动、异常聚集、秸秆违规焚烧、牲畜异常集散、河道异常作业等情况进行识别与分类，并输出事件类型、发生时间、空间位置及关联目标信息；同时支持异常等级评估与联动处置机制，可与村级综治平台及应急响应流程对接，为乡村公共安全、生态保护及社会治理提供及时、精准、可追溯的智能预警能力
4.7.3	乡村多模态时空推理大模型	模型需对乡村区域中的人员活动、车辆流动、异常事件与环境变化进行持续理解与预测，从而提升安防预警与事件处置能力。与通用场景中的多模态推理主要侧重跨模态语义理解或通用事件判断不同，乡村安防更强调稀疏监控条件下的时空关联推断、地理空间约束以及长时间尺度的行为模式识别，模型需要在监控覆盖不均、数据模态不完整和事件发生低频但影响较大的环境中进行综合推理，因此更加依赖时空上下文整合与区域治理知识来支撑实际安防决策
4.7.4	乡村多模态生成大模型	生成多样化训练数据，提升监控识别算法对复杂环境的适应能力；同时还能对低清监控画面进行超分辨率重建或补全，提高取证与识别效率
4.7.5	乡村模型融合	融合上述多模态系列模型与平安乡村已建设专业模型，实现村庄出入口异常人员、车辆监测和关注人群管理监测，实现乡村地区的鱼塘水库守护、果园农场守护、养殖场守护等，保障村民人身财产安全，自动开展治安巡逻监测、河沟治理监测、危险区域落水监测，对非法电鱼、摩电违规驾乘、公路晒场等行为事件进行实时监测预警，通过智慧安防技术手段，为构建更高水平的平安乡村注入更强的技术动力，助力打造打防管控一体的乡村治安防控及公共服务体

		系，提升乡村安全防范能力，促进乡村智慧化进程
4.8	平安机场	
4.8.1	机场多模态表征模型	在机场场景中应用的多模态表征模型在训练时通常具有强场景约束、结构化业务语义以及跨模态时空信息融合等特性：模型需要同时对接视频监控图像、安检图像、文本信息（航班信息、告示牌、广播文本）、传感器或行为日志等多源数据，因此训练过程中更强调视觉-文本-行为数据的语义对齐。模型通常需要具备对复杂光照、遮挡、人群密集环境的鲁棒性，以及对细粒度目标与长尾事件的表征能力，以适应机场真实运行环境中高动态、多主体和安全敏感的特点
4.8.2	机场多模态理解大模型	机场场景中的行为事件相比通用安防场景具有安全等级高、人员规模大、管控区域分级严格和风险类型更具安全敏感性等特点。机场属于重要交通枢纽和重点防护单位，人员流量大且来源复杂，安防不仅需要关注一般异常行为，还需重点识别遗留物品、异常徘徊、人员聚集、闯入限制区域、尾随通行等事件。同时机场通常划分为公共区、控制区和隔离区等多级管控区域，不同区域对人员行为和通行权限要求严格，因此行为事件识别需要结合旅客流程与区域权限管理进行分析，并具备高准确度和实时响应能力，以保障航空运行安全和旅客秩序。
4.8.3	机场多模态时空推理大模型	本模型定位于机场全域态势感知与智能研判核心，通过整合视频监控、航班动态、旅客行李轨迹、安检过检及门禁通行等多维数据，构建覆盖航站楼、空侧陆侧的立体化时空关系模型。实现对旅客、工作人员、行李货物及保障车辆的全轨迹追踪与行为预测，支撑安防管控、运行调度优化及应急处置决策
4.8.4	机场多模态生成大模型	生成多样化训练数据以覆盖不同光照、角度、遮挡和天气等复杂场景，从而提升监控识别算法在真实环境中的泛化能力；同时，通过对低清监控画面进行超

		分辨率重建与细节补全，可有效提升图像清晰度与关键信息可辨性，进而提高识别的准确性和效率
4.8.5	机场模型融合	融合上述多模态系列模型与平安机场已建设专业模型，实现对机场内部及周边的全面监控和管理，人员、车辆与物品的全流程监测与管控，包括周界入侵防护、重点区域访问控制及异常行为识别等能力。对关键区域、重点设备、危险品运输及重点关注人员进行动态管控，实现身份核验、行为分析和轨迹追踪等能力
4.9	平安医院	
4.9.1	医院多模态表征模型	医院环境具有人员类型复杂（医护、患者、访客、医闹）、活动模式差异明显、关键区域安全等级不同等特点，因此模型通常需要强化细粒度行为识别、区域语义理解和异常模式的表征能力。需重点学习人员行为、空间区域，以实现对异常行为（如闯入限制区域、长时间徘徊、医患冲突、患者跌倒等）的有效表征
4.9.2	医院多模态理解大模型	医院安防场景中的行为事件相比通用安防场景具有人员构成复杂、行为类型特殊、风险事件多样和安全敏感度高等特点。医院属于半开放环境，人员流动频繁，既包含医护人员、患者和家属等多类角色，又存在推送病人、陪护聚集等特殊医疗行为，因此在行为识别上需要区分正常医疗活动与异常事件。同时，医院更容易出现医疗纠纷、情绪冲突、跌倒走失等风险事件，并且药房、ICU、手术室等重点区域对非法进入和异常行为的管控要求较高。因此，医院安防行为事件识别需要结合医疗业务场景，实现更精准的判别和应急处置
4.9.3	医院多模态时空推理大模型	本模型定位于医院智慧运营管理中枢，通过关联视频监控、患者就诊轨迹、医护定位、医疗设备状态及药品流转等异构数据，建立跨院区、跨科室的精细化时空映射。实现对患者、医护人员、物资设备的全流程动线分析，赋能安防预警、医疗质量监管及服务效率提升

4.9.4	医院多模态生成大模型	生成多样化训练数据，提升监控识别算法对复杂环境的适应能力；同时还能对低清监控画面进行超分辨率重建或补全，提高识别效率
4.9.5	医院模型融合	融合上述多模态系列模型与平安医院已建设专业模型，实现未戴脱岗离岗、医疗纠纷、安全事件、紧急救治通道保障等进行监测和智能预警，提升监管效率，增强透明度，促进行业自律，提升医疗过程安全监管的效率和水平
4.10	环保安防	
4.10.1	环保多模态表征模型	本模型定位于生态环境监测与治理体系中的基础感知核心，承担对环境监控视频及图像数据进行全要素结构化解析的作用，为污染识别、风险研判与执法监管提供标准化数据支撑。在功能层面，模型支持对河道水体、烟囱排放、扬尘区域、垃圾堆放、渣土车辆、裸土覆盖情况、植被状态及相关作业设备等要素进行检测与分类，并输出目标类别、空间位置及状态属性信息；同时具备适应复杂光照、远距离观测及气候变化条件的鲁棒性，实现环境要素的数字化表达与动态监测，为环保巡查、污染溯源及治理评估提供可靠的视觉数据基础
4.10.2	环保多模态理解大模型	本模型定位于生态环境监管与污染防控体系中的智能预警核心，承担对环境监控场景中异常排放与违规行为进行自动识别、快速研判与分级告警的作用，是提升环保执法效率与精准监管能力的重要技术支撑。在功能层面，模型基于视频时序分析与环境要素建模能力，对异常烟气排放、黑烟超标、扬尘异常升高、露天焚烧、非法倾倒垃圾、渣土车违规覆盖不严及水体异常颜色变化等情况进行识别与分类，并输出事件类型、发生时间、空间位置及关联主体信息；同时支持风险等级评估与联动处置机制，可对接环保监管平台与执法流程，实现实时预警、证据留存与事后溯源分析，为环境治理与污染防控提供精准、可追溯的智能化支撑能力
4.10.3	环保多模态生成大模型	生成多样化训练数据，提升监控识别算

		法对复杂环境的适应能力；同时还能对低清监控画面进行超分辨率重建或补全，提高取证与识别效率
4.10.4	环保模型融合	融合上述多模态系列模型与环保安防已建设专业模型，实现对涉及环境保护的安防智能化监控、管理和优化。通过实现烧桔杆检测、河道漂浮监测、垃圾乱堆放监测、工厂废气排放监测、工厂扬尘监测、违规排污识别、裸土未覆盖、车辆冒黑烟等智能场景的应用，可以有效提升管理效率，降低环境污染，促进节能减排，为环保过程提供了全面、高效、便捷的安全保障
4.11	平安工地	
4.11.1	工地多模态表征模型	本模型定位于施工现场智能监管体系中的基础感知核心，承担对工地场景进行全要素结构化解析的作用，为安全管理、作业监督与风险识别提供标准化视觉数据支撑。在功能层面，模型支持对施工人员、工程车辆、塔吊设备、脚手架、物料堆放区、安全防护设施及作业区域边界等要素进行检测与分类，并输出目标类别、空间位置、数量统计及基础属性信息；同时可适应粉尘、强光、遮挡及复杂动态环境，实现对施工现场运行状态的全面数字化表达，为安全生产管理与精细化施工监管提供可靠的数据基础
4.11.2	工地多模态理解大模型	本模型定位于施工现场安全生产与风险防控体系中的智能预警核心，承担对工地场景中异常行为、违规作业及突发安全事件进行自动识别与分级告警的作用，是实现安全生产闭环管理的重要技术支撑。在功能层面，模型基于视频时序分析与作业规范规则建模能力，对未佩戴安全帽或反光衣、危险区域违规进入、高空抛物、人员跌落、机械设备异常运行、明火作业异常及异常聚集等情况进行识别与分类，并输出事件类型、发生时间、空间位置及关联目标信息；同时支持风险等级评估与联动响应机制，可与现场管理平台、广播系统及应急处置流程对接，实现实时预警、过程

		留痕与事后溯源分析，为施工现场安全监管与生产管理提供精准、可靠的智能保障能力
4.11.3	工地多模态生成大模型	生成多样化训练数据以覆盖不同光照、角度、遮挡和天气等复杂场景，从而提升监控识别算法在真实环境中的泛化能力；同时，通过对低清监控画面进行超分辨率重建与细节补全，可有效提升图像清晰度与关键信息可辨性，进而提高目标识别与取证分析的准确性和效率
4.11.4	工地模型融合	融合上述多模态系列模型与平安工地已建设专业模型，实现未系安全带、未戴安全帽、违反安全流程、工服合规性、未穿反光衣、吸烟、化学品泄漏监测、火情、安全风险、危险动作、机械臂下站人、区域禁入等异常行为事件的智能监测，提升安全生产领域对工地风险的感知能力、预警能力和处置效率，可有效降低安全事故的发生率，提升工地安全生产水平
4.12	平安铁路	
4.12.1	铁路多模态表征模型	对火车站、铁路沿线的人员及物品进行建模，支持目标检索、相似度匹配、零样本分类、跨域迁移等能力，可应用于人脸识别、人体识别、车辆识别及聚类分析等模块的底层特征支撑引擎
4.12.2	铁路多模态理解大模型	本模型定位于铁路运营安全保障体系中的智能风险识别核心，承担对铁路沿线及站场场景中的异常行为与突发事件进行自动检测、快速研判与分级预警的作用，是保障行车安全与运营稳定的重要技术支撑。在功能层面，模型基于视频时序分析与场景规则建模能力，对人员侵入轨道、翻越围栏、滞留线路、抛掷异物、设备异常状态、烟火异常及可疑聚集等情况进行识别与分类，并输出事件类型、发生时间、空间位置及关联目标信息；同时支持风险等级评估与联动处置机制，可与调度系统、报警系统及应急响应流程对接，实现实时告警、闭环处置与事后溯源分析，为铁路运行安全与综合管控提供高可靠性的智能预警能力

4.12.3	铁路多模态时空推理大模型	本模型定位于铁路网络安全运营与运力调度决策引擎，通过融合视频监控、列车运行图、旅客出行链、票务信息及线路设备状态等数据，搭建跨车站、跨线路的网络化时空分析框架。实现对旅客、作业人员、列车车辆及关键设施的全链条轨迹还原与风险预判，保障客运安全与运输秩序
4.12.4	铁路多模态生成大模型	生成多样化训练数据，提升监控识别算法对复杂环境的适应能力；同时还能对低清监控画面进行超分辨率重建或补全，提高取证与识别效率
4.12.5	铁路模型融合	融合上述多模态系列模型与平安铁路已建设专业模型，实现对火车站、铁路沿线的异常事件识别、特殊人员发现、人员行为识别、人员物品识别查找、目标轨迹生成等更实时、准确的监测和预测能力，给出处理建议或工单触达到责任人
5	模型推理优化	
5.1	安防行业大模型量化压缩与蒸馏算法研究	
5.1.1	模型可压缩性分析	(1) 各层量化 bit 推荐范围 (2) 剪枝比例建议 (3) 蒸馏难度评估
5.1.2	量化算法研究	(1) PTQ (Post-Training Quantization) (2) QAT (Quantization Aware Training) (3) 超低比特量化
5.1.3	模型剪枝研究	(1) 非结构化剪枝 (2) 结构化剪枝
5.1.4	低秩分解	(1) 超大模型压缩 (2) 微调场景
5.1.5	知识蒸馏	(1) Logits 蒸馏 (2) 中间层蒸馏 (3) 多任务蒸馏
5.1.6	混合压缩策略	(1) 自动组合策略 (2) 搜索压缩超参数 (3) 精度-延迟 Pareto 优化
5.1.7	精度对齐优化	(1) 小规模再训练 (2) LoRA 微调恢复 (3) 对齐再优化
5.1.8	性能评估与基准测试	(1) 精度指标

		(2) 效率指标 (3) 稳定性指标
5.2	模型国产化适配与加速	
5.2.1	硬件适配与抽象模块	(1) 统一算子接口 (2) 统一内存接口 (3) 精度格式适配 (FP32 / BF16 / FP16 / INT8 / INT4) (4) 设备能力探测 (算力、显存、带宽)
5.2.2	算子级优化模块	(1) Kernel Fusion (2) Tensor Core 利用 (3) Warp-level 优化 (4) Tile 优化 (5) 内存对齐优化
5.2.3	高效 Attention 优化模块	(1) FlashAttention (2) PagedAttention (3) Multi-Query Attention (4) KV Cache 压缩
5.2.4	并行与分布式执行模块	(1) 单卡优化 (批量合并、动态 batching) (2) 多卡优化 (Tensor Parallel、Pipeline Parallel、Data Parallel) (3) 多机优化 (异步调度)
5.2.5	精度与量化适配模块	(1) 动态精度切换 (2) INT8 / INT4 推理支持 (3) BF16 自动适配 (4) 混合精度 fallback 机制
5.2.6	推理调度与负载均衡模块	(1) 动态批处理 (2) 请求排队策略 (3) 优先级调度 (4) 限流机制 (5) 异步执行
5.2.7	性能监控与分析模块	(1) GPU 利用率 (2) 显存使用率 (3) Kernel 时间分析 (4) 通信耗时 (5) 瓶颈定位
5.3	大小模型协同	结合大模型的强大计算能力和小模型的灵活性，以实现更高效、更适应性强的智能系统
5.4	端边云结合	云算力中心负责训练和推理；边缘设备上的大模型平台负责对经过剪枝、量化、蒸馏等操作的压缩模型进行微调和推

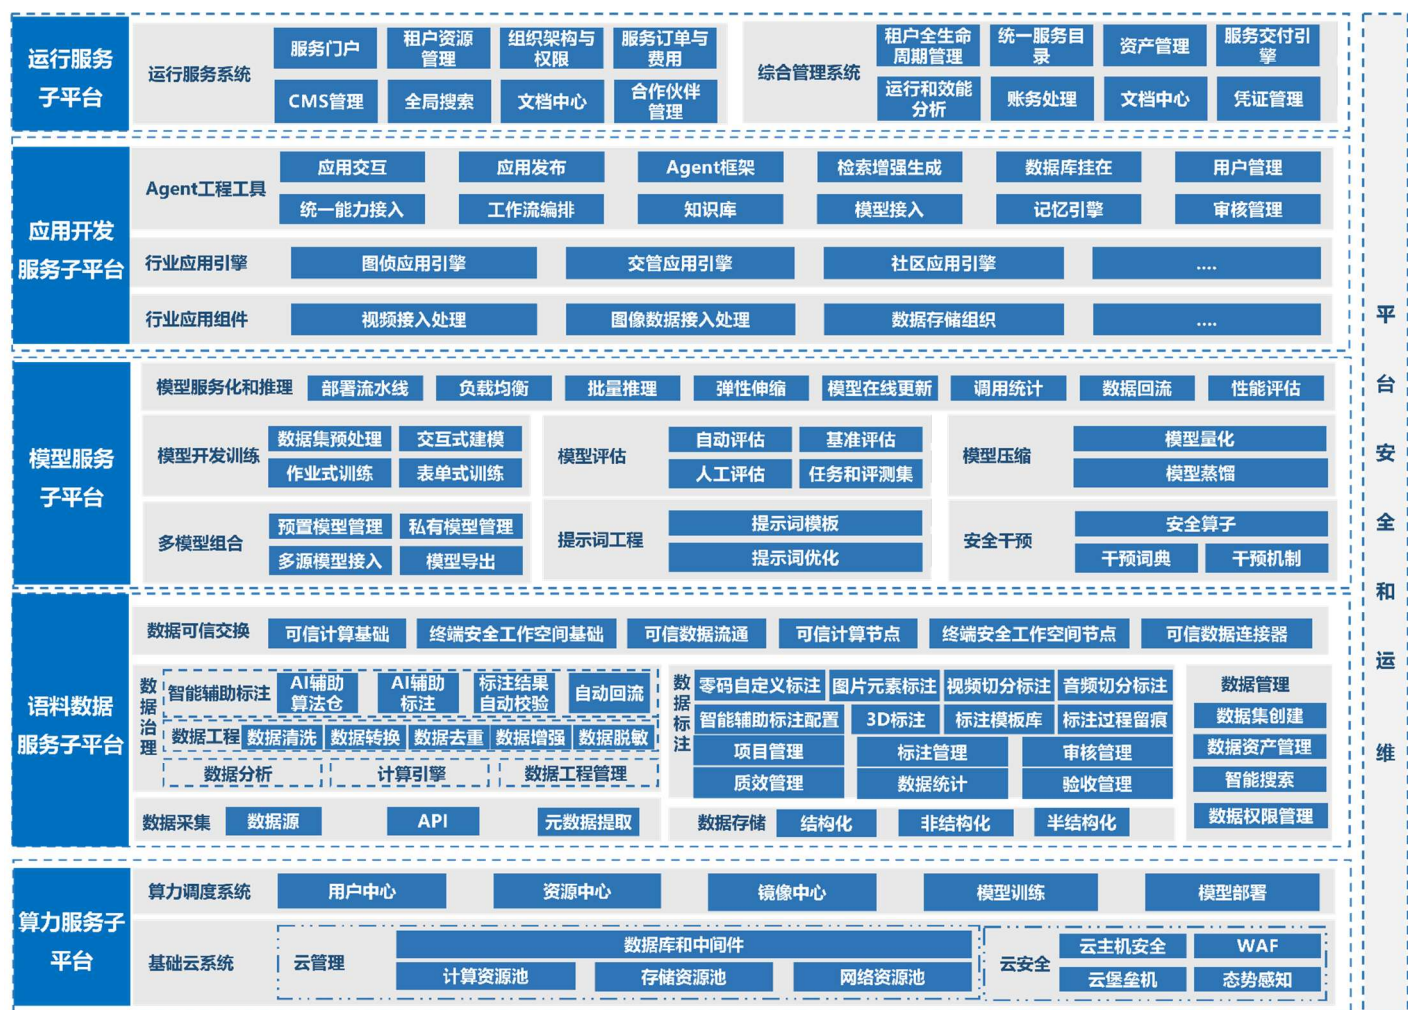
		理；端侧设备则通过调用云算力中心实现数据回流以及小模型推理。
--	--	--------------------------------

6.1.5 安防行业人工智能共性服务平台建设方案

基于安防行业生态伙伴对人工智能研发应用的共性需求，项目拟集约建设人工智能共性服务平台，形成覆盖算力调度、数据集管理、模型训练、高效微调、模型管理、模型评测、应用开发、推理应用的全流程 AI 服务能力，形成安防人工智能研发工具链，为行业内企事业单位和人工智能企业、高校、科研院所参与基地共建共创提供标准化、组件化、模块化的工具支撑，为行业用户提供安防行业大模型通用能力推理服务，从而有序引导数据、算法、人才在基地形成汇聚，一体化推进研发攻关、应用迭代和生态培育。

6.1.5.1 总体框架

安防行业人工智能共性服务平台整体架构分为算力资源服务、数据服务、模型服务、应用开发和运行服务共5个子平台，平台整体架构如图132所示。



平台安全和运维

图 132 技术架构

算力服务子平台：作为基础设施支撑，提供丰富的算力资源，以虚拟化、服务化的方式动态分配和高效管理算力资源，为用户提供引擎更灵活、可扩展的计算能力支持，包括：

- （1）可实现对 CPU、GPU 的智能算力调度与精准分配。
- （2）支持异构计算容器，能良好兼容各类 GPU。
- （3）支持分布式块存储、并行文件存储和海量云存储多种方式。
- （4）提供多种算力调度系统。
- （5）兼容百度飞桨、华为昇思等多种深度学习框架。

语料数据服务子平台：作为数据处理的核心枢纽，主要负责数据全生命周期管理。主要功能包括：

- （1）遵循视频联网标准，通过视频联网平台接口进行数据采集。通过 API 接口、数据源进行数据接入。
- （2）通过数据看板对数据分布、任务分布、质量指标等关键指标数据动态展示，实现对平台数据使用情况实时监测与多维分析。
- （3）支持结构化、非结构化、半结构化等多种数据存储形式。提供数据清洗、数据增强、数据标注、数据同步等多种数据工程工具。
- （4）支持数据可信交换、融合共享，配置安全策略与空间管理规则，确保数据安全。
- （5）实现数据集的创建、发布、加密封装及权限管理。

模型服务子平台：作为一站式大模型服务平台，为模型开发者提供模型全生命周期管理能力，包括：

- （1）多模型组合工具支持对模型进行统一纳管和展示，支持模型类型、分类、框架等多维度筛选，方便用户快速了解平台已有模型，并进行便捷的训练和部署。
- （2）模型工程工具提供语言、视觉、语音、多模态等模型的训

练和调优功能，包括 SFT 训练、post-pretrain 训练、强化学习训练、模型蒸馏等功能。同时也具备模型推理功能，支持直接将模型发布为模型服务，对外提供标准化服务。整体对训练任务、推理任务、模型、提示词进行管理。

应用开发服务子平台：专注于行业应用的开发与发布，构建安防行业的 AI 应用，包括：

（1）行业应用组件针对各类场景应用，提供行业通用的组件库，为应用开发提供便捷可快速直接调用的组件库。

（2）行业应用引擎提供针对如图侦、交管、社区等应用场景的特有服务能力集合。

（3）Agent 工程工具聚焦于应用开发与发布，包括应用交互、调试、发布及 Agent 框架搭建、知识库调用等操作，支持检索增强生成等。

（4）行业应用场景图谱覆盖智慧图侦、智慧交管、平安城市、平安社区等众多领域，助力实现行业融合应用开发，将模型与数据能力转化为服务实战的行业应用。

运行服务子平台：以“需求对接+全链路服务+生态协同”为核心，面向租户与生态伙伴的统一服务入口，对外提供 AI 能力和产品，同时对内具备能力管理、资源管理、租户管理、AI 资产管理等功能，包括：

（1）运行服务系统提供 AI 能力和产品的展示、资源申请、能力开发、订单结算、生态对接等全场景租户需求，实现从需求发现、资源获取到服务使用、问题反馈的全链路闭环。

（2）综合管理系统提供租户管理、订单管控、效能分析、资产交付、身份认证等全场景需求，为前台运行服务系统提供全链路、一

体化的底层支撑能力。

6.1.5.2 算力服务子平台

算力资源服务子平台采用先进的人工智能计算架构，提供人工智能应用所需算力服务、数据服务、算法服务和算力调度服务的公共算力新型基础设施。通过算力的生产、聚合、调度和释放，高效支撑数据开放共享、智能生态建设、产业创新聚集。算力资源服务为整个共性服务平台提供底层资源支撑，包括计算资源（CPU、GPU 资源）、存储资源、网络资源和安全资源，底层高性能 AI 计算能力提供芯片、服务器、高性能网络等服务。同时，算力资源服务支持使用国产 AI 芯片，来完成部分推理或训练任务。

具体建设模块包括：基础云系统、算力调度系统。

6.1.5.2.1 算力服务子平台架构




图 133 算力资源服务子平台逻辑架构

算力资源服务子平台，兼容适配业界广泛使用的主流硬件、操作系统，对算力资源进行统一管理、调度和监控，同时进行细粒度的资源实时分配，实现海量任务的智能自动调度、任务管理、数据加载和预处理，支撑大模型从数据处理到预训练、微调到多模型管理的整个

研发流程。

算力资源服务设计遵照“分层解耦，异构兼容，统一管理，统一服务”的目标，整合硬件资源，实现硬件资源的共享，通过算力资源服务对基础设施资源进行统一的管理，屏蔽底层硬件的异构性和组网的复杂性。通过计算、存储、网络等虚拟化技术将传统物理设备进行池化处理，构建统一的计算、存储、网络和安全资源池。为上层应用提供运行稳定、安全隔离、按需获取的基础资源服务，以细粒度管理方式充分利用基础设施资源，大幅提高云计算平台基础设施的资源利用率。

基础云系统：是对基础设施的云化管理，通过云管理模块将基础设施层提供的硬件设备按照逻辑功能的不同划分为计算、存储、网络等不同功能的资源池，其中，计算资源池包括云服务器、裸金属服务器、GPU 服务器、容器服务、弹性伸缩服务；存储资源池包括块存储、对象存储、文件存储；网络资源池包括私有网络、弹性公网 IP、专线服务、云解析服务、负载均衡服务；数据库与中间件包括关系型数据库、内存数据库、全文数据库。同时，提供云安全模块，对云内安全进行统一保障。

算力调度系统：算力调度系统是基于基础云系统构建，聚焦智算设备，提供算力资源管理、任务调度、模型优化、故障诊断及性能优化于一体的综合性平台。为用户提供个性化、高效能的算力服务，适配人工智能相关需求，助力构建稳定可靠的高性能计算环境。包括用户中心、资源中心、镜像中心、模型训练、模型部署。

6.1.5.2.2 算力服务子平台技术方案

6.1.5.2.2.1 基础云系统

基础云系统是核心基础设施，提供云管理模块和云安全模块，其

中云管理模块包含计算资源池、存储资源池、网络资源池、数据库与中间件等服务能力。

基础云系统提供领先的虚拟化技术，通过虚拟机和软件定义网络，实现了多租户隔离及组网，对于计算/虚拟机隔离，租户的虚机被创建在指定的计算节点上或将它的虚机部署在指定的专有的服务器上，主要是通过 **Host aggregate** 技术来支持这种需求的实现。存储卷物理隔离，不同租户的卷创建在不同的后端存储上，即支持租户在指定的后端上创建卷 **Volume**。在网络的逻辑隔离，采用 **VxLAN** 等技术模式，不同租户或应用相互隔离，即便在同一个机房内也不可见，有效保证数据的安全性。同时在单地域内可以将部署在多个机房的服务纳入同一个虚拟网络，即可实现多机房冗余。

基础云系统拥有多种存储技术，可针对用户不同应用场景提供量身定制的解决方案。包括块存储、文件存储、对象存储等，支持海量数据的大规模压力考验，能够确保用户的数据安全可靠。

基础云系统提供多种数据库和中间件服务，包括关系型数据库，对性能要求高的 **NoSQL** 存储系统，支持全文检索的弹性搜索服务。

6.1.5.2.2.1.1 云管理模块

6.1.5.2.2.1.1.1 计算资源池

6.1.5.2.2.1.1.2 云服务器




图 134 云服务器架构

云服务器是基于虚拟化技术构建的虚拟服务器，通过整合物理服务器资源，为用户提供一种处理能力可弹性伸缩的计算服务，管理方式比物理服务器更简单高效。根据业务需要，用户可按需配置资源，随时创建或释放任意多台云服务器实例，提升运维效率。

云服务器为用户快速部署应用构建提供稳定可靠的基础，可以降低网络规模计算的难度，使用户更专注于核心业务创新。另外，用户无需再购买及维护托管虚拟机的硬件，使用云服务器能有效降低 IT 成本。

6.1.5.2.2.1.1.3 裸金属服务器




图 135 裸金属服务器产品架构

裸金属服务器是用户可以在云环境中独享的高性能物理裸机，用户拥有完全的物理设备管理权限，同时可以结合弹性公网 IP、负载均衡灵活组网，并与云服务器在内网互通，灵活应对用户多种复杂场景的业务需求，轻松构建内网混合云。

基于智算云提供的裸金属服务器，用户可以在管理控制台便捷的创建和管理云环境中的物理裸机，包括配置裸金属服务器名称、网络 IP，查看硬件配置和创建时间等。

6.1.5.2.2.1.1.4 GPU 服务器




图 136 基地运行组织架构

GPU 服务器是配备独享 GPU 卡的高性能云计算服务，可以帮助用户快速、便捷的获得高质量的 GPU 计算资源，能够大幅提高机器学习及科学计算等大规模计算框架的运行速度，为搭建人工智能及高性能计算平台提供基础架构支持。

GPU 服务器提供两种形态计算资源，虚拟机形态的 GPU 云服务器和物理机形态的 GPU 物理服务器：

（1）GPU 云服务器：提供与标准云服务器一致的管理方式，用户可以快速灵活地申请并管理 GPU 云服务器，结合私有网络 VPC、

负载均衡负载均衡，共同构建云环境中高可用的 GPU 集群。

(2) GPU 物理服务器：当普通 GPU 云服务器无法满足用户的业务要求时，智算云还可以提供租用独享 GPU 物理服务器的服务。并在用户计划搭建超高性能的 GPU 集群时，提供配置更多 GPU 卡(8 卡以上)和高速互联带宽的超高性能的 GPU 物理服务器集群的服务。

6.1.5.2.2.1.1.5 容器服务




图 137 容器服务架构

容器服务基于轻量级虚拟化技术，提供接近物理服务器的高性能容器环境，支持容器全生命周期管理，实现业务快速部署与弹性调整；依托 Kubernetes 与 Docker 构建容器引擎，提供集群动态创建、自动扩缩容、监控运维、镜像及工作负载管理等能力，降低搭建维护成本并提升可观测性与可用性，覆盖计算、网络、存储、权限、日志监控等完整功能模块；支持服务模块拆分与独立部署升级，容器具备独立环境镜像与网络 IP，通过灵活方式实现服务发现，可整合各类云服务构建服务集群，且集群环境迁移、复制便捷，通过镜像选择与访问地址配置即可快速搭建一致新集群。

6.1.5.2.2.1.1.6 弹性伸缩




图 138 弹性伸缩服务架构

弹性伸缩是自动化扩缩容用户云资源的管理服务，当用户业务所需的云资源用量经常性变化时，弹性伸缩会是用户使用云资源的理想方式。

目前弹性伸缩能够帮用户的管理的云资源包括云服务器，以及和云服务器相关的云磁盘和弹性公网 IP 等。支持对这些资源进行自动化的横向扩缩容。

6.1.5.2.2.1.1.7 存储资源池

6.1.5.2.2.1.1.8 云磁盘




图 139 云磁盘架构

云磁盘是一种安全可靠的高弹性存储服务，作为云服务器的扩展块存储部件，为云服务器数据存储提供高可用和高容量支持。有独立于云服务器的生命周期，支持快速扩容、在线备份和回滚。

云磁盘支持数据的随机读写，在吞吐量，IOPS 以及异常恢复时间等方面，都有不错的性能，能够满足大部分客户在各类场景下的使用需求。

云磁盘具有独立于云服务器的生命周期，并支持在线扩容，在线转换云磁盘类型，通过自动快照进行容灾备份和磁盘回滚等众多弹性管理功能。

相比本地盘，云磁盘采用三副本或纠删码技术对磁盘数据进行存储。若部分存储节点，存储介质或网络交换机发生意外故障，数据会立即迁移到其它节点，用户对数据的访问不会受到任何影响，更不会

感知到组件故障的发生。

6.1.5.2.2.1.1.9 对象存储




图 140 对象存储架构

对象存储，是一种以对象为单位，将数据、元数据和唯一标识符组合存储的分布式存储架构，具有高扩展性、高持久性和高可用性特点，对外提供统一的存储接口服务。

支持常见的访问接口统一访问，通过标准的 RESTful API 接口提供服务，支撑多种业务需求。对象存储支持多数据中心多活。

支持不同类别数据存放到不同存储类型，以降低总存储成本，同时满足服务要求。

6.1.5.2.2.1.1.10 网络资源池

6.1.5.2.2.1.1.11 私有网络




图 141 私有网络架构

私有网络 VPC (Virtual Private Cloud) 是一个用户能够自定义的虚拟网络。通过 VPC，用户可以灵活设置网络地址空间，实现私有网络隔离，多个虚拟网络之间（同城和跨城）稳定高速对等互通。通过对等连接网关云平台 VPC 支持多个私有网络之间（同城和跨城）高速、稳定对等互通。通过 VPN/专线的形式，将云平台与用户的私有数据中心构建组成一个灵活、可扩展的混合云，实现原有业务轻松、安全地迁移到云端。

6.1.5.2.2.1.1.12 弹性公网 IP




图 142 弹性公网 IP 服务架构

弹性公网 IP 为用户提供公网带宽服务。用户可以将弹性公网 IP 实例与云服务器、负载均衡、NAT 网关、VPN 网关等实例绑定或解绑，为用户访问公网提供 IP 地址和公网带宽，做到灵活匹配业务变更，增加用户使用弹性。

6.1.5.2.2.1.1.13 专线服务




图 143 IDC 专线服务架构

专线服务为客户提供 IDC 与云平台快速和可靠的连接方式。云专线服务分为物理专线和专线网关两个组成部分。用户可在物理专线上划分多个专线通道作为虚拟链路资源。专线网关由用户在其 VPC 中创建并维护，用户将专线通道绑定在指定专线网关上，并配置两端路由最终实现流量互通。

6.1.5.2.2.1.1.14 云解析服务




图 144 云解析服务架构

云解析服务作为互联网基础设施的核心组成部分，通过分布式域名解析系统实现域名与 IP 地址的双向映射，构建人机交互的关键信息桥梁。其核心功能是将便于人类记忆的域名（如 `www.example.com`）转换为计算机可识别的 IP 地址（如 `192.168.1.1`），同时支持反向解析（IP 到域名），解决网络资源寻址的复杂性问题。其中：

（1）域空间（如 `x.com`、`y.com`）：代表域名的管理范围，在该范围内可配置一系列域名解析记录（如 A、AAAA、MX 等），用于控制域名下的网络服务访问，是域名解析管理的基本单元。

（2）A 记录（Address Record）：一种 DNS 记录类型，用于将域名映射到对应的 IPv4 地址，实现从人类可读的域名到机器可识别的 IPv4 地址的转换，是最常用的域名解析记录，方便用户通过域名访问目标服务器。

（3）AAAA 记录：用于将域名映射到 IPv6 地址，功能与 A 记录类似，但适用于 IPv6 网络环境，满足日益增长的 IPv6 地址解析需

求。

（4）MX 记录（Mail Exchange Record）：指定域名对应的邮件交换服务器，用于处理电子邮件的发送和接收，确保邮件按规则路由到正确的邮件服务器，是邮件系统正常运行的关键配置。

（5）DNS 服务集群：由多台 DNS 服务器组成的集群，通过负载均衡与协同工作，共同处理域名解析请求，提供高可用性和高效的解析服务，确保用户域名解析请求快速、准确响应。

（6）分布式数据库：存储 DNS 记录数据的数据库，采用分布式架构，具备高扩展性、可靠性和数据一致性，支持 DNS 服务集群对解析记录的高效查询与更新，为域名解析提供数据支撑。

6.1.5.2.2.1.15 负载均衡




图 145 负载均衡服务架构

负载均衡通过将同一区域的多台云服务器虚拟成一个组，设置一个内网或外网的服务地址，将前端并发访问转发给后台多台云服务器，实现应用程序的流量均衡，性能上实现业务水平扩展。负载均衡还通过故障自动切换及时地消除服务的单点故障，提升服务的可用性。

支持四层(传输层,TCP/UDP 协议)和七层(应用层,HTTP/HTTPS

协议）两种流量转发模式：

（1）四层负载均衡：基于 IP 端口进行流量转发，适用于 TCP/UDP 协议的高性能场景，支持快速转发与低延迟数据传输，满足数据库连接、实时通信等底层服务需求；

（2）七层负载均衡：基于 URL、HTTP 头信息等应用层参数进行流量分发，支持精细化的规则配置（如路径转发、域名分流、Header 改写），适用于 Web 服务、API 接口等上层应用场景。

6.1.5.2.2.1.1.16 数据库和中间件

6.1.5.2.2.1.1.17 关系型数据库




图 146 关系型数据库架构

关系数据库是专业、高性能、高可靠的关系型数据库服务。关系数据库提供 Web 界面进行配置、操作数据库实例，还为用户提供可靠的数据备份和恢复、完备的安全管理、完善的监控、轻松扩展等功能支持。相对于自建数据库，云数据库具有更经济、更专业、更高效、更可靠、简单易用等特点，提供数据迁移、备份、同步功能，并具备高可用特性，使用户能更专注于核心业务。

6.1.5.2.2.1.1.18 内存数据库




图 147 内存数据库架构

内存数据库服务提供稳定、高效以及高可扩展性的分布式缓存服务。简单缓存服务兼容 Redis 协议。基于 Redis 提供标准版和集群版的架构模式，并支持自定义副本数量，为用户提供多样化的数据结构支持。其架构经过优化，可从容应对高并发场景，确保服务稳定运行，且部署与集成简便，大幅降低用户的管理成本。

简单缓存服务主要用于缓解后端存储服务的压力、快速响应热点数据，降低了用户部署与管理 Cache 服务的复杂性，支持标准 Redis API 接口。双副本实例默认支持主从热备，实现故障自动切换、故障迁移、数据备份、实例监控等运维管理功能。相对于自建 Redis，使用简单缓存服务具有更经济、更专业、更高效、更可靠、简单易用等特点，使用户能更专注于核心业务。

6.1.5.2.2.1.1.19 全文数据库




图 148 全文数据库架构

全文数据库是一项托管服务，让用户可以在云系统中轻松地部署、操作和扩展 Elasticsearch，主要功能包括：

（1）支持通过云管理控制台创建、配置和管理云 Elasticsearch 集群。

（2）支持自动检测并替换出现故障的 Elasticsearch 节点，减少自行管理基础设施和 Elasticsearch 软件的相关开销。

（3）完全兼容 Elasticsearch 开源 API，便于用户现有 Elasticsearch 业务零成本迁移。

（4）提供权限管理机制，便于用户对集群的权限自由配置，进一步保证数据安全。

6.1.5.2.2.1.2 云安全模块

6.1.5.2.2.1.2.1 云主机安全




图 149 云主机安全架构

云主机安全是云系统为保护用户服务器上运行业务的连续性，而提供的一款主机安全服务。具备高稳定性、轻量级、易部署的特点，可供企业级用户快速构建主机安全防护体系。云主机安全主要功能有恶意进程查杀、防暴力破解、异地登录检测、网站后门检测、安全基线检查、日志检索等。

云主机安全主要采用 CS 架构，由 Agent（安全客户端）、Sever、Web 三个模块组成，云主机安全管控系统为用户的云环境提供基础的、便捷的、高效的、稳定的安全服务能力，其中：

（1）Web 端主要提供集中管控、安全配置、事件分析、告警配置等功能。

（2）Sever 端主要提供数据分析、安全检测、任务下发和结果保存等功能。

（3）安全客户端主要监控、收集、处理和传输等功能。

6.1.5.2.2.1.2.2 Web 应用防火墙




图 150 Web 应用防火墙架构

Web 应用防火墙（Web Application Firewall，简称 WAF）是云系统面向用户提供的 Web 安全防护系统，能够有效防护各种 Web 攻击，协助用户定制访问规则，提升网站等业务的安全。独创的全新 WAF 技术架构体系，能够将 WAF 实例灵活部署在各个 Web 业务入口，避免了传统云 WAF 架构下黑客绕过代理直攻源站的尴尬。云端安全大数据能力的集成也让 WAF 能更有效更快捷的帮助客户提升网站安全性与可用性

6.1.5.2.2.1.2.3 云堡垒机




图 151 云堡垒机架构

云堡垒机是云系统提供的一个综合性运维管控服务平台，提供了云资产管理、统一账号认证管理、权限管理、应用管理、运维审计等功能。云堡垒机从逻辑上分为服务层、接入层和用户层，其中：

（1）服务层：负责云堡垒机整体服务的管理调度，包括堡垒机实例的生成、销毁、容灾、调度、数据保管等。

（2）接入层：通过云网络实现到用户 VPC 的接入。

（3）用户层：用户真实可见的云堡垒机管理界面。

云堡垒机具有以下特性：