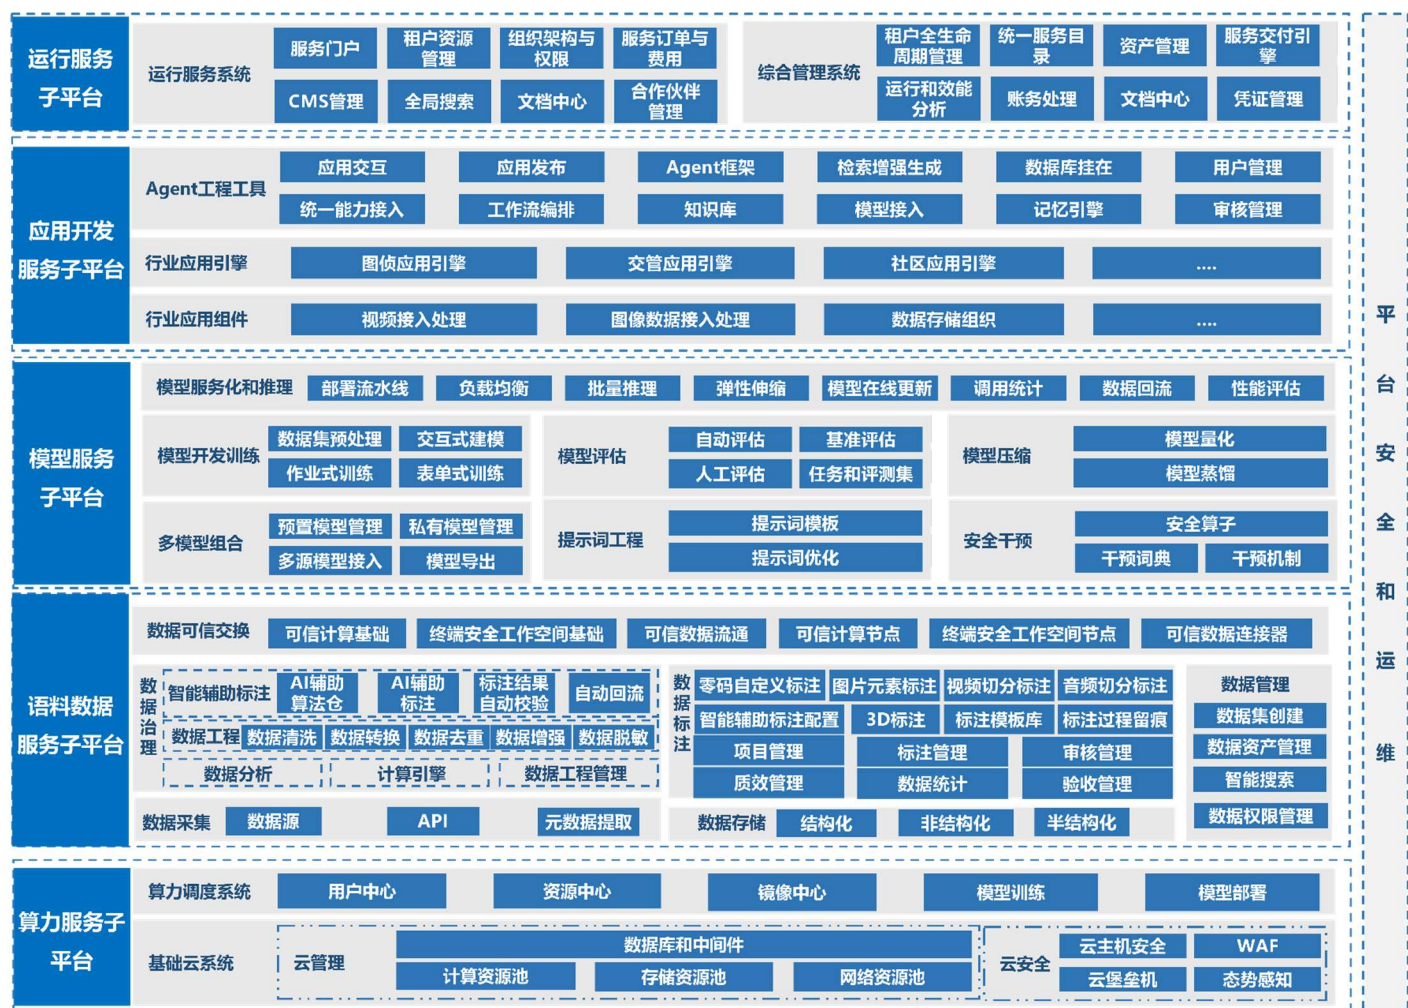




平台安全和运维

图 132 技术架构

算力服务子平台：作为基础设施支撑，提供丰富的算力资源，以虚拟化、服务化的方式动态分配和高效管理算力资源，为用户提供引擎更灵活、可扩展的计算能力支持，包括：

- （1）可实现对 CPU、GPU 的智能算力调度与精准分配。
- （2）支持异构计算容器，能良好兼容各类 GPU。
- （3）支持分布式块存储、并行文件存储和海量云存储多种方式。
- （4）提供多种算力调度系统。
- （5）兼容百度飞桨、华为昇思等多种深度学习框架。

语料数据服务子平台：作为数据处理的核心枢纽，主要负责数据全生命周期管理。主要功能包括：

- （1）遵循视频联网标准，通过视频联网平台接口进行数据采集。通过 API 接口、数据源进行数据接入。
- （2）通过数据看板对数据分布、任务分布、质量指标等关键指标数据动态展示，实现对平台数据使用情况实时监测与多维分析。
- （3）支持结构化、非结构化、半结构化等多种数据存储形式。提供数据清洗、数据增强、数据标注、数据同步等多种数据工程工具。
- （4）支持数据可信交换、融合共享，配置安全策略与空间管理规则，确保数据安全。
- （5）实现数据集的创建、发布、加密封装及权限管理。

模型服务子平台：作为一站式大模型服务平台，为模型开发者提供模型全生命周期管理能力，包括：

- （1）多模型组合工具支持对模型进行统一纳管和展示，支持模型类型、分类、框架等多维度筛选，方便用户快速了解平台已有模型，并进行便捷的训练和部署。
- （2）模型工程工具提供语言、视觉、语音、多模态等模型的训

练和调优功能，包括 SFT 训练、post-pretrain 训练、强化学习训练、模型蒸馏等功能。同时也具备模型推理功能，支持直接将模型发布为模型服务，对外提供标准化服务。整体对训练任务、推理任务、模型、提示词进行管理。

应用开发服务子平台：专注于行业应用的开发与发布，构建安防行业的 AI 应用，包括：

（1）行业应用组件针对各类场景应用，提供行业通用的组件库，为应用开发提供便捷可快速直接调用的组件库。

（2）行业应用引擎提供针对如图侦、交管、社区等应用场景的特有服务能力集合。

（3）Agent 工程工具聚焦于应用开发与发布，包括应用交互、调试、发布及 Agent 框架搭建、知识库调用等操作，支持检索增强生成等。

（4）行业应用场景图谱覆盖智慧图侦、智慧交管、平安城市、平安社区等众多领域，助力实现行业融合应用开发，将模型与数据能力转化为服务实战的行业应用。

运行服务子平台：以“需求对接+全链路服务+生态协同”为核心，面向租户与生态伙伴的统一服务入口，对外提供 AI 能力和产品，同时对内具备能力管理、资源管理、租户管理、AI 资产管理等功能，包括：

（1）运行服务系统提供 AI 能力和产品的展示、资源申请、能力开发、订单结算、生态对接等全场景租户需求，实现从需求发现、资源获取到服务使用、问题反馈的全链路闭环。

（2）综合管理系统提供租户管理、订单管控、效能分析、资产交付、身份认证等全场景需求，为前台运行服务系统提供全链路、一

体化的底层支撑能力。

6.1.5.2 算力服务子平台

算力资源服务子平台采用先进的人工智能计算架构，提供人工智能应用所需算力服务、数据服务、算法服务和算力调度服务的公共算力新型基础设施。通过算力的生产、聚合、调度和释放，高效支撑数据开放共享、智能生态建设、产业创新聚集。算力资源服务为整个共性服务平台提供底层资源支撑，包括计算资源（CPU、GPU 资源）、存储资源、网络资源和安全资源，底层高性能 AI 计算能力提供芯片、服务器、高性能网络等服务。同时，算力资源服务支持使用国产 AI 芯片，来完成部分推理或训练任务。

具体建设模块包括：基础云系统、算力调度系统。

6.1.5.2.1 算力服务子平台架构




图 133 算力资源服务子平台逻辑架构

算力资源服务子平台，兼容适配业界广泛使用的主流硬件、操作系统，对算力资源进行统一管理、调度和监控，同时进行细粒度的资源实时分配，实现海量任务的智能自动调度、任务管理、数据加载和预处理，支撑大模型从数据处理到预训练、微调到多模型管理的整个

研发流程。

算力资源服务设计遵照“分层解耦，异构兼容，统一管理，统一服务”的目标，整合硬件资源，实现硬件资源的共享，通过算力资源服务对基础设施资源进行统一的管理，屏蔽底层硬件的异构性和组网的复杂性。通过计算、存储、网络等虚拟化技术将传统物理设备进行池化处理，构建统一的计算、存储、网络和安全资源池。为上层应用提供运行稳定、安全隔离、按需获取的基础资源服务，以细粒度管理方式充分利用基础设施资源，大幅提高云计算平台基础设施的资源利用率。

基础云系统：是对基础设施的云化管理，通过云管理模块将基础设施层提供的硬件设备按照逻辑功能的不同划分为计算、存储、网络等不同功能的资源池，其中，计算资源池包括云服务器、裸金属服务器、GPU 服务器、容器服务、弹性伸缩服务；存储资源池包括块存储、对象存储、文件存储；网络资源池包括私有网络、弹性公网 IP、专线服务、云解析服务、负载均衡服务；数据库与中间件包括关系型数据库、内存数据库、全文数据库。同时，提供云安全模块，对云内安全进行统一保障。

算力调度系统：算力调度系统是基于基础云系统构建，聚焦智算设备，提供算力资源管理、任务调度、模型优化、故障诊断及性能优化于一体的综合性平台。为用户提供个性化、高效能的算力服务，适配人工智能相关需求，助力构建稳定可靠的高性能计算环境。包括用户中心、资源中心、镜像中心、模型训练、模型部署。

6.1.5.2.2 算力服务子平台技术方案

6.1.5.2.2.1 基础云系统

基础云系统是核心基础设施，提供云管理模块和云安全模块，其

中云管理模块包含计算资源池、存储资源池、网络资源池、数据库与中间件等服务能力。

基础云系统提供领先的虚拟化技术，通过虚拟机和软件定义网络，实现了多租户隔离及组网，对于计算/虚拟机隔离，租户的虚拟机被创建在指定的计算节点上或将它的虚拟机部署在指定的专有的服务器上，主要是通过 **Host aggregate** 技术来支持这种需求的实现。存储卷物理隔离，不同租户的卷创建在不同的后端存储上，即支持租户在指定的后端上创建卷 **Volume**。在网络的逻辑隔离，采用 **VxLAN** 等技术模式，不同租户或应用相互隔离，即便在同一个机房内也不可见，有效保证数据的安全性。同时在单地域内可以将部署在多个机房的服务纳入同一个虚拟网络，即可实现多机房冗余。

基础云系统拥有多种存储技术，可针对用户不同应用场景提供量身定制的解决方案。包括块存储、文件存储、对象存储等，支持海量数据的大规模压力考验，能够确保用户的数据安全可靠。

基础云系统提供多种数据库和中间件服务，包括关系型数据库，对性能要求高的 **NoSQL** 存储系统，支持全文检索的弹性搜索服务。

6.1.5.2.2.1.1 云管理模块

6.1.5.2.2.1.1.1 计算资源池

6.1.5.2.2.1.1.2 云服务器




图 134 云服务器架构

云服务器是基于虚拟化技术构建的虚拟服务器，通过整合物理服务器资源，为用户提供一种处理能力可弹性伸缩的计算服务，管理方式比物理服务器更简单高效。根据业务需要，用户可按需配置资源，随时创建或释放任意多台云服务器实例，提升运维效率。

云服务器为用户快速部署应用构建提供稳定可靠的基础，可以降低网络规模计算的难度，使用户更专注于核心业务创新。另外，用户无需再购买及维护托管虚拟机的硬件，使用云服务器能有效降低 IT 成本。

6.1.5.2.2.1.1.3 裸金属服务器




图 135 裸金属服务器产品架构

裸金属服务器是用户可以在云环境中独享的高性能物理裸机，用户拥有完全的物理设备管理权限，同时可以结合弹性公网 IP、负载均衡灵活组网，并与云服务器在内网互通，灵活应对用户多种复杂场景的业务需求，轻松构建内网混合云。

基于智算云提供的裸金属服务器，用户可以在管理控制台便捷的创建和管理云环境中的物理裸机，包括配置裸金属服务器名称、网络 IP，查看硬件配置和创建时间等。

6.1.5.2.2.1.1.4 GPU 服务器




图 136 基地运行组织架构

GPU 服务器是配备独享 GPU 卡的高性能云计算服务，可以帮助用户快速、便捷的获得高质量的 GPU 计算资源，能够大幅提高机器学习及科学计算等大规模计算框架的运行速度，为搭建人工智能及高性能计算平台提供基础架构支持。

GPU 服务器提供两种形态计算资源，虚拟机形态的 GPU 云服务器和物理机形态的 GPU 物理服务器：

(1) GPU 云服务器：提供与标准云服务器一致的管理方式，用户可以快速灵活地申请并管理 GPU 云服务器，结合私有网络 VPC、

负载均衡负载均衡，共同构建云环境中高可用的 GPU 集群。

(2) GPU 物理服务器：当普通 GPU 云服务器无法满足用户的业务要求时，智算云还可以提供租用独享 GPU 物理服务器的服务。并在用户计划搭建超高性能的 GPU 集群时，提供配置更多 GPU 卡(8 卡以上)和高速互联带宽的超高性能的 GPU 物理服务器集群的服务。

6.1.5.2.2.1.1.5 容器服务




图 137 容器服务架构

容器服务基于轻量级虚拟化技术，提供接近物理服务器的高性能容器环境，支持容器全生命周期管理，实现业务快速部署与弹性调整；依托 Kubernetes 与 Docker 构建容器引擎，提供集群动态创建、自动扩缩容、监控运维、镜像及工作负载管理等能力，降低搭建维护成本并提升可观测性与可用性，覆盖计算、网络、存储、权限、日志监控等完整功能模块；支持服务模块拆分与独立部署升级，容器具备独立环境镜像与网络 IP，通过灵活方式实现服务发现，可整合各类云服务构建服务集群，且集群环境迁移、复制便捷，通过镜像选择与访问地址配置即可快速搭建一致新集群。

6.1.5.2.2.1.1.6 弹性伸缩




图 138 弹性伸缩服务架构

弹性伸缩是自动化扩缩容用户云资源的管理服务，当用户业务所需的云资源用量经常性变化时，弹性伸缩会是用户使用云资源的理想方式。

目前弹性伸缩能够帮用户的管理的云资源包括云服务器，以及和云服务器相关的云磁盘和弹性公网 IP 等。支持对这些资源进行自动化的横向扩缩容。

6.1.5.2.2.1.1.7 存储资源池

6.1.5.2.2.1.1.8 云磁盘




图 139 云磁盘架构

云磁盘是一种安全可靠的高弹性存储服务，作为云服务器的扩展块存储部件，为云服务器数据存储提供高可用和高容量支持。有独立于云服务器的生命周期，支持快速扩容、在线备份和回滚。

云磁盘支持数据的随机读写，在吞吐量，IOPS 以及异常恢复时间等方面，都有不错的性能，能够满足大部分客户在各类场景下的使用需求。

云磁盘具有独立于云服务器的生命周期，并支持在线扩容，在线转换云磁盘类型，通过自动快照进行容灾备份和磁盘回滚等众多弹性管理功能。

相比本地盘，云磁盘采用三副本或纠删码技术对磁盘数据进行存储。若部分存储节点，存储介质或网络交换机发生意外故障，数据会立即迁移到其它节点，用户对数据的访问不会受到任何影响，更不会

感知到组件故障的发生。

6.1.5.2.2.1.1.9 对象存储




图 140 对象存储架构

对象存储，是一种以对象为单位，将数据、元数据和唯一标识符组合存储的分布式存储架构，具有高扩展性、高持久性和高可用性特点，对外提供统一的存储接口服务。

支持常见的访问接口统一访问，通过标准的 RESTful API 接口提供服务，支撑多种业务需求。对象存储支持多数据中心多活。

支持不同类别数据存放到不同存储类型，以降低总存储成本，同时满足服务要求。

6.1.5.2.2.1.1.10 网络资源池

6.1.5.2.2.1.1.11 私有网络




图 141 私有网络架构

私有网络 VPC (Virtual Private Cloud) 是一个用户能够自定义的虚拟网络。通过 VPC，用户可以灵活设置网络地址空间，实现私有网络隔离，多个虚拟网络之间（同城和跨城）稳定高速对等互通。通过对等连接网关云平台 VPC 支持多个私有网络之间（同城和跨城）高速、稳定对等互通。通过 VPN/专线的方式，将云平台与用户的私有数据中心构建组成一个灵活、可扩展的混合云，实现原有业务轻松、安全地迁移到云端。

6.1.5.2.2.1.1.12 弹性公网 IP

